Fichamento: Faithfulness Estimate

ALVAREZ-MELIS, D.; JAAKKOLA, T. S. *Towards Robust Interpretability with Self-Explaining Neural Networks.* NeurIPS, 2018, p. 7786–7795

Métrica no Quantus: `quantus.FaithfulnessEstimate`

Aluno: Arthur Santos de Oliveira (RA: 156297)

Atualizado em: 20/10/2026

Repositório: https://github.com/Arthur-so/shap-ecg-arrhythmia

---

Como ler. `[p. N]` indica a página do PDF do artigo (16 páginas, incluindo o material suplementar). As citações estão no original em inglês, cada uma seguida de uma tradução livre. A **Parte I** explica a métrica sem pressupor a leitura do artigo; a **Parte II** é o fichamento, em ordem de páginas; a **Parte III** descreve a versão implementada no TCC, sua aderência ao artigo e os resultados; a versão antiga, do Quantus, aparece resumida no final.

PARTE I · ENTENDENDO A MÉTRICA

1. O problema que a métrica resolve

A pergunta é a mesma da Faithfulness Correlation: **as importâncias que a explicação atribui correspondem ao efeito real dos atributos sobre o modelo?** Muda a forma de testar. Em vez de retirar grupos de atributos sorteados, a Faithfulness Estimate retira **cada atributo isoladamente**, um de cada vez, e verifica se os atributos considerados mais importantes são os que mais mudam a saída do modelo.

2. A ideia em uma frase e um exemplo

> **Definição em uma frase**
> Para cada atributo, mede-se a **queda na saída do modelo** quando só ele é retirado (substituído por um valor de referência). A Faithfulness Estimate é a **correlação de Pearson** entre a importância que a explicação dá a cada atributo e essa queda.

Exemplo com 4 atributos. Duas explicações dizem o quanto cada atributo importa:

	Atributo 1	**Atributo 2**	**Atributo 3**	**Atributo 4**
Importância segundo a **explicação A**	0,5	0,3	0,1	0,1
Importância segundo a **explicação B**	0,1	0,1	0,3	0,5
Queda real ao retirar só esse atributo	0,40	0,25	0,08	0,06

A queda real é medida no modelo: retira-se o atributo 1 (os outros três ficam como estão) e mede-se quanto a saída caiu; depois o atributo 2, e assim por diante. Com a explicação A, os atributos que ela considera mais importantes são os que mais derrubam a saída: a correlação entre a linha da explicação A e a linha da queda real é **0,998**, e a explicação é **fiel**. Com a explicação B, que inverte a ordem, a correlação é $-$**0,856**, e a explicação é **infiel**.

3. Passo a passo

Para um exemplo x, com a explicação φ:

1. Para cada atributo i: substituir só o atributo i pela baseline e medir a queda da saída, $f(x) - f(x_{[x_i=\bar{x}_i]})$.
2. Calcular a correlação de Pearson entre as importâncias φ_i e as quedas. Esse é o valor do exemplo x.

O valor de um conjunto de exemplos (no TCC, de uma classe) é a média dos valores dos exemplos. Vai de -1 a 1, e maior é melhor.

3.1. Diferença em relação à Faithfulness Correlation

	Faithfulness Correlation	**Faithfulness Estimate**
O que se retira de cada vez	Um grupo de atributos sorteado	Um único atributo
Quantas retiradas por exemplo	Um número escolhido de sorteios	Uma por atributo (todos)
Importância comparada	Soma das importâncias do grupo	Importância do atributo
Pergunta	Grupos mais importantes derrubam mais a saída?	Atributos mais importantes derrubam mais a saída?

4. Traduzindo para o ECG

No ECG, retirar **um ponto** (uma derivação em um instante) de cada vez não faz sentido: são 180 000 pontos, pontos vizinhos são quase iguais, e retirar um só praticamente não muda o sinal. O próprio artigo diz que, para entradas de alta dimensão, atributos brutos (como pixels) levam a explicações ruidosas, e propõe trabalhar com **atributos de nível mais alto** (Parte II, citação da p. 4). No TCC, esse papel pode ser cumprido pelas **36 regiões do batimento** (12 derivações × pré-QRS, QRS e ST-T), já usadas na Consistency e na Faithfulness Correlation.

Glossário rápido

Atributo (feature) Cada unidade que recebe uma importância e pode ser retirada.

Conceito (basis concept) No artigo, um atributo de nível mais alto que um pixel, como um traço ou uma textura.

Baseline (valor de referência) Valor usado para "retirar" um atributo, substituindo o original.

Queda Diferença entre a saída do modelo com a entrada original e com o atributo retirado.

PARTE II · FICHAMENTO DO ARTIGO

5. Mapa de leitura

O artigo propõe um modelo autoexplicativo (SENN). Só uma parte é sobre a métrica:

Páginas	**Seção**	**Prioridade**	**Por quê**
p. 1	Resumo, §1	`ler`	Os três requisitos: explicitude, fidelidade e estabilidade
p. 2	§2.2	`ler`	Atributos brutos × conceitos de nível mais alto
p. 2–4	§2.3–§3	`pular`	Arquitetura do SENN
p. 4	§4	`ler`	Por que atributos brutos são ruins em alta dimensão
p. 5	§5, §5.1	`ler`	Critérios de avaliação e métodos comparados (inclui SHAP)
p. 6	§5.3, Fig. 3	`ler`	**A métrica**
p. 7	§5.4	`consulta`	Estabilidade (base da Local Lipschitz Estimate, a revisar depois)

6. Citações comentadas

`p. 1` Resumo

"We propose three desiderata for explanations in general – explicitness, faithfulness, and stability – and show that existing methods do not satisfy them."
Tradução: "Propomos três requisitos para explicações em geral — explicitude, fidelidade e estabilidade — e mostramos que os métodos existentes não os satisfazem."

EXPLICAÇÃO
A Faithfulness Estimate do Quantus vem do requisito de **fidelidade**. O requisito de **estabilidade**

dá origem à Local Lipschitz Estimate, que também está no pipeline do TCC.

p. 2 §2.2 Além dos atributos brutos

"Typical interpretable models tend to consider each variable (one feature or one pixel) as the fundamental unit which explanations consist of. However, pixels are rarely the basic units used in human image understanding; instead, we would rely on strokes and other higher order features. We refer to these more general features as interpretable basis concepts and use them in place of raw inputs."
TRADUÇÃO: "Modelos interpretáveis típicos tendem a considerar cada variável (um atributo ou um pixel) como a unidade fundamental de que as explicações são feitas. No entanto, pixels raramente são as unidades básicas usadas na compreensão humana de imagens; em vez disso, nos apoiaríamos em traços e outros atributos de ordem superior. Chamamos esses atributos mais gerais de conceitos básicos interpretáveis e os usamos no lugar das entradas brutas."

EXPLICAÇÃO
Os autores defendem explicar em termos de **unidades com significado**, e não de pixels. No ECG, o equivalente natural de um "traço" são as ondas e segmentos do batimento (P, QRS, ST-T) em cada derivação.

p. 4 §4 Conceitos básicos interpretáveis

"Raw input features are the natural basis for interpretability when the input is low-dimensional and individual features are meaningful. For high-dimensional inputs, raw features (such as individual pixels in images) often lead to noisy explanations that are sensitive to imperceptible artifacts in the data [...]. To avoid some of these shortcomings, we can instead operate on higher level features. [...] For example, in medical image processing higher-level visual aspects [...] are among the first aspects that doctors look for when diagnosing, so they are natural "units" of explanation."
TRADUÇÃO: "Os atributos brutos da entrada são a base natural para a interpretabilidade quando a entrada tem baixa dimensão e os atributos individuais têm significado. Para entradas de alta dimensão, atributos brutos (como pixels individuais em imagens) frequentemente levam a explicações ruidosas, sensíveis a artefatos imperceptíveis nos dados [...]. Para evitar algumas dessas deficiências, podemos trabalhar com atributos de nível mais alto. [...] Por exemplo, no processamento de imagens médicas, aspectos visuais de nível mais alto [...] estão entre os primeiros que os médicos procuram ao diagnosticar, e por isso são 'unidades' naturais de explicação."

EXPLICAÇÃO: TRECHO-CHAVE PARA O TCC
Este é o principal argumento do próprio artigo para **não usar pontos isolados do ECG** como atributos. O ECG tem 180 000 valores por exame (alta dimensão), e um ponto isolado não tem significado. As regiões do batimento são, como no exemplo médico do artigo, as unidades que o cardiologista examina.

p. 5 §5 Critérios de avaliação

"(ii) Faithfulness: Are relevance scores indicative of "true" importance? [...] proposing qualitative assessment of (i) and quantitative metrics for evaluating (ii) and (iii)."
TRADUÇÃO: "(ii) Fidelidade: os escores de relevância indicam a importância 'verdadeira'? [...] propondo uma avaliação qualitativa de (i) e métricas quantitativas para avaliar (ii) e (iii)."

EXPLICAÇÃO
A fidelidade é um dos dois critérios para os quais os autores propõem uma **medida quantitativa**. A outra é a estabilidade.

p. 5 §5.1 Dados e métodos

"We carry out quantitative evaluation on three classification settings: (i) MNIST digit recognition, (ii) benchmark UCI datasets and (iii) Propublica's COMPAS Recidivism Risk Score datasets. [...] We compare our approach against [...] LIME, kernel Shapley values (SHAP) and perturbation-based occlusion sensitivity [...]."
TRADUÇÃO: "Realizamos a avaliação quantitativa em três cenários de classificação: (i) reconhecimento de dígitos do MNIST, (ii) conjuntos de referência da UCI e (iii) os dados de risco de reincidência COMPAS, da Propublica. [...] Comparamos nossa abordagem com [...] LIME, valores de Shapley via kernel (SHAP)

e sensibilidade por oclusão [...].”

EXPLICAÇÃO

Os experimentos de fidelidade (Figura 3) usam dados **tabulares da UCI** (ionosphere, heart, diabetes, abalone), com poucas dezenas de atributos ou menos, e o SHAP avaliado é o **KernelSHAP**. No MNIST, a métrica é aplicada a poucos **conceitos aprendidos**, e não a pixels.

p. 6 §5.3 Fidelidade: a métrica

“Since this is rarely available, a common approach to measuring the faithfulness of relevance scores with respect to the model they are explaining relies on a proxy notion of importance: observing the effect of removing features on the model’s prediction. For example, for a probabilistic classification model, we can obscure or remove features, measure the drop in probability of the predicted class, and compare against the interpreter’s own prediction of relevance [17, 3]. Here, we further compute the correlations of these probability drops and the relevance scores on various points, and show the aggregate statistics in Figure 3 (left) for LIME, SHAP and SENN [...] on various UCI datasets.”

Tradução: “Como [a importância verdadeira] raramente está disponível, uma abordagem comum para medir a fidelidade dos escores de relevância em relação ao modelo explicado recorre a uma noção indireta de importância: observar o efeito de remover atributos sobre a predição do modelo. Por exemplo, para um modelo de classificação probabilístico, podemos ocultar ou remover atributos, medir a queda na probabilidade da classe predita e comparar com a predição de relevância do próprio explicador [17, 3]. Aqui, calculamos ainda as correlações entre essas quedas de probabilidade e os escores de relevância em vários pontos, e mostramos as estatísticas agregadas na Figura 3 (esquerda) para LIME, SHAP e SENN [...] em vários conjuntos da UCI.”

EXPLICAÇÃO

É a definição da métrica, descrita em texto (sem fórmula). Três pontos: (i) a saída usada é a **probabilidade da classe predita**; (ii) cada atributo é removido e sua queda é comparada com a sua relevância, e a **correlação** é calculada **por exemplo**; (iii) o resultado é agregado sobre vários exemplos. O procedimento de remoção vem de trabalhos anteriores ([17] Samek et al., 2017; [3] Arras et al., 2017).

p. 6 §5.3 Remoção de atributos em redes convolucionais

“[...] while feature removal is not always meaningful for other predictions models (i.e., one must replace pixels with black or averaged values to simulate removal in a CNN), the definition of our model allows for targeted removal of features, rendering an evaluation based on it more reliable.”

Tradução: “[...] embora a remoção de atributos nem sempre tenha significado para outros modelos de predição (isto é, é preciso substituir pixels por preto ou por valores médios para simular a remoção em uma CNN), a definição do nosso modelo permite a remoção direcionada de atributos, tornando uma avaliação baseada nela mais confiável.”

EXPLICAÇÃO

Os autores admitem que, em redes convolucionais como a do TCC, “remover” um atributo só pode ser **simulado**, trocando-o por preto ou por valores médios, e que isso torna a avaliação menos confiável. É a origem da baseline “black” do Quantus. Num ECG em z-score, o equivalente de “valores médios” é o zero (média de cada derivação).

p. 6 Figura 3

“Figure 3: Left: Aggregated correlation between feature relevance scores and true importance, as described in Section 5.3. Right: Faithfulness evaluation SENN on MNIST with learnt concepts.”

Tradução: “Figura 3: Esquerda: correlação agregada entre os escores de relevância dos atributos e a importância verdadeira, conforme descrito na Seção 5.3. Direita: avaliação de fidelidade do SENN no MNIST com conceitos aprendidos.”

EXPLICAÇÃO

A figura mostra a distribuição da métrica (eixo “Faithfulness Estimate”, de −0,5 a 1,0) para LIME, SHAP e SENN em quatro conjuntos da UCI. O artigo não traz os valores em tabela, só o gráfico, então serve como referência visual: a métrica varia bastante entre exemplos e métodos.

PARTE III · APLICAÇÃO AO TCC

7. Versão implementada no TCC

Código: `src/faithfulness_estimate.py` (commit `76c0dff`). Para cada um dos 622 mapas SHAP do modelo B (predições corretas do teste):

1. **Atributos.** O ECG é dividido nas **36 regiões do batimento**: 12 derivações × 3 tipos de trecho (pré-QRS, QRS e ST-T), a partir dos picos R detectados na derivação II. Cada região reúne o **mesmo tipo de trecho em todos os batimentos completos** daquela derivação (em média, 19 batimentos por ECG). O preenchimento e os batimentos incompletos ficam de fora.
2. **Importância de cada região:** a soma do mapa SHAP nos pontos da região.
3. **Retirada isolada:** cada região é trocada pela baseline, uma de cada vez (36 retiradas por ECG), e mede-se a **queda** da saída do modelo para a classe explicada: saída original menos saída com a região retirada.
4. **Correlação de Pearson** entre as 36 importâncias e as 36 quedas. Esse é o valor do ECG; a média por classe resume os resultados.
5. **Duas baselines:** zero (em escala z-score, é a média de cada derivação) e a média de cada ponto no conjunto de treino.
6. **Duas saídas:** o *logit* da classe (principal) e a probabilidade (sigmoide do *logit*, a saída do artigo), como verificação.

Conferência. Num modelo linear sintético com atribuições exatas, a métrica dá 1,000, como deve. O código reaproveita as funções da Faithfulness Correlation: com regiões, a Faithfulness Estimate é o caso dela com grupos de uma única região, percorrendo todas as regiões em vez de sorteá-las. Isso garante que as duas métricas usem exatamente as mesmas regiões e baselines.

8. Aderência ao artigo

Aspecto	Artigo	Versão do TCC	Aderente?
Procedimento	Retirar atributos e comparar a queda com a relevância (§5.3, p. 6)	Igual	Sim
O que se retira	Cada atributo, isoladamente	Cada região, isoladamente	Sim
Unidade de atributo	Atributos com significado; para entradas de alta dimensão, atributos de nível mais alto que o pixel (p. 2 e 4)	36 regiões do batimento	Sim, adaptado
Baseline	Preto ou valores médios, para simular a retirada em CNNs (p. 6)	Zero (média da derivação) e média do treino	Sim
Classe	Classe predita (p. 6)	Classe explicada, que é sempre uma classe predita (só predições corretas)	Sim
Saída	Probabilidade da classe (p. 6)	*Logit*; probabilidade como verificação	**Desvio justificado**
Correlação	Correlação por exemplo, agregada sobre vários exemplos (p. 6, Fig. 3)	Pearson por ECG, média por classe	Sim
Preenchimento	Não se aplica	Fora da métrica	Escolha do TCC

8.1. Adaptação 1: regiões no lugar de pontos

O artigo não retira pixels: ele argumenta que, em entradas de alta dimensão, os atributos brutos produzem explicações ruidosas e que é melhor trabalhar com unidades de nível mais alto, que tenham significado para quem interpreta, citando como exemplo os aspectos que os médicos procuram num diagnóstico (p. 4). As regiões do batimento seguem essa ideia: são os trechos que um cardiologista examina (onda P e intervalo PR, complexo QRS, segmento ST e onda T), em cada derivação. Duas consequências da escolha precisam ser registradas:

- **Uma região junta todos os batimentos.** Retirar "QRS de V1" troca o QRS de V1 em todos os batimentos de uma vez. A métrica avalia o que se repete batimento a batimento e dilui o que ocorre em um só batimento, como uma extrassístole (CVP, CAP).
- **Regiões não representam o ritmo.** Retirar uma região não muda o intervalo entre batimentos, que é o que define a fibrilação atrial (AF). A métrica tende a subestimar a fidelidade em classes de ritmo.

8.2. Adaptação 2: *logit* no lugar da probabilidade

O modelo é muito confiante nas predições corretas: num diagnóstico com 18 ECGs, a mediana do *logit* original foi 7,07, o que corresponde a uma probabilidade de 99,9%. Nessa faixa, a probabilidade satura: nos 622 mapas, 84% das retiradas mudam a probabilidade menos de 0,01, e a correlação passa a depender de poucas retiradas. O *logit* é a mesma saída antes da sigmoide, não satura e distingue melhor os efeitos. Por isso é a saída principal. A probabilidade é calculada nas mesmas retiradas e reportada para mostrar que a conclusão não muda (seção 9).

9. Resultados

A versão adaptada foi calculada inicialmente no Kaggle (GPU T4, 20/10/2026) com os mapas da versão 1 (32 ECGs sorteados do treino como referência do GradientSHAP, 50 sorteios). Desde 26/10/2026 o TCC usa a versão 2 dos mapas (opção D do documento `fichamentos/verificacao-referencia-gradientshap`): referência balanceada, com 4 ECGs de rótulo único de cada uma das 9 classes (36), e 200 sorteios por mapa. A métrica foi recalculada com os mapas novos, com o mesmo código `src/faithfulness_estimate.py`, para os mesmos **622 mapas** do modelo B (predições corretas do teste; versão 23 do notebook). Cada mapa teve as 36 regiões retiradas uma a uma, nas duas baselines. Não houve nenhum valor indefinido. Os arquivos estão em `results/modeloB_v2/faithest/`; os da versão 1, em `results/modeloB_faithest/`.

9.1. Por classe

A tabela usa os mapas da versão 2 e a baseline zero. A média do treino deu os mesmos valores até a segunda casa decimal (a maior diferença em um mapa foi 0,10). A Faithfulness Correlation é a do modelo B com grupos de 9 regiões, também com os mapas da versão 2, para comparação. Entre parênteses, a posição da classe (1.º = maior valor). A última coluna repete a Faithfulness Estimate da versão 1.

Classe	Mapas	FE (*logit*)	Desvio	FE (prob.)	Faithf. Corr.	F1	FE, versão 1
BRD	172	**0,78** (1.º)	0,11	0,76	0,75 (1.º)	0,927 (2.º)	0,78
BRE	20	0,70 (2.º)	0,14	0,56	0,65 (2.º)	0,870 (4.º)	0,72
CVP	59	0,66 (3.º)	0,14	0,57	0,62 (5.º)	0,837 (5.º)	0,66
STE	14	0,59 (4.º)	0,15	0,53	0,63 (4.º)	0,596 (9.º)	0,57
IAVB	61	0,55 (5.º)	0,19	0,54	0,65 (3.º)	0,884 (3.º)	0,57
CAP	45	0,54 (6.º)	0,17	0,52	0,50 (7.º)	0,750 (8.º)	0,55
AF	108	0,52 (7.º)	0,21	0,51	0,54 (6.º)	0,931 (1.º)	0,51
SNR	78	0,49 (8.º)	0,23	0,40	0,45 (9.º)	0,796 (6.º)	0,51
STD	65	0,49 (9.º)	0,22	0,47	0,47 (8.º)	0,778 (7.º)	0,51
Global	622	**0,61**	0,21	0,57	0,60	0,819	0,62

SNR e STD diferem em menos de 0,01 e, na prática, empatam na última posição.

9.2. O que mudou em relação à versão 1

- **A ordem das classes é exatamente a mesma**, da 1.ª à 9.ª posição.
- **Os valores mudam pouco:** a média global passa de 0,62 para 0,61, e nenhuma classe muda mais de 0,02. Mapa a mapa, a diferença média entre as duas versões é de 0,07, e a correlação entre os valores das duas versões é 0,90 (diagnóstico, só para conferir a estabilidade).

Assim, a fidelidade medida não depende do ruído do GradientSHAP nem da escolha dos ECGs de referência da versão 1.

9.3. Verificações

- **Teste do sinal (todas as 22 392 retiradas):** retirar uma região de atribuição positiva baixa o *logit* em 0,31, em média; retirar uma de atribuição negativa o **aumenta** em 0,36. Em 68% das retiradas, o sinal da queda coincide com o sinal da atribuição. Retirar o que ajuda a classe baixa a saída, e retirar o que atrapalha a aumenta.
- **Distribuição:** a mediana por mapa é 0,65, e só 7 dos 622 mapas têm valor negativo.
- **Probabilidade (saída do artigo):** global de 0,57, contra 0,61 com o *logit*. Os valores ficam menores, sobretudo em BRE (0,70 → 0,56) e SNR (0,49 → 0,40), mas a ordem das classes muda pouco: BRD, BRE e CVP continuam no topo, e SNR, STD e AF, embaixo. A conclusão não depende da escolha da saída.
- **Onde a retirada pesa:** em média, retirar uma região QRS baixa o *logit* em 0,29; uma ST-T, em 0,12; uma pré-QRS, em 0,01. Esses valores não dependem dos mapas (só do modelo e da baseline), por isso são iguais nas duas versões.

9.4. O que se conclui

1. **As explicações são fiéis de forma moderada e em todas as classes.** A correlação global é 0,61, e o sinal da atribuição indica a direção do efeito da retirada na maioria dos casos (68%).
2. **A Faithfulness Estimate concorda com a Faithfulness Correlation.** O valor global é quase o mesmo (0,61 e 0,60), e a ordem das classes é parecida: BRD e BRE no topo; SNR, STD, AF e CAP embaixo. É o esperado, já que, com regiões, a Faithfulness Estimate é o caso da Faithfulness Correlation com grupos de uma região. A concordância mostra que o resultado não depende do tamanho do grupo retirado.
3. **A fidelidade coincide com o F1 só em parte** (comparação descritiva, sem coeficiente de correlação). BRD está entre as melhores nas duas medidas. Já AF tem o maior F1 e uma das menores fidelidades, e STE tem o menor F1 e fidelidade intermediária (com só 14 mapas).
4. **O resultado é estável:** refazer os mapas com outra referência e quatro vezes mais sorteios não muda a ordem das classes.

10. Versão antiga (Quantus) e por que foi substituída

A configuração usada antes no pipeline (`quantus.FaithfulnessEstimate` com `features_in_step=500`) ordenava os 180 000 pontos do mapa pela atribuição, formava 360 grupos de 500 pontos e trocava cada grupo pelo **mínimo** do próprio ECG, medindo a queda do *logit*. Ela tinha dado valores entre 0,13 e 0,51 por classe (modelo anterior). Um diagnóstico com 18 ECGs (2 por classe) comparou essa configuração com a versão por regiões:

	Versão antiga	**Regiões**
Queda média ao retirar o que tem atribuição positiva	+3,30	+0,29
Queda média ao retirar o que tem atribuição **negativa**	**+3,06**	**−0,37**
Faithfulness Estimate (*logit*)	0,21	0,60

Na versão antiga, trocar qualquer grupo de 500 pontos pelo mínimo derrubava a saída em cerca de 3, inclusive quando o grupo tinha atribuição negativa, que deveria fazer a saída subir. A queda media o **dano** causado ao sinal, e não a retirada de informação, e os valores positivos vinham da mistura entre grupos no sinal (muito dano) e no preenchimento (pouco dano). Com as regiões, o sinal da atribuição passa a indicar a direção do efeito, como se espera de uma explicação fiel.