# Fichamento: Faithfulness Correlation

BHATT, U.; WELLER, A.; MOURA, J. M. F. *Evaluating and Aggregating Feature-based Model Explanations*. IJCAI, 2020, p. 3016–3022

**Métrica no Quantus:** `quantus.FaithfulnessCorrelation`

**Aluno:** Arthur Santos de Oliveira (RA: 156297)

**Atualizado em:** 14/10/2026

**Repositório:** https://github.com/Arthur-so/shap-ecg-arrhythmia

---

**Como ler.** `[p. N]` indica a página do PDF do artigo (1 a 7; no anais, p. 3016 a 3022). As citações estão no original em inglês, cada uma seguida de uma tradução livre. A **Parte I** explica a métrica sem pressupor a leitura do artigo; a **Parte II** é o fichamento, em ordem de páginas; a **Parte III** compara o artigo com a implementação do Quantus e com a configuração usada no TCC, e avalia a aderência ao caso do ECG.

## PARTE I · ENTENDENDO A MÉTRICA

### 1. O problema que a métrica resolve

Um método como o SHAP atribui a cada atributo da entrada uma **importância** para a decisão do modelo. A pergunta da Faithfulness Correlation é: **essas importâncias correspondem ao efeito real dos atributos sobre o modelo?** Se a explicação diz que um conjunto de atributos é muito importante, retirar esses atributos deveria mudar muito a saída do modelo. Se diz que são pouco importantes, retirá-los deveria mudar pouco.

### 2. A ideia em uma frase e um exemplo

> **Definição em uma frase**
> Sorteiam-se vários subconjuntos de atributos. Para cada um, calcula-se (i) a **soma das importâncias** que a explicação dá a esses atributos e (ii) a **queda na saída do modelo** quando eles são substituídos por um valor de referência (*baseline*). A Faithfulness Correlation é a **correlação de Pearson** entre essas duas listas de números.

**Exemplo com 4 atributos.** Um modelo recebe 4 atributos (1, 2, 3 e 4). Duas explicações diferentes dizem o quanto cada atributo importa para a decisão:

| | **Atributo 1** | **Atributo 2** | **Atributo 3** | **Atributo 4** |
|---|---|---|---|---|
| Importância segundo a **explicação A** | 0,5 | 0,3 | 0,1 | 0,1 |
| Importância segundo a **explicação B** | 0,1 | 0,1 | 0,3 | 0,5 |

A explicação A diz que os atributos 1 e 2 são os mais importantes; a B diz o contrário, que são o 3 e o 4. Para saber qual delas é fiel ao modelo, retiram-se pares de atributos (substituindo-os pela baseline) e mede-se a queda real na saída do modelo. Para cada par, soma-se também a importância que cada explicação deu aos dois atributos retirados:

| **Par retirado** | **Queda real na saída (medida no modelo)** | **Soma segundo A** | **Soma segundo B** |
|---|---|---|---|
| {1, 2} | 0,70 | 0,5 + 0,3 = 0,8 | 0,1 + 0,1 = 0,2 |
| {1, 3} | 0,55 | 0,5 + 0,1 = 0,6 | 0,1 + 0,3 = 0,4 |
| {2, 4} | 0,30 | 0,3 + 0,1 = 0,4 | 0,1 + 0,5 = 0,6 |
| {3, 4} | 0,15 | 0,1 + 0,1 = 0,2 | 0,3 + 0,5 = 0,8 |
| **Correlação entre a soma e a queda real** | | **0,995** | **−0,995** |

**Como ler.** Com a explicação A, os pares que ela considera mais importantes (soma maior) são exatamente os que mais derrubam a saída do modelo: as duas colunas sobem e descem juntas, e a correlação é 0,995, perto de 1. A explicação A é **fiel**. Com a explicação B acontece o contrário: o par que ela considera mais importante, $\{3, 4\}$, é o que menos muda a saída. A correlação é $-0{,}995$, e a explicação B é **infiel**. Uma explicação sem nenhuma relação com o modelo daria correlação perto de 0.

## 3. Passo a passo

Para um exemplo $x$, com a explicação $\varphi$ e o tamanho de subconjunto $|S|$ fixados:

1. Sortear um subconjunto $S$ de $|S|$ atributos.
2. Somar as importâncias desses atributos: $\sum_{i \in S} \varphi_i$.
3. Substituir esses atributos pela baseline e medir a queda: $f(x) - f(x_{[x_S = \bar{x}_S]})$.
4. Repetir os passos 1 a 3 várias vezes (cada repetição é um par "soma, queda").
5. Calcular a correlação de Pearson entre as somas e as quedas. Esse é o valor do exemplo $x$.

O valor de um conjunto de exemplos (no TCC, de uma classe) é a média dos valores dos exemplos. Vai de $-1$ a 1, e maior é melhor.

## 4. Traduzindo para o ECG

No TCC, cada **atributo** é um ponto do ECG: uma derivação em um instante. São $12 \times 15\,000 = 180\,000$ atributos, e o mapa SHAP dá uma importância para cada um. A saída do modelo é o *logit* da classe explicada. Três escolhas, que o artigo deixa em aberto ou trata para dados tabulares, passam a pesar muito:

- **O que é um atributo.** No artigo, os atributos são variáveis tabulares com significado próprio (idade, pressão etc.). No ECG, pontos vizinhos são quase iguais (500 amostras por segundo), e um ponto isolado não tem significado clínico.
- **Quantos atributos retirar** ($|S|$). Retirar 2 de 17 variáveis é retirar uma parte relevante da entrada; retirar 224 pontos espalhados entre 180 000 é retirar 0,12% do sinal.
- **Com o que substituir** (a baseline). Num ECG, "retirar" um ponto significa trocá-lo por algum valor, e esse valor pode criar artefatos, como picos que não existem no sinal.

A Parte III mostra como o Quantus e a configuração do TCC fazem essas escolhas.

### Glossário rápido

**Atributo (feature)** Cada valor de entrada que recebe uma importância. No ECG: um ponto (derivação, instante).

**Baseline (valor de referência)** Valor usado para "retirar" um atributo, substituindo o original.

**Subconjunto ($S$)** Grupo de atributos retirados de uma vez; $|S|$ é o seu tamanho.

**Queda** Diferença entre a saída do modelo com a entrada original e com a entrada modificada.

**Logit** Saída do modelo antes da função sigmoide; é o valor usado pelo artigo e pelo Quantus.

# PARTE II · FICHAMENTO DO ARTIGO

## 5. Mapa de leitura

O artigo propõe três critérios de avaliação e métodos para combinar explicações. Só uma parte interessa a esta métrica:

| Páginas | Seção | Prioridade | Por quê |
|---|---|---|---|
| p. 1 | Resumo, §1 | `ler` | Os três critérios propostos |
| p. 2 | §2, §3.2 | `ler` | Notação e definição da fidelidade (Def. 3) |
| p. 2 | §3.1 | `consulta` | Max/Avg Sensitivity (métricas de robustez a revisar depois) |
| p. 2 | §3.3 | `pular` | Complexidade, não usada no TCC |
| p. 3–5 | §4–§6 | `pular` | Agregação de explicações |
| p. 5 | §7, §7.1 | `ler` | Configuração e procedimento dos experimentos de fidelidade |
| p. 6 | Tabela 2 | `ler` | Tamanhos de subconjunto e resultados |
| p. 5–6 | §7.2 | `consulta` | Sensibilidade (para as métricas de robustez) |

## 6. Citações comentadas

p. 1 Resumo

*"A feature-based model explanation denotes how much each input feature contributes to a model's output for a given data point. [...] This paper proposes quantitative evaluation criteria for feature-based explanations: low sensitivity, high faithfulness, and low complexity."*
Tradução: "Uma explicação de modelo baseada em atributos indica quanto cada atributo de entrada contribui para a saída do modelo em um dado ponto. [...] Este artigo propõe critérios quantitativos de avaliação para explicações baseadas em atributos: baixa sensibilidade, alta fidelidade e baixa complexidade."

**EXPLICAÇÃO**
O artigo define três critérios. A Faithfulness Correlation do Quantus corresponde à **alta fidelidade**. A **baixa sensibilidade** dá origem às métricas Max-Sensitivity e Avg-Sensitivity, que também estão no pipeline do TCC e serão revisadas depois. A complexidade não é usada.

p. 2 §2 Preliminares

*"An explanation function g from a family of explanation functions, G, takes in a predictor f and a point of interest x and returns importance scores $g(f, x) = \varphi_x \in R^d$ for all features, where $g(f, x)_i = \varphi_{x,i}$ [...] is the importance of (or attribution for) feature $x_i$ of x."*
Tradução: "Uma função de explicação g, de uma família de funções de explicação G, recebe um preditor f e um ponto de interesse x e retorna escores de importância $g(f, x) = \varphi_x \in R^d$ para todos os atributos, em que $g(f, x)_i = \varphi_{x,i}$ [...] é a importância (ou atribuição) do atributo $x_i$ de x."

**EXPLICAÇÃO**
No TCC, $f$ é a ResNet34-1D, $g$ é o GradientSHAP e $\varphi_x$ é o mapa SHAP com $d = 180\,000$ valores (12 derivações $\times$ 15 000 instantes). Nada no artigo impede que um "atributo" seja um grupo de pontos, mas a métrica é definida sobre os atributos que a explicação pontua.

p. 2 §3.2 Alta fidelidade

*"The feature importance scores from g should correspond to the important features of x for f; as such, when we set particular features $x_s$ to a baseline value $\bar{x}_s$, the change in predictor's output should be proportional to the sum of attribution scores of features in $x_s$. We measure this as the correlation between the sum of the attributions of $x_s$ and the difference in output when setting those features to a reference baseline."*
Tradução: "Os escores de importância de g devem corresponder aos atributos de x importantes para f; assim, quando fixamos determinados atributos $x_s$ em um valor de referência $\bar{x}_s$, a mudança na saída do preditor deve ser proporcional à soma dos escores de atribuição dos atributos em $x_s$. Medimos isso como a correlação entre a soma das atribuições de $x_s$ e a diferença na saída ao fixar esses atributos em uma baseline de referência."

**EXPLICAÇÃO**
É a ideia central (Parte I, seção 2): **soma das importâncias** de um subconjunto contra a **queda da saída** quando ele é retirado. O artigo atribui essa noção de fidelidade a Yeh et al. (2019), que é o artigo da métrica Infidelity.

p. 2 Observação sobre baselines

*"Remark (Reference Baselines). Recent work has discussed how to pick a proper reference baseline $\bar{x}$. [Sundararajan et al., 2017] suggests using a baseline where $f(\bar{x}) \approx 0$, while others have proposed taking the baseline to be the mean of the training data."*
TRADUÇÃO: "Observação (baselines de referência). Trabalhos recentes discutiram como escolher uma baseline de referência $\bar{x}$ adequada. [Sundararajan et al., 2017] sugere usar uma baseline em que $f(\bar{x}) \approx 0$, enquanto outros propõem tomar como baseline a média dos dados de treino."

**EXPLICAÇÃO**
A baseline representa a "ausência" do atributo, e o artigo cita duas opções: uma entrada neutra para o modelo, ou a média do treino. Nenhuma das duas é o valor mínimo do próprio sinal, que é o padrão do Quantus (seção 8).

p. 2 Definição 3 e estimação

*"Definition 3 (Faithfulness). Given a predictor f, an explanation function g, a point x, and a subset size $|S|$, we define the faithfulness of g to f at x as: $\mu_F(f, g; x) = corr_S$ ( $\Sigma_{i \in S}$ $g(f, x)_i$ , $f(x) - f(x_{[x_s = \bar{x}_s]})$ ). For our experiments, we fix $|S|$ then randomly sample subsets $x_s$ of the fixed size from x to estimate correlation. Since we do not see all subsets in our calculation of faithfulness, we may not get an accurate estimate of the criterion."*
TRADUÇÃO: "Definição 3 (Fidelidade). Dados um preditor f, uma função de explicação g, um ponto x e um tamanho de subconjunto |S|, definimos a fidelidade de g a f em x como: $\mu_F(f, g; x) = corr_S$ ( $\Sigma_{i \in S}$ $g(f, x)_i$ , $f(x) - f(x_{[x_s = \bar{x}_s]})$ ). Nos experimentos, fixamos |S| e sorteamos subconjuntos $x_s$ desse tamanho para estimar a correlação. Como não vemos todos os subconjuntos no cálculo da fidelidade, podemos não obter uma estimativa precisa do critério."

**EXPLICAÇÃO**
A correlação é calculada **para cada exemplo** $x$, sobre os subconjuntos sorteados. Há duas fontes de imprecisão admitidas pelos próprios autores: o valor depende do tamanho $|S|$ escolhido, e é estimado com uma amostra de subconjuntos, e não com todos. Quanto menos subconjuntos sorteados, mais instável a correlação.

p. 2 Para que serve a fidelidade

*"Though hard to codify and even harder to aggregate, faithfulness is desirable, as it demonstrates that an explanation captures which features the predictor uses to generate an output for a given input."*
TRADUÇÃO: "Embora seja difícil de codificar e ainda mais difícil de agregar, a fidelidade é desejável, pois demonstra que uma explicação captura quais atributos o preditor usa para gerar uma saída para uma dada entrada."

**EXPLICAÇÃO**
É uma medida **local** (por exemplo) e **relativa ao modelo**: não diz se a explicação está clinicamente certa, e sim se ela acompanha o que o modelo realmente usa.

p. 5 §7 Configuração

*"For all tabular datasets, we train a multilayer perceptron (MLP) [...] we use MIMIC [...]. We extract seventeen real-valued features deemed critical [...] for sepsis prediction. [...] For experiments with a baseline $\bar{x}$, zero baseline implies that we set features to 0 and average baseline uses the average feature value in D."*
TRADUÇÃO: "Para todos os conjuntos tabulares, treinamos um perceptron multicamadas (MLP) [...] usamos o MIMIC [...]. Extraímos dezessete atributos reais considerados críticos [...] para a predição de sepse. [...] Nos experimentos com uma baseline $\bar{x}$, a baseline zero significa fixar os atributos em 0, e a baseline média usa o valor médio do atributo em D."

**EXPLICAÇÃO**
Os experimentos de fidelidade são **todos tabulares**, com poucos atributos (o MIMIC tem 17), e usam as baselines **zero** e **média**. Não há experimento com séries temporais nem com entradas de alta dimensão.

p. 5 §7.1 Procedimento

*"When evaluating, we take the average of multiple runs where, in each run, we see at least 50 datapoints; for each datapoint, we randomly select |S| features and replace them with baseline values. We then calculate the Pearson's correlation coefficient between the predicted logits of each modified test point and the average explanation attribution for only the subset of features. We notice that, as subset size increases, faithfulness increases until the subset is large enough to contain all informative features."*
TRADUÇÃO: "Na avaliação, tiramos a média de várias execuções em que, em cada uma, vemos pelo menos 50 pontos; para cada ponto, selecionamos aleatoriamente |S| atributos e os substituímos por valores de baseline. Calculamos então o coeficiente de correlação de Pearson entre os logits preditos de cada ponto de teste modificado e a atribuição média da explicação apenas para o subconjunto de atributos. Notamos que, à medida que o tamanho do subconjunto aumenta, a fidelidade aumenta até que o subconjunto seja grande o bastante para conter todos os atributos informativos."

**EXPLICAÇÃO**
Três pontos para o TCC: (i) usa-se o **logit**; (ii) correlacionar a *média* das atribuições com o *logit modificado* dá o mesmo valor absoluto que a Definição 3 (soma × queda), porque para um $x$ fixo a média é a soma dividida por $|S|$ e a queda é $f(x)$ menos o logit modificado; (iii) **o resultado depende de** $|S|$: subconjuntos pequenos demais não contêm atributos informativos e dão fidelidade baixa.

p. 6 Tabela 2

*"Table 2: Faithfulness $\mu_F$ averaged over a test set: (Zero Baseline, Training Average Baseline). Exact quantities can be obtained by dividing table entries by $10^2$." (Subconjuntos: Adult 2, Iris 2, MIMIC 10 e 20; SHAP: (62, 60), (67, 68), (31, 36), (37, 47).)*
TRADUÇÃO: "Tabela 2: Fidelidade $\mu_F$ média sobre um conjunto de teste: (baseline zero, baseline média do treino). As quantidades exatas são obtidas dividindo os valores da tabela por $10^2$."

**EXPLICAÇÃO**
A tabela traz a Faithfulness Correlation de vários métodos de explicação (SHAP, Shapley Sampling, gradiente, Integrated Gradients, DeepLift e outros). Quando o método avaliado é o **SHAP** (estimado por mínimos quadrados ponderados, isto é, o KernelSHAP), a Faithfulness Correlation fica entre **0,31 e 0,68**. Estes são os números usados como referência no restante do fichamento. Os subconjuntos têm de 2 a 20 atributos, em dados tabulares com poucos atributos (o MIMIC usa 17 atributos selecionados). Esses números servem de referência de ordem de grandeza, e não de comparação direta com o ECG.

## PARTE III · APLICAÇÃO AO TCC

### 7. Do artigo ao código do Quantus

Arquivo: `quantus/metrics/faithfulness/faithfulness_correlation.py` (Quantus 0.6.0).

| Etapa | Artigo | Quantus |
|---|---|---|
| Subconjunto | $\|S\|$ fixo, sorteado | `subset_size` índices sorteados sem reposição entre todos os valores do mapa achatado |
| Soma das importâncias | $\sum_{i \in S} \varphi_i$ | Soma do mapa nos índices sorteados (com sinal; `abs=False`) |
| Retirada | Atributos fixados na baseline | Valores substituídos por `perturb_baseline` (padrão `"black"`) |
| Saída | Logit | Saída do modelo para a classe `y` (logit; `softmax=False`) |
| Queda | $f(x) - f(x_{[x_S = \bar{x}_S]})$ | `y_pred - y_pred_perturb` |
| Repetições | Várias, sem número fixo | `nr_runs` (padrão 100) |
| Correlação | Pearson por exemplo | Pearson por exemplo (`correlation_pearson`) |

A fórmula está implementada de acordo com o artigo. As diferenças estão nos **valores padrão**: a baseline `"black"` é o **valor mínimo do próprio exemplo** (`arr.min()` sobre todas as derivações e instantes), e não zero ou a média do treino; e `subset_size=224` vem do contexto de imagens.

## 8. Versão antiga: configuração usada no TCC até 14/10

Até 14/10, a métrica era calculada pelo Quantus, no `src/evaluate.py`, com `nr_runs=10`, `subset_size=224` e os demais valores padrão, por classe e só sobre as predições corretas. O valor da classe era a média dos exemplos, e valores indefinidos (NaN) eram descartados sem aviso.

| **Aspecto** | **Artigo** | **Versão antiga (Quantus)** | **Aderente?** |
|---|---|---|---|
| Fórmula (soma × queda, Pearson por exemplo) | Def. 3 | Igual | Sim |
| Saída usada | Logit | Logit da classe explicada | Sim |
| Unidade de atributo | Variável tabular com significado | Ponto isolado (derivação, instante) | **Não adaptada** |
| Tamanho do subconjunto | 2 a 20 atributos, em entradas com poucos atributos | 224 de 180 000 pontos (0,12%) | **Não** |
| Baseline | Zero ou média do treino | Mínimo do próprio ECG (pico negativo) | **Não** |
| Nº de subconjuntos por exemplo | Vários | 10 | Fraco |
| Trecho de preenchimento | Não se aplica | Incluído no sorteio | **Não** |
| Exemplos avaliados | Conjunto de teste | Só predições corretas, por classe | Recorte do TCC |

**Por que cada "Não" importa**

1. **Baseline "black".** Em sinal com z-score, o mínimo do ECG é um valor extremo, tipicamente o fundo de uma onda S. Trocar pontos por ele cria **picos artificiais**, aos quais o modelo pode reagir como se fossem eventos cardíacos. A queda medida passa a refletir o artefato, e não a ausência do atributo.
2. **Ponto isolado como atributo.** Pontos vizinhos do ECG são quase iguais, e um ponto isolado não carrega uma informação clínica. Retirar um ponto não equivale a retirar uma informação.
3. **Subconjunto pequeno e espalhado.** Os 224 pontos dão cerca de 19 por derivação, um a cada 1,6 s. A soma das atribuições desses pontos dispersos não representa nenhuma região do sinal.
4. **Preenchimento.** Cerca de metade dos 15 000 instantes de um registro típico é preenchimento (o registro médio tem 15 s). No diagnóstico, 45% dos pontos sorteados caíram ali, onde não há ECG.
5. **Poucas repetições.** Uma correlação de Pearson com 10 pares é muito instável.

*Correção:* na primeira versão deste fichamento, a hipótese era que as quedas ficariam perto de zero. O diagnóstico (seção 10) mostrou o contrário: as quedas são grandes, mas não têm relação com as atribuições, o que aponta para os artefatos do item 1.

## 9. Resultados da versão antiga

A métrica foi calculada no pipeline anterior (modelo de 30/09, ainda sem a classe CVP), com a configuração da seção 8:

| **Classe** | SNR | AF | IAVB | BRE | BRD | CAP | STD | STE |
|---|---|---|---|---|---|---|---|---|
| **Faithfulness Correlation** | 0,114 | 0,023 | 0,116 | −0,097 | 0,132 | −0,068 | 0,042 | 0,030 |

Todos os valores ficaram perto de zero (entre −0,10 e 0,13). Como referência, no próprio artigo de Bhatt et al. (2020), a Faithfulness Correlation das explicações SHAP fica entre 0,31 e 0,68 (Tabela 2, citação da p. 6). A comparação serve só como ordem de grandeza: lá, o SHAP é o KernelSHAP aplicado a dados tabulares; aqui, o GradientSHAP aplicado a ECG.

## 10. Diagnóstico: por que a versão antiga não funcionava

Para confirmar o problema com dados, as duas formas de "retirar atributos" foram testadas nos mesmos ECGs, com o modelo atual (modelo B). Antes dos números, os termos usados:

- **Região.** Um trecho do ECG com significado clínico. Cada batimento é dividido em três partes (pré-QRS, QRS e ST-T), e cada parte é considerada separadamente em cada uma das 12 derivações. Assim, **cada ECG tem 36 regiões** (12 derivações × 3 partes), por exemplo "QRS da derivação V1". A região inclui essa parte em todos os batimentos do registro.
- **Subconjunto.** Um grupo de atributos retirados *ao mesmo tempo*. Na versão antiga, um subconjunto são 224 pontos sorteados; na versão atual, são algumas regiões sorteadas. Neste teste, **cada subconjunto tem 9 das 36 regiões** (cerca de um quarto do ECG).
- **Repetição.** Para calcular uma correlação, é preciso repetir a retirada várias vezes, cada vez com um subconjunto diferente: cada repetição gera um par (soma das atribuições, queda da saída). Neste teste, foram **10 subconjuntos por ECG**, ou seja, 10 pares, e a correlação de cada ECG é calculada sobre esses 10 pares.

| **Número** | **O que é** |
|---|---|
| 9 classes × 4 ECGs = 36 ECGs | ECGs testados: 4 sorteados de cada uma das 9 classes (o 36 aqui é coincidência com o número de regiões) |
| 36 regiões | Partes em que *cada* ECG é dividido (12 derivações × pré-QRS, QRS, ST-T) |
| 9 regiões | Tamanho de cada subconjunto na versão atual: 9 das 36 regiões são retiradas de uma vez |
| 224 pontos | Tamanho de cada subconjunto na versão antiga |
| 10 subconjuntos | Quantas retiradas diferentes foram feitas em cada ECG (10 pares para a correlação) |

Resultado:

| | **Versão antiga**: 224 pontos → mínimo do ECG | **Versão atual**: 9 de 36 regiões → zero |
|---|---|---|
| Queda média do logit (logit original: ≈ 7,6 em módulo) | 2,56 | 2,14 |
| **Faithfulness Correlation média** | **−0,02** | **0,57** |
| Valores indefinidos (NaN) | 0 | 0 |
| Pontos sorteados no preenchimento | 45% | — (fora do sorteio) |

Na versão antiga, **o modelo reage muito à perturbação, mas a reação não tem relação com o que a explicação aponta** (correlação ≈ 0): a queda mede a resposta aos picos artificiais. Retirando regiões inteiras com uma baseline neutra, a correlação sobe para 0,57, na faixa que o artigo obtém para explicações SHAP (0,31 a 0,68, Tabela 2). Isso mostra que o resultado antigo vinha da configuração, e não das explicações.

## 11. Versão atual: implementação própria

A métrica foi reimplementada em `src/faithfulness_correlation.py` (commit `baf7d4f`), seguindo a Definição 3 do artigo, e a versão do Quantus foi retirada do pipeline.

### 11.1. Como funciona

1. **Atributos = regiões do batimento.** Os mesmos 36 atributos da Consistency: 12 derivações $\times$ 3 regiões (pré-QRS, QRS e ST-T), definidas a partir dos picos R. A importância de uma região é a soma do mapa SHAP em todos os seus pontos.
2. **Sorteio.** Para cada ECG, sorteiam-se 50 subconjuntos de $|S|$ regiões. Batimentos incompletos e o preenchimento ficam fora.
3. **Retirada.** Cada região sorteada é substituída pela baseline em todos os batimentos, e mede-se a queda do logit da classe explicada.
4. **Correlação.** Pearson entre as 50 somas e as 50 quedas, para cada ECG; depois, média por classe. Valores indefinidos são contados e reportados.
5. **Configurações.** Duas baselines (zero e média do treino), com os mesmos subconjuntos nas duas, e três tamanhos: $|S| = 4$, 9 e 18 regiões (cerca de 10%, 25% e 50% da entrada).

### 11.2. Artigo $\times$ versão antiga $\times$ versão atual

| **Aspecto** | **Artigo (Bhatt et al., 2020)** | **Versão antiga (Quantus)** | **Versão atual** |
|---|---|---|---|
| Fórmula | Pearson, por exemplo, entre soma das atribuições e queda da saída | Igual | Igual |
| Saída | Logit | Logit da classe explicada | Logit da classe explicada |
| Atributo | Variável tabular | Ponto isolado (180 000) | **Região do batimento (36)** |
| Importância do atributo | $\varphi_i$ | Valor do mapa no ponto | Soma do mapa na região |
| Tamanho do subconjunto | Fixo; 2 a 20 atributos; o artigo varia o tamanho | 224 pontos (0,12%) | **4, 9 e 18 regiões** (10 a 50%) |
| Baseline | **Zero e média do treino**, as duas reportadas | Mínimo do ECG | **Zero e média do treino** |
| Subconjuntos por exemplo | Vários (não fixado) | 10 | **50** |
| Preenchimento | Não se aplica | No sorteio | **Fora** |
| Valores indefinidos | — | Descartados sem aviso | **Contados** |
| Exemplos | Teste ($\geq$ 50 pontos) | Predições corretas, por classe | Predições corretas (622 mapas), por classe |

Única adaptação em relação ao artigo: o que é um **atributo**. Todo o resto segue o protocolo original, inclusive o uso das duas baselines e de mais de um tamanho de subconjunto, como na Tabela 2.

### 11.3. Conferência do código

Num caso sintético com um modelo linear, em que a atribuição exata de cada região é exatamente o efeito de retirá-la, a métrica deu **1,0**. Com a atribuição invertida, deu $-$**1,0**; com uma atribuição aleatória, $-0{,}12$ (perto de zero). Um teste completo com 18 mapas reais também rodou sem valores indefinidos. Nesse teste, as baselines zero e média do treino deram praticamente o mesmo resultado: como os batimentos não estão alinhados entre pacientes, a média de cada ponto (derivação, instante) nos ECGs de treino fica perto de zero.

## 12. Resultados da versão atual

A métrica foi calculada no Kaggle (GPU) para os 622 mapas do modelo B (versão 17 do notebook, com o modelo e os mapas do dataset `arthurso/shap-ecg-modelob`), com 50 subconjuntos por mapa. **Nenhum valor ficou indefinido.** As duas baselines deram resultados praticamente iguais (diferença máxima de 0,003), por isso a tabela mostra só a baseline zero.

| Classe | Mapas | F1 | $\|S\| = 4$ | $\|S\| = 9$ | $\|S\| = 18$ |
|---|---|---|---|---|---|
| BRD | 172 | 0,927 | 0,77 | **0,74** | 0,69 |
| BRE | 20 | 0,870 | 0,69 | **0,65** | 0,51 |
| IAVB | 61 | 0,884 | 0,58 | **0,64** | 0,62 |
| CVP | 59 | 0,837 | 0,64 | **0,61** | 0,54 |
| STE | 14 | 0,596 | 0,57 | **0,60** | 0,53 |
| AF | 108 | 0,931 | 0,54 | **0,54** | 0,55 |
| STD | 65 | 0,778 | 0,50 | **0,52** | 0,43 |
| CAP | 45 | 0,750 | 0,54 | **0,52** | 0,44 |
| SNR | 78 | 0,796 | 0,49 | **0,46** | 0,39 |
| **Global** | 622 | 0,819 | 0,61 | **0,61** | 0,55 |

*Valores de Faithfulness Correlation (média por classe), baseline zero; $|S|$ é o número de regiões, de 36, retiradas de uma vez em cada subconjunto. F1 no teste, com limiares por classe. Classes ordenadas pela coluna $|S| = 9$.*

### 12.1. Leitura

1. **As explicações são fiéis ao modelo, de forma moderada.** Todas as classes têm correlação positiva, entre 0,39 e 0,77, e a média global é 0,61. Quando o SHAP dá mais importância a um grupo de regiões, retirar esse grupo derruba mais a saída do modelo. Como ordem de grandeza, o valor fica na faixa que o artigo obtém para explicações SHAP em dados tabulares (0,31 a 0,68).
2. **Diferenças entre classes.** BRD tem as explicações mais fiéis em todos os tamanhos de subconjunto, e SNR as menos fiéis, também em todos. As demais classes trocam de posição conforme $|S|$.
3. **Efeito do tamanho do subconjunto.** A fidelidade global é igual com 4 e 9 regiões (0,61) e cai com 18 (0,55). O artigo observa que a fidelidade sobe com $|S|$ até o subconjunto conter os atributos informativos; aqui, retirar metade do ECG de uma vez já não aumenta a correlação.

### 12.2. Comparação descritiva com o F1 ($|S| = 9$)

| Classe | Posição no F1 | Posição na Faithfulness Correlation | Leitura |
|---|---|---|---|
| BRD | 2º | 1º | Concordância no topo |
| IAVB | 3º | 3º | Concordância no topo |
| BRE | 4º | 2º | Concordância no topo |
| CVP | 5º | 4º | Posições próximas |
| STD | 7º | 7º | Concordância na base |
| CAP | 8º | 8º | Concordância na base |
| AF | 1º | 6º | **Discordância**: melhor F1, fidelidade intermediária |
| SNR | 6º | 9º | **Discordância**: fidelidade mais baixa entre todas |
| STE | 9º | 5º | **Discordância**: pior F1, fidelidade intermediária (só 14 mapas) |

As duas ordenações coincidem em seis das nove classes (topo: BRD, IAVB, BRE; base: STD, CAP; CVP no meio) e divergem em três (AF, SNR e STE). Desempenho e fidelidade tendem a andar juntos, mas não de forma estrita. A comparação é descritiva, pelos mesmos motivos explicados no fichamento da Consistency: as nove classes não são observações independentes.

## 13. Como redigir no TCC

**Sugestão**
"A métrica Faithfulness Correlation (BHATT; WELLER; MOURA, 2020) mede a correlação de Pearson entre a soma das atribuições de subconjuntos aleatórios de atributos e a queda na saída do modelo (*logit*) quando esses atributos são substituídos por um valor de referência. Os experimentos originais usam dados tabulares com poucos atributos. A configuração padrão da biblioteca Quantus, aplicada ao ECG, sorteia 224 pontos isolados entre 180 000 e os substitui pelo valor mínimo do sinal; em um diagnóstico com 36 exemplos, essa configuração produziu quedas grandes na saída, mas sem relação com as atribuições (correlação média de $-0{,}02$), indicando que a perturbação mede artefatos. A métrica foi então implementada pelo autor seguindo o protocolo do artigo, com uma única adaptação: os atributos passaram a ser as 36 regiões do batimento (12 derivações $\times$ pré-QRS, QRS e ST-T), cuja importância é a soma das atribuições na região. Foram usados 50 subconjuntos por exemplo, subconjuntos de 4, 9 e 18 regiões e as duas baselines do artigo (zero e média do treino)."

**Sugestão: resultados**
"A Faithfulness Correlation foi positiva em todas as classes, com média global de 0,61 (subconjuntos de 9 regiões), variando de 0,46 (SNR) a 0,74 (BRD). As duas baselines produziram valores praticamente idênticos. Comparando as ordenações, as classes de maior e menor desempenho preditivo coincidem, em sua maioria, com as de maior e menor fidelidade (BRD, IAVB e BRE no topo; STD e CAP na base), com exceções em AF, SNR e STE."