# Fichamento: justiça das explicações (lacunas de fidelidade)

BALAGOPALAN, A.; ZHANG, H.; HAMIDIEH, K.; HARTVIGSEN, T.; RUDZICZ, F.; GHASSEMI, M. *The Road to Explainability is Paved with Bias: Measuring the Fairness of Explanations*. ACM Conference on Fairness, Accountability, and Transparency (FAccT), 2022

**Tema:** diferença de qualidade das explicações entre subgrupos de dados

**Aluno:** Arthur Santos de Oliveira (RA: 156297)

**Atualizado em:** 28/10/2026

**Link:** https://arxiv.org/abs/2205.03295

**Leitura:** íntegra do texto principal (arXiv v2, pp. 1–16); apêndices (provas, tabelas adicionais, detalhes da simulação) não lidos

**Repositório:** https://github.com/Arthur-so/shap-ecg-arrhythmia

---

**Como ler.** `[p. N]` indica a página do PDF lido (arXiv v2, 33 páginas com apêndices). As citações estão no original em inglês, cada uma seguida de uma tradução livre e de uma explicação.


**Resumo**

- **Objetivo:** auditar se a qualidade das explicações pós-hoc é igual entre subgrupos protegidos (sexo, raça).
- **Dados e modelos:** quatro conjuntos tabulares (adult, lsac, mimic, recidivism); modelos caixa-preta de regressão logística e rede neural.
- **Métodos de explicação:** locais (LIME, SHAP) e globais (modelo aditivo generalizado, GAM, e árvore de decisão esparsa).
- **Avaliação: fidelidade** no sentido de aproximação (quanto o modelo explicativo reproduz as predições da caixa-preta), medida por acurácia, AUROC e erro médio, e duas medidas de **lacuna de fidelidade** entre subgrupos; 5 repetições; teste de Wilcoxon.
- **Conclusão:** a fidelidade difere de forma significativa entre subgrupos; a média global superestima a qualidade para alguns deles.


## 1. O que o trabalho faz

O artigo transporta para as explicações a ideia de justiça de grupo (*group fairness*): uma explicação é justa se tem fidelidade igualmente alta para todos os grupos. Aqui, "fidelidade" é a qualidade com que um modelo simples (linear local, GAM ou árvore) imita a caixa-preta, e não a correlação entre atribuição e queda da predição usada no TCC. Os autores provam que a diferença de paridade demográfica entre a caixa-preta e a explicação é igual à diferença do erro residual médio entre os grupos, o que liga a lacuna de fidelidade à preservação da justiça. Depois medem as lacunas, testam treino robusto (Just Train Twice e reamostragem balanceada), investigam causas (justiça da caixa-preta e informação de grupo presente nas variáveis) e simulam o efeito sobre decisões de admissão.

## 2. Como avalia as explicações

- **Lacuna máxima em relação à média** ($\Delta_L$): diferença entre a fidelidade média e a do pior subgrupo.
- **Lacuna média entre subgrupos** ($\Delta_L^{group}$): média das diferenças de fidelidade entre todos os pares de grupos do mesmo atributo.
- **Configuração:** divisão 50% (treino da caixa-preta) / 30% (treino da explicação) / 10% (validação) / 10% (teste); 5 repetições; lacunas testadas contra zero com o teste de Wilcoxon unilateral ($p < 0{,}05$); grupos interseccionais excluídos por tamanho amostral.

## 3. Resultados e conclusões

| Achado | Valor relatado |
|---|---|
| LIME, lacuna máxima de acurácia em relação à média | 0,1% a 21,4% |
| LIME, lacunas entre grupos protegidos (AUROC / acurácia) | 0–6,6% / 0,3–20,6% |
| GAM e árvore, lacuna máxima de acurácia | 0 a 13,5% |
| mimic, regressão logística: diferença de desempenho da caixa-preta entre sexos × lacuna de fidelidade da árvore | 3,6% × 8,1% |
| Fidelidade média global de todos os modelos | acima de 85% |

O SHAP tem lacuna zero quando a explicação usa as mesmas variáveis da caixa-preta, mas a lacuna aparece quando se usa um subconjunto delas; explicações mais esparsas têm lacunas maiores. O treino robusto reduz as lacunas em alguns conjuntos, mas não as elimina. As lacunas persistem mesmo com caixas-pretas justas e diminuem quando as variáveis carregam pouca informação de grupo. O subgrupo com as piores explicações nem sempre é o minoritário. A simulação, apoiada em hipóteses fortes declaradas pelos autores, sugere que lacunas maiores levam a diferenças maiores na acurácia das decisões.

## 4. Citações

p. 2 §1 Introdução

*"These findings indicate that judging the quality of explanations by their average fidelity alone—a common approach—overestimates explanation quality for some subgroups, potentially leading to worse downstream decision making."*
Tradução: "Esses resultados indicam que julgar a qualidade das explicações apenas pela fidelidade média, uma abordagem comum, superestima a qualidade das explicações para alguns subgrupos, o que pode levar a decisões piores."

**EXPLICAÇÃO**
É o argumento central para relatar as métricas do TCC por classe de arritmia, e não só a média global: uma Faithfulness Correlation média aceitável pode esconder classes com explicações muito piores.

p. 11 §6.1 Caixas-pretas justas

*"Strikingly, the gaps in fidelity AUROC often exceed the gaps in AUROC of the blackbox models themselves"*
Tradução: "De forma marcante, as lacunas de fidelidade em AUROC frequentemente excedem as lacunas de AUROC dos próprios modelos caixa-preta"

**EXPLICAÇÃO**
A diferença de qualidade da explicação entre grupos não é um reflexo da diferença de desempenho do modelo: pode ser maior e ter outras causas. Para o TCC, a ordem das classes pelo F1 e a ordem pelas métricas de explicação não precisam coincidir, e a divergência é um resultado em si.

p. 14 §8.1 Recomendações

*"We also highlight the importance of carefully choosing the metric for measuring fidelity (e.g., accuracy, AUROC, precision, etc.): different metrics may be affected by properties of the dataset and hence predictions from a blackbox/explanation model (e.g., class imbalance) differently."*
Tradução: "Destacamos também a importância de escolher com cuidado a métrica de fidelidade (p. ex., acurácia, AUROC, precisão etc.): métricas diferentes podem ser afetadas de modos diferentes por propriedades do conjunto de dados e, portanto, pelas predições da caixa-preta ou do modelo explicativo (p. ex., desbalanceamento de classes)."

**EXPLICAÇÃO**
O CPSC2018 é desbalanceado (classes como CVP e STE têm poucos exemplos). Comparações entre classes precisam considerar o tamanho de cada grupo, pois métricas calculadas em poucos ECGs são mais instáveis.

p. 15 §8.2 Implicações

*"For example, rare subgroups may be more diffidult to approximate, and will naturally have lower fidelity than others [52, 102]."*
Tradução: "Por exemplo, subgrupos raros podem ser mais difíceis de aproximar e terão naturalmente fidelidade menor que os demais [52, 102]."

**EXPLICAÇÃO**
Hipótese a verificar no TCC: classes raras no treino podem ter tanto F1 menor quanto explicações piores, e a raridade seria então uma causa comum, não uma relação direta entre desempenho e explicação.

## 5. Relação com o TCC

Este é o trabalho que dá o enquadramento mais claro para a comparação por classe feita no TCC: trocando "subgrupo protegido" por "classe de arritmia", a pergunta é a mesma (a qualidade da explicação é igual entre grupos?), e a recomendação é a mesma (analisar a qualidade por grupo, e não pela média). Três resultados interessam diretamente à comparação com o F1: as lacunas na explicação podem superar as lacunas de desempenho do modelo; o grupo com as piores explicações nem sempre é o minoritário; e a escolha da métrica interage com o desbalanceamento. As medidas de lacuna do artigo ($\Delta_L$, distância do pior grupo à média, e $\Delta_L^{group}$, diferença média entre pares) podem ser adaptadas como resumo descritivo das métricas por classe no TCC, sem recorrer a correlações com o F1.

As diferenças são de natureza: o artigo trata de explicações por modelos substitutos e de dados tabulares, com fidelidade medida contra as predições da caixa-preta; o TCC usa atribuições (GradientSHAP) e mede fidelidade por perturbação de regiões do ECG. Os grupos do artigo são atributos demográficos que não definem o rótulo; no TCC, os grupos são as próprias classes, de modo que a classe e a explicação estão entrelaçadas.

## 6. Como citar no TCC

- Balagopalan et al. (2022) mostraram que a qualidade das explicações pode diferir de forma significativa entre subgrupos e que a média global superestima essa qualidade para alguns deles; por isso, as métricas de explicação foram analisadas separadamente para cada classe de arritmia.