Fichamento: Dynamask, máscaras dinâmicas para séries temporais

CRABBÉ, J.; VAN DER SCHAAR, M. *Explaining Time Series Predictions with Dynamic Masks*. International Conference on Machine Learning (ICML), PMLR 139, 2021

Tema: método de saliência por perturbação para séries multivariadas e métricas de informação e entropia da máscara

Aluno: Arthur Santos de Oliveira (RA: 156297)

Atualizado em: 28/10/2026

Link: https://arxiv.org/abs/2106.05303

Leitura: íntegra do texto principal (arXiv v1, p. 1–9); dos apêndices, só a seção A.3 (máscara para outros métodos)

Repositório: https://github.com/Arthur-so/shap-ecg-arrhythmia

---

Como ler. `[p. N]` indica a página do PDF do arXiv (25 páginas, com apêndices). As citações estão no original em inglês, cada uma seguida de uma tradução livre e de uma explicação.

Resumo

- **Objetivo:** um método de saliência que dê a importância de cada atributo em cada instante de uma série multivariada, respeitando a dependência temporal, selecionando poucos pontos (parcimônia) e produzindo mapas fáceis de ler (legibilidade).
- **Método:** uma máscara $M \in [0,1]^{T \times d}$ é otimizada para que a entrada perturbada mantenha a predição; a perturbação é **dinâmica**, feita com valores vizinhos no tempo (borrão gaussiano temporal ou média móvel).
- **Métricas novas:** informação da máscara e entropia da máscara, que também podem ser calculadas para outros métodos depois de normalizar o mapa para $[0,1]$.
- **Avaliação:** regressor caixa-branca com atributos importantes conhecidos; classificador GRU em dados sintéticos de um modelo oculto de Markov (HMM); GRU de mortalidade no MIMIC-III, avaliado substituindo as observações mais importantes pela média temporal.
- **Conclusão:** o Dynamask supera os métodos comparados, entre eles o GradientSHAP, na maioria das métricas.

1. O que o trabalho faz

O artigo parte de dois problemas das séries temporais. O primeiro é o **contexto**: métodos agnósticos tratam cada instante como um atributo separado e esquecem a ordem temporal. O segundo é o **tamanho**: com T instantes e d atributos, o mapa tem $T \times d$ valores e fica difícil de ler. A resposta é uma máscara ajustada a cada exemplo. Onde $m_{t,i}$ é perto de 1, o valor original é mantido; onde é perto de 0, ele é trocado por uma versão borrada ou pela média da vizinhança temporal. A perda soma três termos: o erro entre a predição original e a perturbada, um termo de **área** que força a máscara a destacar uma fração a dos pontos e a ficar quase binária, e um termo opcional de **continuidade** no tempo [p. 5]. A **máscara extremal** é a de menor área a cujo erro fica abaixo de um limiar ε.

2. Como avalia as explicações

Há três experimentos, em ordem de dificuldade [p. 7–9]:

- **Caixa-branca** ($T = d = 50$, 10 repetições): a saída depende de poucos atributos ou de poucos instantes conhecidos. Métricas: área sob a curva de precisão (AUP) e de revocação (AUR) em relação aos pontos verdadeiramente importantes, informação $I_M(A) = -\sum_{(t,i)\in A} \ln(1 - m_{t,i})$ e entropia $S_M(A)$ na região importante A.
- **HMM** ($T = 200$, 3 atributos, 5 repetições): a classe depende de um atributo diferente conforme

o estado oculto; uma GRU é treinada e explicada.

- **MIMIC-III** (48 horas, 31 atributos, 3 repetições): sem verdade de referência, as observações mais importantes são trocadas pela média temporal do atributo no paciente, e mede-se a entropia cruzada entre as predições (CE, maior é melhor) e a acurácia em relação às predições originais (ACC, menor é melhor).

Para comparar com os outros métodos, os mapas deles são normalizados pelo mínimo e pelo máximo e tratados como máscaras (Apêndice A.3).

3. Resultados e conclusões

Recorte da Tabela 3 [p. 8], experimento HMM (média ± desvio arredondados; I dividido por 10^5 e S por 10^4):

Método	**AUP** ↑	**AUR** ↑	$I_M(A)$ ↑	$S_M(A)$ ↓
Dynamask	0,88	0,70	2,24	0,04
Integrated Gradients	0,56	0,78	0,05	1,39
GradientSHAP	0,49	0,62	0,33	1,73
FIT	0,44	0,60	0,47	1,57

O Integrated Gradients tem a maior AUR, mas marca 87 % dos pontos como importantes, contra 32 % do Dynamask, quando só um terço o é [p. 8]. No MIMIC-III, as observações escolhidas pelo Dynamask mudam mais a predição quando substituídas, mas a acurácia fica acima de 0,98 para todos os métodos, isto é, a substituição raramente inverte a predição [p. 9]. Enguehard (2023) relata problemas na implementação original do Dynamask que alteram parte desses números.

4. Citações comentadas

p. 2 §1 Introdução

"These methods are static as the time dependency, and hence the context, is forgotten when treating all the time steps as separate features."
Tradução: "Esses métodos são estáticos, pois a dependência temporal, e portanto o contexto, é esquecida quando todos os instantes são tratados como atributos separados."

EXPLICAÇÃO
A crítica atinge os métodos agnósticos aplicados ponto a ponto, como o SHAP. O GradientSHAP do TCC também atribui ponto a ponto; a agregação em trechos do batimento recupera parte do contexto na **leitura** do mapa, mas não muda o modo como o mapa é calculado.

p. 2 §1 Introdução

"By parsimony, we mean that a saliency method should not select more inputs than necessary to explain a given prediction. For instance, a method that identifies 90% of the inputs as salient is not making the interpretation task easier."
Tradução: "Por parcimônia, entendemos que um método de saliência não deve selecionar mais entradas do que o necessário para explicar uma predição. Por exemplo, um método que identifica 90 % das entradas como importantes não facilita a interpretação."

EXPLICAÇÃO
É a motivação das métricas de complexidade. No TCC, a entropia de Bhatt et al. (2020) por regiões indica cerca de 24 regiões efetivas em 36, um mapa pouco parcimonioso. A ressalva de Hicks et al. (2021), de que a rede também usa contexto fora da onda principal, impede ler isso automaticamente como defeito.

p. 6 §2.4 Entropia da máscara

"Clearly, it is desirable for our mask to provide explanations with low entropy. This stems from the fact that the entropy is maximized when mask coefficients $m_{t,i}$ are close to 0.5."
Tradução: "Claramente, é desejável que a máscara dê explicações com baixa entropia, porque a entropia é máxima quando os coeficientes $m_{t,i}$ estão perto de 0,5."

EXPLICAÇÃO
A entropia da máscara mede a **indecisão** de cada ponto (importante ou não), somada sobre os pontos. A entropia usada no TCC é outra: mede como a importância total se **distribui** entre as regiões. As duas olham a legibilidade, mas não são intercambiáveis.

p. 7 §3 Experimentos

"There are two big difficulties to keep in mind when evaluating the quality of a saliency method. The first one is that the true importance of features is usually unknown with real-world data. The second one is that the the [sic] performance of a saliency method in identifying relevant features depends on the black-box and its performances."
Tradução: "Há duas grandes dificuldades ao avaliar a qualidade de um método de saliência. A primeira é que a importância verdadeira dos atributos costuma ser desconhecida em dados reais. A segunda é que o desempenho de um método de saliência em identificar atributos relevantes depende do modelo caixa-preta e do desempenho dele."

EXPLICAÇÃO
A segunda dificuldade é a pergunta do TCC: se a qualidade da explicação depende do desempenho do modelo, ela pode variar entre classes com F1 diferentes. O artigo afirma a dependência, mas não a mede; o TCC a examina de forma descritiva, por classe.

p. 9 §4 Conclusão

"For future works, it would be interesting to design more sophisticated consistency tests for saliency methods in a dynamic setting, like the ones that exist in image classification (Adebayo et al., 2018)."
Tradução: "Em trabalhos futuros, seria interessante criar testes de consistência mais sofisticados para métodos de saliência em contexto dinâmico, como os que existem em classificação de imagens (Adebayo et al., 2018)."

EXPLICAÇÃO
Os autores apontam como lacuna os testes de randomização. O TCC preenche parte dela no ECG com o eMPRT (modelo com pesos sorteados) e o Random Logit (classe trocada), calibrados pelo piso do GradientSHAP.

5. Relação com o TCC

O Dynamask não é usado no TCC, mas o artigo contribui com conceitos: parcimônia e legibilidade como propriedades desejáveis (ligadas à métrica de complexidade), a escolha da substituição na avaliação por perturbação (aqui a média temporal do próprio exemplo) e a afirmação de que a qualidade da explicação depende do modelo. O GradientSHAP aparece entre os métodos comparados, com resultado fraco no HMM, mas o cenário (GRU, dados sintéticos, três atributos) é muito diferente de uma ResNet em ECG de 12 derivações, e a correção de implementação apontada por Enguehard (2023) recomenda cautela com os números.

6. Como citar no TCC

Sugestão
Crabbé e van der Schaar (2021) propuseram o Dynamask, que ajusta a cada série uma máscara de importância por atributo e instante usando perturbações feitas com valores vizinhos no tempo, e introduziram a entropia da máscara como medida de legibilidade; os autores observam que a capacidade de um método de saliência em identificar atributos relevantes depende do modelo explicado e do seu desempenho.