Fichamento: ROAR (Remove And Retrain)

HOOKER, S.; ERHAN, D.; KINDERMANS, P.-J.; KIM, B. *A Benchmark for Interpretability Methods in Deep Neural Networks.* NeurIPS, 2019

Tema: meta-avaliação de métodos de atribuição por remoção de características e retreino

Aluno: Arthur Santos de Oliveira (RA: 156297)

Atualizado em: 28/10/2026

Link: https://arxiv.org/abs/1806.10758

Leitura: íntegra (arXiv v3, 17 páginas, incluindo o material suplementar)

Repositório: https://github.com/Arthur-so/shap-ecg-arrhythmia

---

Como ler. `[p. N]` indica a página do PDF lido (arXiv v3, 17 páginas). As citações estão no original em inglês, cada uma seguida de uma tradução livre e de uma explicação.

Resumo

- **Objetivo:** medir empiricamente se os mapas de importância de características (*feature importance*) de redes profundas apontam de fato as entradas informativas.
- **Dados e modelo:** ImageNet, Food 101 e Birdsnap; ResNet-50 usada tanto para gerar os mapas quanto para o retreino.
- **Métodos de explicação:** gradiente (GRAD), Integrated Gradients (IG), Guided Backprop (GB) e os conjuntos SmoothGrad (SG), SmoothGrad-Squared (SG-SQ) e VarGrad (VAR) em torno de cada um; controles independentes do modelo: ordem aleatória e filtro de bordas de Sobel.
- **Avaliação:** ROAR, que remove a fração t dos pixels mais importantes (troca pela média do canal) em treino e teste, retreina o modelo do zero e mede a queda de acurácia; 5 retreinos por configuração.
- **Conclusão:** GRAD, IG e GB não superam a ordem aleatória; só SG-SQ e VarGrad a superam com folga.

1. O que o trabalho faz

O artigo propõe um *benchmark* para comparar métodos de atribuição sem verdade de referência. A ideia de partida é o teste de deleção clássico (Samek et al.): retirar as entradas que o mapa diz serem importantes e observar quanto o classificador piora. Os autores apontam o defeito desse teste: a imagem com pixels trocados por um valor constante sai da distribuição de treino (*distribution shift*, mudança de distribuição), e a queda de acurácia pode vir do artefato e não da retirada de informação. Por isso o ROAR retreina o modelo, a partir de pesos aleatórios, no conjunto já modificado, de modo que treino e teste tenham a mesma distribuição. Um experimento com dados artificiais (16 dimensões, 4 informativas, modelo de mínimos quadrados) mostra que, sem retreino, até a pior ordenação possível parece funcionar.

2. Como avalia as explicações

- **Perturbação:** os pixels do topo da ordenação são substituídos pela média de cada canal; frações $t \in \{0, 10, 30, 50, 70, 90\}\%$.
- **Escala:** 18 estimadores, 540 conjuntos de dados modificados (180 por conjunto original), 5 ResNet-50 treinadas de forma independente para cada um; acurácia de teste média dos 5 retreinos.
- **Controles:** a ordem aleatória e o filtro de Sobel não dependem do modelo e funcionam como **limite inferior**: um método que usa os pesos do modelo deveria superá-los.

- **Variante KAR** (*Keep And Retrain*, no suplemento): mantém os pixels mais importantes em vez de removê-los; discrimina pior os métodos.
- **Configuração dos métodos:** IG com imagem preta como referência e $k = 25$ passos; conjuntos (SG, SG-SQ, VAR) com 15 estimativas ruidosas.

3. Resultados e conclusões

Situação	Valor relatado
ResNet-50 no ImageNet sem modificação	76,68% de acurácia
90% das entradas trocadas ao acaso, com retreino	63,53% ± 0,13 (5 execuções)
90% trocadas ao acaso, sem retreino	0,5%
Diferença entre o melhor e o pior método-base em $t = 90\%$	Birdsnap 4,22%; Food 101 5,17%; ImageNet 3,62

GRAD, IG e GB ficam abaixo (ou no mesmo nível) da ordem aleatória e do filtro de Sobel em todos os conjuntos e frações. O SmoothGrad clássico não melhora e às vezes piora o método-base; SG-SQ e VarGrad superam com folga os controles. Elevar o mapa ao quadrado (usar só a magnitude) melhora um pouco todos os métodos, mas não explica o ganho dos conjuntos. A ordem dos melhores métodos muda com o conjunto de dados (no Birdsnap os conjuntos em torno de GB vão melhor; no ImageNet e no Food 101, em torno de GRAD). Limitação declarada: o modelo avaliado após o retreino não é o mesmo que gerou os mapas, e entradas redundantes podem adiar a queda de acurácia.

4. Citações

p. 1 §1 Introdução

"Without re-training,it is unclear whether the degradation in model performance comes from the distribution shift or because the features that were removed are truly informative [10, 12]."
Tradução: "Sem retreino, não fica claro se a queda de desempenho do modelo vem da mudança de distribuição ou de as características removidas serem de fato informativas [10, 12]."

EXPLICAÇÃO
É a crítica central às métricas de perturbação sem retreino, categoria em que estão a Faithfulness Correlation e a Faithfulness Estimate do TCC. No ECG, trocar uma região (por exemplo, o QRS de uma derivação) pela referência também produz um sinal que o modelo nunca viu; a queda do *logit* mistura informação retirada e artefato.

p. 2 §1 Introdução

"Given that these methods do not depend upon the model, the performance of these variants respresent a lower bound of accuracy that a interpretability method could be expected to achieve."
Tradução: "Como esses métodos não dependem do modelo, o desempenho dessas variantes representa um limite inferior de acurácia que se espera que um método de interpretabilidade atinja."

EXPLICAÇÃO
Controle independente do modelo como régua: um número de qualidade só tem sentido comparado a um nível de referência. O TCC segue a mesma lógica com o piso (distância entre dois mapas GradientSHAP do mesmo ECG com sementes diferentes) e com o modelo de pesos sorteados do eMPRT.

p. 9 §4.3.3 Conjuntos

"This suggests that while the VAR and SG-SQ consistently improve performance, the choice of the best underlying estimator may vary by task."
Tradução: "Isso sugere que, embora VAR e SG-SQ melhorem o desempenho de forma consistente, a escolha do melhor estimador de base pode variar conforme a tarefa."

EXPLICAÇÃO
A qualidade medida de um método não é uma propriedade fixa dele: depende dos dados. É um

argumento a favor de relatar as métricas separadas por classe no TCC, em vez de apenas uma média global.

p. 15 §6.4 Elevar ao quadrado

"The magnitude may be far more telling of feature importance than direction; a negative signal may be just as important as positive contributions towards a model's prediction."
TRADUÇÃO: "A magnitude pode ser muito mais reveladora da importância de uma característica do que a direção; um sinal negativo pode ser tão importante quanto contribuições positivas para a predição do modelo."

EXPLICAÇÃO
Apoia a decisão do TCC de calcular algumas medidas também sobre a magnitude (valor absoluto) dos mapas agregados por região, como nas distâncias "com sinal e só magnitude" do eMPRT.

5. Relação com o TCC

O ROAR mede a qualidade de um método pelo efeito sobre o desempenho de um modelo retreinado, e não pela comparação entre qualidade da explicação e desempenho do modelo original; também não separa os resultados por classe (relata a acurácia média de teste). Portanto, o artigo não responde à pergunta do TCC (se a qualidade da explicação acompanha o F1 por classe), mas oferece dois pontos de apoio. Primeiro, a exigência de comparar cada método a controles que não dependem do modelo, que no TCC corresponde ao piso e ao modelo aleatório: só a distância em relação a esses controles indica que a explicação carrega informação do modelo. Segundo, a observação de que a ordem dos métodos muda com o conjunto de dados, o que justifica olhar as métricas por classe.

O artigo também levanta a ressalva mais importante para as métricas de fidelidade do TCC: sem retreino, perturbar uma região cria sinais fora da distribuição. O retreino não é viável no TCC (seriam 36 regiões × frações × repetições de uma ResNet34-1D), o que deve ser declarado como limitação; a Faithfulness Correlation e a Faithfulness Estimate medem a resposta do modelo treinado ao sinal perturbado, não a informação contida na região.

6. Como citar no TCC

- Hooker et al. (2019) mostraram que, sem retreinar o modelo, não é possível separar a queda de desempenho causada pela retirada de informação daquela causada pela mudança de distribuição introduzida pela perturbação; as métricas de fidelidade usadas neste trabalho não retreinam o modelo e estão sujeitas a essa limitação.
- Seguindo a lógica de comparar cada método a controles independentes do modelo (Hooker et al., 2019), os valores das métricas foram interpretados em relação a um piso de variação do próprio GradientSHAP.