Fichamento: ExECG, framework de XAI para modelos de ECG

JANG, J.-H.; JO, Y.-Y. *ExECG: An Explainable AI Framework for ECG models.* arXiv:2605.19258, 2026

Tema: biblioteca em Python que padroniza a aplicação e a visualização de métodos de XAI em modelos de ECG

Aluno: Arthur Santos de Oliveira (RA: 156297)

Atualizado em: 28/10/2026

Link: https://arxiv.org/abs/2605.19258

Leitura: íntegra (arXiv v1, 13 páginas, incluindo o Apêndice A)

Repositório: https://github.com/Arthur-so/shap-ecg-arrhythmia

---

Como ler. `[p. N]` indica a página do PDF do arXiv (13 páginas). As citações estão no original em inglês, cada uma seguida de uma tradução livre e de uma explicação.

Resumo

- **Objetivo:** oferecer uma ferramenta aberta que padronize e torne reprodutível a aplicação de XAI a modelos de ECG, já que cada estudo monta o seu próprio fluxo.
- **Estrutura:** três etapas. *Wrapper* (entrada no formato (lote, derivações, amostras), saídas por tipo de tarefa e acesso a ativações e gradientes); *Explainer* (atribuição: saliency, SmoothGrad, Integrated Gradients, Grad-CAM, Grad-CAM++ e Guided Grad-CAM; contrafactuais por StyleGAN; conceitos por TCAV); *Visualizer* (mapas agregados em faixas de tempo e a grade clínica 4×3).
- **Casos de uso:** ResNet-1D para detectar fibrilação atrial (AF), com 12 derivações de 10 s a 250 Hz, treinada com PTB-XL e MIMIC-IV-ECG; no apêndice, regressão do potássio sérico.
- **Avaliação:** não há métrica quantitativa da qualidade das explicações; há demonstração em exemplos e comparação visual entre métodos.
- **Conclusão:** as três famílias de explicação dão visões complementares; os autores reconhecem que a avaliação se limita a um caso de uso.

1. O que o trabalho faz

É um artigo de ferramenta. Parte de quatro princípios: **padronização** (mesma interface para modelos com entradas e saídas diferentes), **reprodutibilidade** (controle de sementes, parâmetros e configurações), **integração** (vários métodos no mesmo fluxo) e **extensibilidade** (métodos novos acoplados com pouco esforço) [p. 3]. A família de **atribuição** dá um valor de importância a cada amostra do sinal; a de **contrafactuais** gera um ECG modificado que leva a saída para um valor-alvo; a de **conceitos** (TCAV) mede quanto um conceito clínico, como "fibrilação atrial", influencia uma camada da rede. A biblioteca traz um gerador StyleGAN de ECG e um conjunto de conceitos montado a partir do desafio PhysioNet/CinC 2021. Entre os métodos de atribuição listados não há nenhum da família SHAP [p. 4].

2. Como avalia as explicações

Não avalia quantitativamente. Para a AF, aplica os seis métodos de atribuição a um mesmo ECG e observa quais regiões cada um destaca; para o contrafactual, relata a mudança da probabilidade de AF; para o TCAV, verifica se o escore do conceito fica acima de 0,5 (nível do acaso) com intervalos de confiança de 95 % [p. 7–8]. Na visualização, a atribuição pode ser agregada em faixas de tempo (`bin_size=25` amostras, isto é, 0,1 s a 250 Hz) para reduzir o ruído [p. 6]. Não há referência de ruído, teste de randomização ou medida de fidelidade.

3. Resultados e conclusões

No caso da AF, Guided Grad-CAM, Grad-CAM, SmoothGrad e saliency destacam a região da onda P, enquanto Integrated Gradients e Grad-CAM++ destacam outras regiões [p. 7]. O contrafactual eleva a probabilidade de AF de 0,0005 para 0,7712, com atenuação da onda P e RR irregular, mas também com morfologia irregular que não é típica de AF [p. 7–8]. O conceito "fibrilação atrial" tem TCAV acima de 0,5 em todas as camadas. Duas inconsistências de leitura: o texto diz usar "one publicly available" base, mas cita duas [p. 1]; e, no apêndice, a predição do potássio vai "de 0,005 a 0,5395" no texto, mas de 0,33 a 0,60 na legenda da Figura 8 [p. 12–13].

4. Citações comentadas

p. 1 Resumo

"Although ECG XAI has been extensively investigated and steadily improved, practical pipelines and reporting conventions vary across studies, hindering reuse and reproducibility."
Tradução: "Embora a XAI para ECG tenha sido amplamente investigada e aprimorada, os fluxos práticos e as convenções de relato variam entre os estudos, o que dificulta o reaproveitamento e a reprodutibilidade."

EXPLICAÇÃO
É o diagnóstico que motiva o artigo e vale para a revisão do TCC: cada trabalho escolhe método, camada, referência e forma de exibir de um jeito, e os resultados ficam difíceis de comparar. O TCC registra essas escolhas (referência balanceada, número de sorteios, regiões) pelo mesmo motivo.

p. 3 §2.2 Princípios

"Reproducing explanation requires controlling random seeds, parameters, and execution configurations. To make this practical, ExECG systematically manages these factors so that explanations can be regenerated under identical conditions."
Tradução: "Reproduzir uma explicação exige controlar sementes aleatórias, parâmetros e configurações de execução. Para tornar isso prático, o ExECG gerencia esses fatores de forma sistemática, de modo que as explicações possam ser geradas de novo em condições idênticas."

EXPLICAÇÃO
Métodos com sorteio, como o GradientSHAP, mudam de uma execução para outra. O TCC fixa a semente de cada mapa e, além disso, **mede** essa variação: o piso é a distância entre dois mapas do mesmo ECG com sementes diferentes, e serve de régua para a sensibilidade, o Random Logit e o eMPRT.

p. 7 §4.1 Caso de atribuição

"Guided Grad-CAM, Grad-CAM, SmoothGrad, and the vanilla saliency map consistently highlight the same region of the ECG waveform. This region corresponds to the P-wave segment, which is often absent or markedly attenuated in AF (Hindricks et al., 2021). The agreement across explainers therefore suggests that the classifier relies on P-wave."
Tradução: "Guided Grad-CAM, Grad-CAM, SmoothGrad e o mapa de saliência simples destacam de forma consistente a mesma região do traçado. Essa região corresponde ao segmento da onda P, que costuma estar ausente ou muito atenuada na AF (Hindricks et al., 2021). A concordância entre os métodos sugere, portanto, que o classificador se apoia na onda P."

EXPLICAÇÃO
O argumento usa **concordância entre métodos** e **plausibilidade clínica** como evidência. Nenhuma das duas mede fidelidade: métodos aparentados (dois derivam do Grad-CAM, e o SmoothGrad é uma média de mapas de saliência) podem errar juntos. O TCC usa a mesma expectativa clínica (AF na região pré-QRS) só como leitura, e mede a fidelidade com perturbações.

p. 7 §5 Conclusão

"Finally, our current evaluation is limited to a single use case, and broader validation across tasks, datasets, and architectures remains future work."
TRADUÇÃO: "Por fim, nossa avaliação atual se limita a um único caso de uso, e uma validação mais ampla, com outras tarefas, bases e arquiteturas, fica para trabalhos futuros."

EXPLICAÇÃO
A limitação é declarada pelos autores. O artigo deve ser citado como ferramenta e como sinal de que a área busca padronização, e não como evidência sobre a qualidade de algum método em ECG.

5. Relação com o TCC

O ExECG converge com o TCC em dois pontos: a preocupação com reprodutibilidade (sementes e parâmetros fixados) e a agregação temporal da atribuição para torná-la legível. Diverge em três: (i) não inclui métodos SHAP, que são o objeto do TCC; (ii) agrega em faixas fixas de tempo, enquanto o TCC agrega em trechos fisiológicos do batimento (pré-QRS, QRS, ST-T) por derivação; (iii) não tem métricas de avaliação, que são o centro do TCC. A ferramenta mostra que, até 2026, o esforço de padronização em XAI para ECG se concentra em gerar e exibir explicações, e não em medi-las, o que reforça a contribuição do TCC.

6. Como citar no TCC

Sugestão
Jang e Jo (2026) propuseram o ExECG, uma biblioteca que padroniza a aplicação de métodos de atribuição, contrafactuais e de conceitos a modelos de ECG, com controle de sementes para reprodutibilidade; a demonstração, em um classificador de fibrilação atrial, compara os métodos de forma visual e não inclui métricas quantitativas de qualidade das explicações.