Fichamento: relação entre explicação e predição (visão causal)

KARIMI, A.-H.; MUANDET, K.; KORNBLITH, S.; SCHÖLKOPF, B.; KIM, B. *On the Relationship Between Explanation and Prediction: A Causal View.* International Conference on Machine Learning (ICML), PMLR 202, 2023

Tema: quanto a explicação reflete a predição, em função do desempenho do modelo

Aluno: Arthur Santos de Oliveira (RA: 156297)

Atualizado em: 28/10/2026

Link: https://arxiv.org/abs/2212.06925

Leitura: íntegra (arXiv v4, versão dos anais do ICML 2023, 23 páginas); figuras do Apêndice B lidas pelas legendas

Repositório: https://github.com/Arthur-so/shap-ecg-arrhythmia

---

Como ler. `[p. N]` indica a página do PDF lido (arXiv v4). As citações estão no original em inglês, cada uma seguida de uma tradução livre e de uma explicação.

Resumo

- **Objetivo:** quantificar a relação entre a explicação (E) e a predição (Y) de um modelo, e ver como ela muda com o desempenho do modelo.
- **Dados e modelos:** *model zoo* de Unterthiner et al. (2020): 30.000 CNNs de 3 camadas (4.970 parâmetros) por conjunto de dados (CIFAR10, SVHN, MNIST, Fashion-MNIST), treinadas com hiperparâmetros sorteados.
- **Métodos de explicação:** gradiente, SmoothGrad, Integrated Gradients e Grad-CAM; mais uma referência ideal, *Identity* ($E = Y$).
- **Avaliação:** efeito de tratamento (inferência causal) dos hiperparâmetros sobre Y e sobre E, comparado por correlação, em 8 faixas de acurácia; separação entre efeito direto e efeito mediado por Y.
- **Conclusão:** a relação entre E e Y está longe do ideal, e a distância ao ideal aumenta nos modelos de melhor desempenho.

1. O que o trabalho faz

O artigo trata hiperparâmetros (otimizador, inicialização, ativação, taxa de aprendizado, regularização ℓ_2, *dropout*, divisão dos dados) como **tratamentos**, no sentido da estrutura de resultados potenciais de Rubin: eles vêm antes do treino e determinam o modelo, a predição e a explicação. Se a explicação de fato explica a predição, a influência de um hiperparâmetro sobre E deveria passar por Y. Os autores medem o **efeito individual de tratamento** (ITE, *individual treatment effect*) de cada hiperparâmetro sobre Y e sobre E para uma mesma instância, usando uma distância em espaço de *kernel* (KTE, *kernelized treatment effect*, com *kernel* RBF), já que Y e E são vetores ou mapas. Para separar o efeito direto de H sobre E do efeito mediado por Y, permutam as predições ao acaso e recalculam as explicações.

2. Como avalia as explicações

- **Pré-processamento dos mapas:** corte acima do percentil 99, normalização para $[0, 1]$ e zeragem das atribuições negativas (para comparar todos os métodos nas mesmas condições).
- **Estratificação pelo desempenho:** os 30.000 modelos são divididos em 8 faixas de acurácia (percentis 0–20, 20–40, 40–60, 60–80, 80–90, 90–95, 95–99, 99–100), com grupos de controle dentro de cada faixa.

- **Comparação:** correlações de Pearson e de Spearman entre ITE_Y e ITE_E em cada faixa; a explicação *Identity* dá a correlação perfeita e serve de referência ideal.
- **Robustez da análise:** os autores verificam que o resultado não depende da escolha do *kernel* (linear, polinomial, RBF, cosseno).

3. Resultados e conclusões

A maioria dos tipos de hiperparâmetro influencia E e Y de forma parecida quando se olham todos os modelos juntos. Separando por faixa de acurácia, porém, ITE_Y e ITE_E não seguem o mesmo padrão. A correlação entre eles cresce nas faixas de maior acurácia para gradiente e Integrated Gradients, mas fica moderada em comparação com a referência ideal (as legendas do apêndice falam em valores absolutos de no máximo cerca de 0,5). A distância entre o caso ideal e os métodos **aumenta** nos modelos de melhor desempenho: neles, uma parte maior da explicação vem de algo que não é a predição. Para SmoothGrad e Grad-CAM, a influência dos hiperparâmetros sobre E vem sobretudo diretamente de H. Os autores limitam as conclusões ao domínio testado (arquitetura fixa, pequena) e advertem que a métrica proposta, sozinha, não basta para endossar um método.

4. Citações

p. 6 §3.2 Resultados

"How the relationship between E and Y changes as a function of the performance of the model is important for practitioners in deciding when E can or cannot be used."
Tradução: "Como a relação entre E e Y muda em função do desempenho do modelo é importante para que os profissionais decidam quando E pode ou não ser usada."

EXPLICAÇÃO
É a mesma pergunta do TCC em outra escala: o TCC pergunta se a qualidade da explicação acompanha o desempenho (F1) por classe de um modelo; o artigo pergunta o mesmo entre milhares de modelos com desempenhos diferentes.

p. 6 §3.2 Grupo de controle

"Therefore, we continue with within-accuracy-bucket control groups, and refrain from comparing absolute values of ITE (for Y or E) across buckets, but instead, look to relative ITE values of H on Y and E across buckets."
Tradução: "Por isso, seguimos com grupos de controle dentro de cada faixa de acurácia e evitamos comparar valores absolutos de ITE (para Y ou E) entre faixas; em vez disso, olhamos para os valores relativos de ITE de H sobre Y e E entre as faixas."

EXPLICAÇÃO
Cautela metodológica que o TCC também adota: os valores absolutos de uma métrica em grupos diferentes (classes, no TCC) dependem da referência de cada grupo, por isso a comparação se faz por posições relativas, e cada métrica é lida contra o seu piso.

p. 8 §4 Discussão e conclusões

"Our results suggest that the relationships between E and Y is far from ideal. In fact, the gap between 'ideal' case only increases in higher-performing models–models that are likely to be deployed."
Tradução: "Nossos resultados sugerem que a relação entre E e Y está longe do ideal. Na verdade, a distância ao caso 'ideal' só aumenta nos modelos de melhor desempenho, os que provavelmente serão colocados em uso."

EXPLICAÇÃO
Desmonta a expectativa ingênua de que "modelo melhor ⇒ explicação melhor". Para o TCC, significa que não há razão teórica para esperar que as classes de F1 mais alto tenham explicações mais fiéis; um resultado nesse sentido, ou no oposto, precisa ser lido como observação, não como confirmação de uma regra.

p. 13 Apêndice A.3

"We also recognize that relying solely on the suggested metric may lead to misleading results and should not be considered adequate for endorsing an explanation approach."
TRADUÇÃO: "Também reconhecemos que confiar apenas na métrica sugerida pode levar a resultados enganosos e não deve ser considerado suficiente para endossar um método de explicação."

EXPLICAÇÃO
A própria referência ideal (*Identity*) tem correlação perfeita e não explica nada. Reforça a escolha do TCC de usar várias métricas, cada uma para uma propriedade, em vez de um único índice.

5. Relação com o TCC

Entre os trabalhos desta seção, é o que trata mais diretamente da relação entre explicação e desempenho, e a sua conclusão serve de alerta: em modelos de melhor desempenho, as explicações por gradiente refletem a predição **menos** do que o ideal, e a distância cresce com a acurácia. Há diferenças de desenho importantes. O artigo varia o desempenho entre modelos (30.000 CNNs pequenas) e mede quanto a explicação acompanha mudanças da predição; o TCC tem um único modelo e varia o desempenho entre classes (9 valores de F1). Com tantos modelos, o artigo pode usar correlações; com nove classes, uma correlação entre métricas e F1 seria frágil, o que sustenta a opção do TCC por uma comparação descritiva, por ordens e posições. O cuidado dos autores em não comparar valores absolutos entre faixas, só relativos, é o mesmo que o TCC aplica ao comparar classes.

A ressalva para a discussão: o artigo não estuda SHAP (cita os valores de Shapley como extensão futura) e usa CNNs de imagem muito menores que a ResNet34-1D; as conclusões servem como indício, não como resultado transferível.

6. Como citar no TCC

- Karimi et al. (2023) mostraram, em 30.000 redes treinadas com hiperparâmetros diferentes, que a relação entre explicação e predição está longe do ideal e se afasta ainda mais dele nos modelos de maior acurácia; por isso, este trabalho não parte do pressuposto de que classes com F1 mais alto tenham explicações de melhor qualidade e compara as duas grandezas de forma descritiva.