Fichamento: o problema do desacordo entre explicações

KRISHNA, S.; HAN, T.; GU, A.; WU, S.; JABBARI, S.; LAKKARAJU, H. *The Disagreement Problem in Explainable Machine Learning: A Practitioner's Perspective.*
Transactions on Machine Learning Research (TMLR), 2024

Tema: desacordo entre métodos de explicação e como profissionais o resolvem

Aluno: Arthur Santos de Oliveira (RA: 156297)

Atualizado em: 28/10/2026

Link: https://arxiv.org/abs/2202.01602

Leitura: íntegra do texto principal e do Apêndice A (arXiv v6, pp. 1–20); Apêndices B–E (resultados adicionais e estudo com usuários) consultados de forma parcial

Repositório: https://github.com/Arthur-so/shap-ecg-arrhythmia

---

Como ler. `[p. N]` indica a página do PDF lido (arXiv v6, versão publicada na TMLR em 06/2024). As citações estão no original em inglês, cada uma seguida de uma tradução livre e de uma explicação.

Resumo

- **Objetivo:** definir e medir o *problema do desacordo*: explicações de métodos diferentes, para a mesma predição do mesmo modelo, que apontam coisas diferentes; e investigar como profissionais resolvem esse conflito.
- **Dados e modelos:** COMPAS e German Credit (tabulares; regressão logística, rede densa, floresta aleatória, *gradient boosting*), AG_News (texto; LSTM) e ImageNet (imagem; ResNet-18 pré-treinada).
- **Métodos de explicação:** LIME, KernelSHAP, gradiente, gradiente × entrada, Integrated Gradients e SmoothGrad.
- **Avaliação:** entrevistas com 25 cientistas de dados, seis métricas de concordância entre pares de explicações e um estudo *online* com outros 25 participantes.
- **Conclusão:** os métodos discordam com frequência, e os profissionais resolvem o conflito com heurísticas *ad hoc*.

1. O que o trabalho faz

O artigo não pergunta qual explicação é correta, mas quanto explicações diferentes concordam entre si. As entrevistas mostram que os profissionais consideram que há desacordo quando mudam as k características mais importantes (*top-k*), a ordem entre elas, o sinal da contribuição ou a ordem relativa de características de interesse, e não quando mudam os valores numéricos: 96% dos entrevistados disseram que os valores de métodos diferentes não são diretamente comparáveis. A partir disso, os autores formalizam seis métricas e as aplicam a quatro conjuntos de dados de três modalidades.

2. Como avalia as explicações

Não há medida de fidelidade ao modelo; o que se mede é a **concordância entre pares de métodos**, com valores entre 0 e 1 (quanto menor, maior o desacordo):

- **Feature agreement:** fração de características comuns aos dois conjuntos *top-k* (escolhidos pela magnitude da atribuição).
- **Rank agreement:** fração das comuns que também ocupam a mesma posição; **sign agreement**: que também têm o mesmo sinal; **signed rank agreement**: mesma posição e mesmo sinal.
- **Rank correlation** (correlação de Spearman) e **pairwise rank agreement** (fração de pares com a mesma ordem relativa), sobre um conjunto de características escolhido pelo usuário.

O desacordo é considerado não trivial quando menos de 75% das características concordam (métricas

abaixo de 0,75) ou quando a correlação de postos fica abaixo de 0,50. Em imagens, as seis métricas são calculadas entre LIME e KernelSHAP (superpixels); entre os métodos de gradiente, só a correlação de postos sobre todos os pixels.

3. Resultados e conclusões

Achado	Valor relatado
Entrevistados que usam vários métodos para a mesma predição	22 de 25 (88%)
Entrevistados que já encontraram desacordo	21 de 25 (84%)
Texto (AG_News, $k = 11$): rank e signed rank agreement	abaixo de 0,1 na maioria dos pares
ImageNet, LIME × KernelSHAP: correlação de postos	0,8977
ImageNet, Integrated Gradients × SmoothGrad (pixels)	0,001
Participantes do estudo *online* com heurística *ad hoc* ou sem saber resolver	86%

Outros padrões: a concordância cai à medida que k cresce; o desacordo é maior no German Credit (mais características) do que no COMPAS; é igual ou maior para a rede neural do que para a regressão logística, o que os autores leem como indício de que o desacordo cresce com a complexidade do modelo; e o grau de desacordo depende da métrica usada para medi-lo. Os autores declaram que estudaram a prevalência do desacordo, não suas causas.

4. Citações

p. 5 §3.1.2 Resultados das entrevistas

"24 out of 25 participants (96%) opine that feature importance values output by different explanation methods are not directly comparable."
Tradução: "24 de 25 participantes (96%) consideram que os valores de importância de características produzidos por métodos de explicação diferentes não são diretamente comparáveis."

EXPLICAÇÃO
O que importa é a ordem e o sinal, não a escala. O TCC usa um único método, mas a mesma cautela vale para comparar classes: as métricas são comparadas por ordens e posições, e não pelos valores brutos de uma classe contra os de outra.

p. 8 §4.3.1 Dados tabulares

"These trends suggest that disagreement among explanation methods may increase with model complexity."
Tradução: "Essas tendências sugerem que o desacordo entre métodos de explicação pode aumentar com a complexidade do modelo."

EXPLICAÇÃO
A ResNet34-1D do TCC está no extremo complexo da escala do artigo. É um motivo a mais para não aceitar um mapa GradientSHAP sem verificação e para medir a sua variabilidade (o piso entre sementes).

p. 11 §4.3.3 Imagens

"This suggests that disagreement could potentially vary significantly based on the granularity of image representation."
Tradução: "Isso sugere que o desacordo pode variar de forma significativa conforme a granularidade da representação da imagem."

EXPLICAÇÃO
Superpixels concordam (0,8977); pixels quase não concordam (0,001). Apoia a agregação do TCC em 36 regiões (derivação × segmento do batimento): em granularidade grossa, as comparações ficam mais estáveis e interpretáveis.

p. 15 §6 Discussão

"Finally, the extent of explanation disagreement would also depend on the specific metric being used to measure the disagreement."
TRADUÇÃO: "Por fim, o grau de desacordo entre explicações também depende da métrica específica usada para medi-lo."

EXPLICAÇÃO
A conclusão depende do instrumento. No TCC, cada propriedade (fidelidade, robustez, randomização, complexidade) é lida com a sua própria métrica e não se resume tudo em um único número.

5. Relação com o TCC

O artigo não compara a qualidade da explicação entre classes nem com o desempenho do modelo; mede concordância entre métodos. Mesmo assim, oferece três pontos para o TCC. Primeiro, a recomendação de comparar explicações por **ordem, sinal e conjunto de regiões mais importantes**, e não por valores, que reforça a decisão de fazer a comparação com o F1 por classe de forma descritiva (ordens e posições). Segundo, a constatação de que a concordância depende da granularidade, o que sustenta as 36 regiões. Terceiro, a observação de que modelos mais complexos geram mais desacordo, o que justifica medir a variabilidade do próprio GradientSHAP (piso entre sementes). As métricas *top-k* do artigo (*feature* e *sign agreement*) poderiam servir para comparar os mapas de duas sementes ou de duas classes, caso se queira uma leitura complementar à distância usada no piso.

A ressalva é que o TCC usa um só método de explicação; o desacordo entre métodos fica fora do escopo e deve ser citado como limitação (outro método poderia indicar outras regiões).

6. Como citar no TCC

- Krishna et al. (2024) mostraram que métodos de explicação populares discordam com frequência sobre as características mais importantes de uma mesma predição, e que o grau de desacordo depende da granularidade e da métrica usada; por isso, este trabalho restringe-se a um método e mede a variabilidade dele entre sementes.