Fichamento: SHAP, uma abordagem unificada

LUNDBERG, S. M.; LEE, S.-I. *A Unified Approach to Interpreting Model Predictions*. In: Advances in Neural Information Processing Systems 30 (NeurIPS), 2017

Tema: definição dos valores SHAP e das propriedades que fundamentam o GradientSHAP

Aluno: Arthur Santos de Oliveira (RA: 156297)

Atualizado em: 07/11/2026

Link: https://arxiv.org/abs/1705.07874

Leitura: íntegra da versão arXiv v2 (10 páginas); material suplementar não consultado

Repositório: https://github.com/Arthur-so/shap-ecg-arrhythmia

---

Como ler. `[p. N]` indica a página do PDF do arXiv. As citações estão no original em inglês, cada uma seguida de uma tradução livre e de uma explicação.

Resumo

- **Objetivo:** unificar métodos de explicação (LIME, DeepLIFT, LRP, valores de Shapley) numa única classe, a dos métodos aditivos de atribuição.
- **Ideia central:** uma explicação é um modelo linear simples $g(z') = \phi_0 + \sum_i \phi_i z'_i$; entre esses, só os valores de Shapley satisfazem ao mesmo tempo três propriedades desejáveis (exatidão local, ausência e consistência).
- **Contribuição prática:** os valores SHAP e aproximações eficientes (Kernel SHAP, Deep SHAP).
- **Para o TCC:** fundamenta a leitura do mapa como uma divisão, entre os pontos do ECG, da diferença entre a saída do modelo e a saída de referência.

1. O que o trabalho faz

Os autores mostram que vários métodos de explicação têm a mesma forma: atribuem a cada atributo um valor ϕ_i cuja soma, mais um termo constante ϕ_0, reproduz a saída do modelo [p. 2–3]. Provam que só uma escolha dos ϕ_i atende às três propriedades da seção 3 (Teorema 1), os valores de Shapley da teoria dos jogos cooperativos [p. 4], e chamam de valores SHAP os valores de Shapley de uma esperança condicional da função do modelo [p. 4–5]. O termo constante ϕ_0 é a saída esperada do modelo quando nenhum atributo é conhecido [p. 5].

O GradientSHAP usado no TCC (implementação do Captum) não é descrito neste artigo; ele vem da biblioteca SHAP dos mesmos autores, como aproximação dos valores SHAP por gradientes esperados. O artigo fundamenta a interpretação dos valores, e não o algoritmo específico.

2. Citações

`p. 4` Propriedade 1: exatidão local

"When approximating the original model f for a specific input x, local accuracy requires the explanation model to at least match the output of f for the simplified input x' (which corresponds to the original input x)."

TRADUÇÃO: "Ao aproximar o modelo original f num exemplo x, a exatidão local exige que o modelo de explicação ao menos reproduza a saída de f para a entrada simplificada x' (que corresponde à entrada original x)."

EXPLICAÇÃO

É a propriedade $f(x) = \phi_0 + \sum_i \phi_i$: a soma das atribuições explica a diferença entre a saída e o termo constante. No TCC, é o que justifica dizer que o mapa "distribui, entre os pontos, quanto o ECG se afasta das referências" e que somar o mapa numa região dá a contribuição daquela região.

p. 5 Figura 1: o valor de base

"[SHAP values] explain how to get from the base value $E[f(z)]$ that would be predicted if we did not know any features to the current output $f(x)$."
Tradução: "[Os valores SHAP] explicam como ir do valor de base $E[f(z)]$, que seria previsto se nenhum atributo fosse conhecido, até a saída atual $f(x)$."

EXPLICAÇÃO
No GradientSHAP, "não conhecer" um atributo é substituí-lo pelos valores das referências; o valor de base é, assim, a saída média para os 36 ECGs de referência. Por isso a escolha da referência muda o que o mapa explica (seção 1.3.3 do texto do TCC).

p. 4 Unicidade

"Under Properties 1-3, for a given simplified input mapping h_x, Theorem 1 shows that there is only one possible additive feature attribution method."
Tradução: "Com as propriedades 1 a 3, para um dado mapeamento de entradas simplificadas h_x, o Teorema 1 mostra que só existe um método aditivo de atribuição possível."

EXPLICAÇÃO
É o argumento teórico para preferir métodos da família SHAP. Na prática, o GradientSHAP é uma aproximação estocástica, e as propriedades valem só em média; daí a necessidade de medir o piso (seção 1.5 do texto do TCC).

3. Relação com o TCC

Dá a base conceitual do método de explicação (capítulo de Fundamentação) e a interpretação aditiva do mapa usada nas regiões e nas métricas de fidelidade, que comparam a soma das atribuições com a queda da saída. Não trata de séries temporais, de ECG nem de avaliação quantitativa das explicações.

4. Como citar no TCC

- "Pela propriedade de exatidão local dos valores SHAP (Lundberg e Lee, 2017), a soma das atribuições reproduz a diferença entre a saída do modelo e o valor de base, que no GradientSHAP é a saída média para as referências."