Fichamento: ROAR em EEG de reconhecimento de emoções

MAYOR-TORRES, J. M.; MEDINA-DEVILLIERS, S.; CLARKSON, T.; LERNER, M. D.; RICCARDI, G. *Evaluation of Interpretability for Deep Learning algorithms in EEG Emotion Recognition: A case study in Autism.* Artificial Intelligence in Medicine, v. 143, 102545, 2023 (texto lido: arXiv:2111.13208v6)

Tema: avaliação de mapas de relevância (SmoothGrad, LRP, PatternNet, PatternAttribution) por remoção e retreino (ROAR) em EEG, comparando grupos TD e TEA

Aluno: Arthur Santos de Oliveira (RA: 156297)

Atualizado em: 28/10/2026

Link: https://arxiv.org/abs/2111.13208v6

Leitura: íntegra da versão arXiv v6 (23/02/2023, 12 páginas); material suplementar (Figuras S.1–S.5, Tabela S.1) e versão de periódico não lidos

Repositório: https://github.com/Arthur-so/shap-ecg-arrhythmia

---

Como ler. `[p. N]` indica a página do PDF lido (arXiv v6); a versão publicada pode ter outra paginação e redação. As citações estão no original em inglês, cada uma seguida de uma tradução livre e de uma explicação.

Resumo

- **Objetivo:** verificar quais métodos de explicação são confiáveis para recuperar as características de EEG que uma CNN usa para decodificar emoções faciais vistas por adolescentes com desenvolvimento típico (TD) e com transtorno do espectro autista (TEA).
- **Dados e modelos:** 88 participantes (48 TD, 40 TEA), 48 ensaios cada; EEG de 30 canais $\times$ 752 instantes tratado como imagem; CNN de três blocos, treinada por participante com validação deixando um ensaio de fora.
- **Métodos de explicação:** SmoothGrad (referência), SmoothGrad ao quadrado, PatternNet, PatternAttribution e LRP (preset B), via iNNvestigate.
- **Avaliação:** ROAR (*RemOve And Retrain*): remover as características mais relevantes segundo o mapa médio do grupo, retreinar e medir a queda de acurácia, contra máscaras aleatórias e contra fatias de 47 instantes $\times$ 1 canal.
- **Conclusão principal:** os métodos recuperam trechos tardios (após 500 ms) como essenciais; LRP-B, PatternNet e PatternAttribution são os mais confiáveis ao remover mais de 50% das características, e mostram diferenças entre TD e TEA.

1. O que o trabalho faz

Os ensaios de EEG são pré-processados (remoção de artefatos, branqueamento ZCA) e empilhados como imagem canal $\times$ tempo [p. 2–3]. A CNN atinge acurácia média de 0,860 (TD) e 0,934 (TEA), acima do desempenho dos próprios participantes na tarefa (0,815 e 0,776) [p. 4]. Os mapas de relevância, normalizados em $[-1, 1]$, são tirados em cada iteração da validação cruzada e **promediados por grupo e por emoção**; as comparações estatísticas são feitas em cinco janelas de tempo (0–500, 250–750, ..., 1000–1500 ms) [p. 4, 6–7].

2. Como avalia as explicações

- **ROAR** [p. 6–7]: o mapa médio do grupo (média das quatro emoções) vira uma máscara binária para cada taxa de remoção r (0,1 a 0,9); a CNN é retreinada só com as características admitidas e mede-se a queda de acurácia.
- **Referências** [p. 7]: máscara aleatória uniforme com $r = 0{,}5$; fatias aleatórias de 47 instantes $\times$ 1 canal (cerca de 20 ms) e as mesmas fatias ordenadas pelo método ("fatias do método").

- **Estatística** [p. 7–9]: teste de Kolmogorov-Smirnov entre mapas, ANOVA de um fator com correção de Bonferroni-Holm entre grupos e entre valores de r.

A avaliação é feita sobre mapas médios de grupo, não sobre explicações individuais, e retreina o modelo, ao contrário das métricas por perturbação sem retreino.

3. Resultados e conclusões

SmoothGrad e SmoothGrad ao quadrado têm distribuições de relevância semelhantes em todas as janelas; PatternNet se assemelha ao LRP-B e ao PatternAttribution só nas janelas tardias [p. 7]. Entre TD e TEA, só o LRP-B mostra diferenças significativas nos mapas, sobretudo para raiva e medo [p. 7]. No ROAR, as diferenças em relação às referências aparecem em valores de r específicos e variam por método (por exemplo, SmoothGrad em $r = 0{,}7$ e 0,9; SmoothGrad ao quadrado e LRP-B em $r = 0{,}2$) [p. 8–9]. Na discussão, os autores recomendam começar pelo SmoothGrad ao quadrado, por ser o mais simples, mas na conclusão apontam LRP-B, PatternNet e PatternAttribution como os mais confiáveis quando se remove mais da metade das características [p. 9–10].

4. Citações

p. 2 §1 Introdução

"ROAR works by systematically removing features, indicated to be informative according to the XAI methods, one a time from the CNN and obtaining classifier accuracies without that features. If after their feature-removal the classifier cannot obtain a high categorization accuracy, then the feature identified by XAI methods is indeed informative, reliable and necessary for decoding."
Tradução: "O ROAR remove sistematicamente as características que os métodos de XAI indicam como informativas e obtém a acurácia do classificador sem elas. Se, após a remoção, o classificador não consegue alta acurácia, a característica identificada pelo método é de fato informativa, confiável e necessária para a decodificação."

EXPLICAÇÃO
O ROAR evita o problema da perturbação fora da distribuição ao retreinar o modelo, mas passa a avaliar o que é informativo **para a tarefa**, e não o que o modelo original usou. Por isso, e pelo custo de retreinar a ResNet34-1D várias vezes, o ROAR ficou fora das métricas do TCC.

p. 7 §2.8.1 Referências do ROAR

"As a gold-standard, we expect that the feature removal associated with the more reliable XAI saliency-maps reduces more accuracy than the random baselines. We also expect that the accuracy detriment will be more plausible for higher r values in comparison with lower r values, thus assuring that those removed features are truly relevant."
Tradução: "Como padrão-ouro, espera-se que a remoção guiada pelos mapas mais confiáveis reduza mais a acurácia do que as referências aleatórias. Espera-se também que a queda de acurácia seja mais plausível para valores maiores de r do que para valores menores, garantindo que as características removidas sejam de fato relevantes."

EXPLICAÇÃO
As referências do artigo incluem fatias contíguas no tempo dentro de um canal, o que respeita a estrutura do sinal, ideia próxima das regiões por derivação do TCC. A exigência de superar referências aleatórias é a mesma que o TCC aplica com o piso.

p. 9 §4 Discussão

"However, this effect is only observed when less than 50% of the relevant features are removed [...]. While the best performing method differs based on the exact setting, we recommend using the SmoothGrad-Squared approach, since it is the easiest to implement, before using more complicated methods."
Tradução: "Porém, esse efeito só é observado quando se remove menos de 50% das características relevantes [...]. Embora o melhor método mude conforme a configuração exata, recomendamos usar o SmoothGrad ao quadrado, por ser o mais fácil de implementar, antes de métodos mais complicados."

EXPLICAÇÃO

O trecho mostra que o "melhor método" depende da configuração da avaliação (aqui, da taxa de remoção), e a conclusão do artigo (p. 10) fala em remover **mais** de 50%, em tensão com este trecho. Para o TCC, é um exemplo de por que relatar os resultados por configuração e evitar uma ordenação única.

5. Relação com o TCC

O artigo é relevante sobretudo por comparar explicações entre **grupos** (TD e TEA) e relacioná-las ao desempenho (da CNN e humano), o que lembra a comparação por classe do TCC. Porém, a comparação é feita sobre mapas médios de grupo e por testes de hipótese, não sobre a qualidade das explicações por grupo, e não há relação entre qualidade da explicação e acurácia por grupo. Na avaliação, o ROAR mede a informatividade dos trechos para a tarefa, com retreino, enquanto o TCC mede fidelidade ao modelo treinado, sem retreino; o artigo também não usa SHAP. Como ressalva, os resultados do ROAR são fragmentados (significância em valores isolados de r) e a recomendação final muda entre discussão e conclusão, o que pede cautela ao citar o artigo como evidência a favor de um método.

6. Como citar no TCC

- "Em EEG, Mayor-Torres et al. (2023) avaliaram mapas de relevância por remoção e retreino (ROAR), comparando-os com máscaras aleatórias e com fatias contíguas de cada canal, e observaram que o método mais confiável muda conforme a fração de características removida."