Fichamento: bibliotecas de XAI para séries temporais

PETER, L.; GUMPFER, N.; FISCHER, J.; SEIFERT, C.; HANNIG, J. *Software Frameworks for Explainable AI in Time Series Classification: A Systematic Review.* Preprint arXiv:2608.21449v1, 2026

Tema: revisão sistemática das bibliotecas de explicação e de avaliação para classificação de séries temporais; reprodutibilidade entre implementações

Aluno: Arthur Santos de Oliveira (RA: 156297)

Atualizado em: 28/10/2026

Link: https://arxiv.org/abs/2608.21449

Leitura: íntegra (arXiv v1, 19/08/2026, 21 páginas com apêndice; tabelas do apêndice lidas só para localizar as métricas usadas no TCC)

Repositório: https://github.com/Arthur-so/shap-ecg-arrhythmia

---

Como ler. `[p. N]` indica a página do PDF lido (arXiv v1). As citações estão no original em inglês, cada uma seguida de uma tradução livre e de uma explicação.

Resumo

- **Objetivo:** mapear as bibliotecas (*frameworks*) de software que geram ou avaliam explicações para classificação de séries temporais e comparar métodos, métricas, usabilidade, bases de teste e reprodutibilidade.
- **Dados e modelos:** busca no GitHub (750 entradas, 6 bibliotecas incluídas: TSInterpret, tsCaptum, SIGN-XAI-2, Quantus, time_interpret e XTSC-Bench); dois experimentos ilustrativos: AudioMNIST (voz) e uma CNN treinada em ECG de 12 derivações do PTB-XL (BRD contra normal).
- **Métodos de explicação:** 51 métodos catalogados (16 por perturbação, 25 por gradiente, 4 contrafactuais, 6 outros); comparação de Integrated Gradients entre Captum e Zennit.
- **Avaliação:** não avalia métodos no sentido do TCC; cataloga 52 métricas e compara implementações da mesma explicação e da mesma métrica em bibliotecas diferentes.
- **Conclusão principal:** só 2 das 52 métricas foram feitas para séries temporais, nenhuma para o domínio da frequência, e o mesmo método (Integrated Gradients, com os mesmos parâmetros) dá explicações sistematicamente diferentes em bibliotecas diferentes.

1. O que o trabalho faz

É uma revisão sistemática centrada em software, e não em métodos. A busca foi feita no GitHub em 05/12/2025, com filtros de popularidade (pelo menos quatro estrelas e quatro *forks*) e critérios de inclusão (dizer que suporta séries temporais, ter ao menos dois métodos ou duas métricas, ser instalável em Python e ter documentação) [p. 4–5]. Para cada biblioteca, registram-se métodos, métricas, suporte a séries uni e multivariadas, ao domínio da frequência e a bases com verdade conhecida, além de notas de usabilidade [p. 5–6].

2. Como avalia as explicações

O artigo não propõe nem aplica métricas de qualidade de explicação. A parte empírica é um teste de reprodutibilidade [p. 10–11]: uma CNN treinada no PTB-XL (3 316 registros de 12 derivações, BRD e normais em igual número, acurácia de teste 96,98%) foi explicada com Integrated Gradients no TSInterpret (via Captum) e no SIGN-XAI-2 (via Zennit), com parâmetros idênticos (baseline zero, 50 passos). A concordância entre as duas versões foi medida, nas 443 amostras de teste, pela correlação de Spearman e pela sobreposição de Jaccard dos 5% mais relevantes. Cinco métodos foram comparados (Saliency, Occlusion, Feature Ablation, Deconvolution e Integrated Gradients); só uma métrica (ROC-AUC) existe em duas bibliotecas.

3. Resultados e conclusões

Achado	Valor
Bibliotecas com suporte a séries temporais	6 (contra 1 em 2022) [p. 11]
Métodos catalogados / feitos para séries temporais	51 / 16 [p. 7–8]
Métricas catalogadas / compatíveis / específicas de séries	52 / 44 / 2 (Mask Information e Mask Entropy) [p. 9]
Maior coleção de métricas	Quantus, 36 [p. 7]
IG Captum × Zennit no ECG (443 amostras)	Spearman médio −0,14 (mediana −0,17); 0 amostras com $\rho > 0{,}5$; Jaccard top-5% 0,26 [p. 10]
Demais métodos e a ROC-AUC	idênticos entre bibliotecas com parâmetros iguais [p. 11]

No ECG com BRD, só a versão baseada no Zennit destacou o padrão em "M" (rSR') em V1 [p. 10–11]. Na Tabela A.2, as métricas usadas no TCC (Faithfulness Correlation e Estimate, Max- e Avg-Sensitivity, Complexity, Consistency, Random Logit, eMPRT) aparecem como compatíveis com séries temporais, mas não específicas delas [p. 20–21].

4. Citações

p. 2 §1 Introdução

"In contrast, the electrocardiogram (ECG) is a multivariate time series for which meaningful and clinically interpretable patterns are well defined and visible in the time domain. Pathology-related patterns can be reliably interpreted by domain experts, particularly cardiologists, and often arise from complex cross-channel dependencies, reflecting spatial and temporal interactions of cardiac activity."
Tradução: "Em contraste, o eletrocardiograma (ECG) é uma série temporal multivariada em que padrões significativos e clinicamente interpretáveis são bem definidos e visíveis no domínio do tempo. Os padrões ligados a doenças podem ser interpretados com segurança por especialistas, em especial cardiologistas, e muitas vezes surgem de dependências complexas entre canais, que refletem interações espaciais e temporais da atividade cardíaca."

EXPLICAÇÃO
Justifica explicar o ECG no domínio do tempo e organizar as regiões do TCC por derivação e por trecho do batimento (onda P, QRS, ST-T), que são as unidades em que o cardiologista lê o exame.

p. 10–11 §3.5 Reprodutibilidade

"To verify the results, we analyzed the whole test set of 443 instances: Captum- and Zennit-based IG yielded a mean Spearman rank correlation of −0.14 *(median* −0.17*, std* 0.11*; 0 of 443 instances had* $\rho > 0.5$*) and a top-5% Jaccard overlap of* 0.26 *(*±0.09*). These results confirm that the divergence in Fig. 5 reflects systematic disagreement rather than an instance-specific or thresholding artifact."*
Tradução: "Para verificar os resultados, analisamos todo o conjunto de teste de 443 instâncias: o IG baseado em Captum e em Zennit teve correlação de postos de Spearman média de −0,14 (mediana −0,17, desvio 0,11; nenhuma das 443 instâncias com $\rho > 0{,}5$) e sobreposição de Jaccard dos 5% mais relevantes de 0,26 (±0,09). Isso confirma que a divergência da Fig. 5 reflete discordância sistemática, e não um artefato de uma instância ou do limiar."

EXPLICAÇÃO
O mesmo método, com os mesmos parâmetros, no mesmo modelo de ECG, deu mapas praticamente sem relação entre si conforme a biblioteca. Para o TCC, isso exige registrar a implementação exata do GradientSHAP (biblioteca, versão, número de amostras, referência) e ler as métricas como propriedades daquela implementação.

p. 12 §4 Desafios em aberto

"An assumption that some metrics make is the independence of feature relevance, which is violated by temporal and cross-channel dependencies in time series. Only two of the 52 analyzed metrics were developed specifically for time series […]."

Tradução: “Uma suposição de algumas métricas é a independência da relevância dos atributos, violada pelas dependências temporais e entre canais das séries temporais. Só duas das 52 métricas analisadas foram desenvolvidas especificamente para séries temporais [...].”

EXPLICAÇÃO

Apoia a decisão do TCC de não usar as métricas do Quantus ponto a ponto e de reimplementá-las por regiões do batimento, que agrupam pontos correlacionados no tempo; as dependências entre derivações continuam sem tratamento, o que deve aparecer como limitação.

5. Relação com o TCC

O artigo não avalia explicações; serve para situar o TCC no estado das ferramentas. Ele confirma que as métricas usadas no TCC existem no Quantus apenas como métricas genéricas, “compatíveis” com séries temporais, o que justifica as versões próprias por regiões. O experimento de reprodutibilidade, feito justamente em ECG de 12 derivações com BRD, mostra que diferenças de implementação podem dominar o mapa; no TCC, a medida análoga é o piso (dois mapas do mesmo ECG com sementes diferentes), que quantifica a variação interna do GradientSHAP, mas não a variação entre bibliotecas. Diferenças: o artigo usa Integrated Gradients, não GradientSHAP, e não relaciona explicações com desempenho por classe.

6. Como citar no TCC

- “Peter et al. (2026) observam que, das 52 métricas de avaliação disponíveis em bibliotecas de XAI para séries temporais, só duas foram desenvolvidas para esse tipo de dado, e que o Integrated Gradients, com os mesmos parâmetros, produziu explicações sistematicamente discordantes em duas bibliotecas num modelo de ECG de 12 derivações.”