Fichamento: avaliação rigorosa de XAI em séries temporais

SCHLEGEL, U.; ARNOUT, H.; EL-ASSADY, M.; OELKE, D.; KEIM, D. A. *Towards a Rigorous Evaluation of XAI Methods on Time Series.* IEEE/CVF International Conference on Computer Vision Workshops (ICCVW), 2019

Tema: avaliação de atribuições em séries temporais por perturbação, com referência aleatória e testes sequenciais

Aluno: Arthur Santos de Oliveira (RA: 156297)

Atualizado em: 28/10/2026

Link: https://arxiv.org/abs/1909.07082

Leitura: íntegra (arXiv v2, 5 páginas)

Repositório: https://github.com/Arthur-so/shap-ecg-arrhythmia

---

Como ler. `[p. N]` indica a página do PDF do arXiv (5 páginas). As citações estão no original em inglês, cada uma seguida de uma tradução livre e de uma explicação.

Resumo

- **Objetivo:** propor uma metodologia para avaliar automaticamente atribuições em séries temporais, levando em conta a dimensão temporal.
- **Dados e modelos:** nove bases do arquivo UCR e o MIT-BIH Arrhythmia, todas univariadas; uma CNN simples, uma RNN (LSTM de 100 unidades) e, quando disponível, o modelo do artigo da base (arquiteturas do tipo ResNet), treinados por 50 épocas.
- **Métodos de explicação:** Saliency, LRP, DeepLIFT, LIME e SHAP, além de uma relevância aleatória como referência.
- **Avaliação:** os pontos com relevância acima de um limiar (por exemplo, o percentil 90) são perturbados (zero ou inverso), e a queda da acurácia é comparada com a de uma perturbação de pontos sorteados; dois testes novos alteram subsequências (inversão da ordem e troca pela média).
- **Conclusão:** SHAP foi robusto em todos os modelos; DeepLIFT, LRP e Saliency funcionaram melhor em arquiteturas específicas; LIME foi o pior.

1. O que o trabalho faz

É um artigo curto de oficina (*workshop*) e um dos primeiros a testar métodos de XAI vindos de imagens e textos em séries temporais. Cada ponto no tempo é tratado como um atributo, e o método devolve um vetor de relevância $r = (r_0, \ldots, r_m)$, um valor por ponto. O artigo argumenta que mapas de calor sobre séries longas são difíceis de interpretar, até para especialistas, e por isso propõe uma verificação **automática** [p. 2].

2. Como avalia as explicações

A ideia é a da **análise de perturbação**: se os pontos mais relevantes forem alterados, a acurácia de um bom modelo deve cair muito. Os detalhes:

- **Seleção:** pontos com r_i acima de um limiar e, por exemplo o percentil 90 de r; a fração alterada é pequena.
- **Perturbação pontual:** o ponto vira zero ou o seu inverso ($\max t - t_i$).
- **Verificação:** repete-se o processo com uma relevância **aleatória**, alterando o mesmo número de pontos.

- **Testes sequenciais:** a partir de cada ponto relevante, uma subsequência de comprimento n_s é invertida (*Swap Time Points*) ou trocada pela sua média (*Mean Time Points*), para testar se o modelo usa tendências e formas, e não só valores isolados.
- **Critério:** $qm(t) \geq qm(t_r) > qm(t_c)$, em que qm é a acurácia, t a série original, t_r a série com pontos aleatórios alterados e t_c a série com pontos relevantes alterados.

O artigo não informa o valor de n_s nem testa outros limiares, e os resultados são médias sobre as dez bases.

3. Resultados e conclusões

Tabela 1 [p. 4], modelos do artigo da base (ResNet). Os valores são a variação média da acurácia, normalizada pela acurácia original; maior significa queda maior:

Método	Zero	Inverso	Swap	Média
Saliency	0,06	0,08	0,07	0,07
LRP	0,29	0,29	0,29	0,34
DeepLIFT	0,29	0,30	0,29	0,35
LIME	0,02	0,06	0,04	0,02
SHAP	0,29	0,40	0,31	0,38
Aleatório	0,13	0,21	0,07	0,04

Na ResNet, SHAP, LRP e DeepLIFT superam a referência aleatória em todas as perturbações; o LIME fica abaixo dela em todas, e o Saliency fica abaixo nas perturbações pontuais (zero e inverso). Na CNN simples, porém, a perturbação aleatória por inversão já derruba a acurácia quase tanto quanto os melhores métodos (0,45, contra 0,46 do SHAP), e na RNN o DeepLIFT tem 0,00 em todas as colunas. Os autores leem isso como dependência da arquitetura e pedem métodos de XAI mais adequados a séries temporais [p. 4].

4. Citações comentadas

p. 2 §3 Avaliação

"However, because, e.g., a zero could be an indicator for an anomaly in a time series task, the methodology of evaluation of XAI methods for time series needs specialized heuristics."
Tradução: "No entanto, como, por exemplo, um zero pode indicar uma anomalia numa tarefa de séries temporais, a metodologia de avaliação de métodos de XAI para séries temporais precisa de heurísticas especializadas."

EXPLICAÇÃO
É o problema da **referência de perturbação**: em imagens, zerar um pixel é "apagar"; numa série temporal, o zero pode ser um valor com significado. No ECG, 0 mV é a linha isoelétrica, e zerar um QRS cria um sinal plausível de outra coisa. Toda métrica de fidelidade do TCC depende dessa escolha.

p. 2-3 §3.1 Perturbação

"To verify the assumption, a random relevance $r_r = (r_0, r_1, r_2, \ldots, r_m)$ is used for the same procedure. The number of changed time points, amount of r_i larger than the threshold e, is the same as in the case before to set the same prerequisites for the classifier."
Tradução: "Para verificar a hipótese, uma relevância aleatória r_r é usada no mesmo procedimento. O número de pontos alterados, isto é, a quantidade de r_i acima do limiar e, é o mesmo do caso anterior, para dar ao classificador as mesmas condições."

EXPLICAÇÃO
Uma queda de acurácia só diz algo quando comparada com a queda produzida por uma escolha **sem informação**. A tabela mostra por quê: na CNN simples, alterar pontos sorteados já derruba a acurácia. O TCC segue a mesma lógica de sempre ter uma referência: o piso do GradientSHAP e o modelo com pesos sorteados no eMPRT.

p. 3 §3.3 Metodologia

"If the XAI method produces correct explanations, the assumptions $qm(t) \geq qm(t_{cr}) > qm(t_c)$ *with qm as the quality measure, t the original time series,* t_{cr} *the random changed, and* t_c *the relevant changed time series, holds."*
Tradução: "Se o método de XAI produz explicações corretas, vale a desigualdade $qm(t) \geq qm(t_{cr}) > qm(t_c)$, em que qm é a medida de qualidade, t a série original, t_{cr} a série com alteração aleatória e t_c a série com alteração nos pontos relevantes."

EXPLICAÇÃO
O critério é por conjunto de dados (acurácia), e não por explicação. Diz se um método, em média, aponta pontos que importam, mas não dá um valor por ECG nem por classe. As métricas do TCC (Faithfulness Correlation e Estimate) dão um valor por mapa, o que permite resumir por classe e comparar descritivamente com o F1.

p. 4 §5 Conclusão

"In our experiment, we find that SHAP works robust for all models, but others like DeepLIFT, LRP, and Saliency Maps work better for specific architectures."
Tradução: "Em nosso experimento, verificamos que o SHAP funciona de forma robusta em todos os modelos, enquanto outros, como DeepLIFT, LRP e mapas de saliência, funcionam melhor em arquiteturas específicas."

EXPLICAÇÃO
É um dos apoios empíricos mais citados para usar SHAP em séries temporais. Deve ser lido com as ressalvas do próprio artigo: resultados preliminares, séries univariadas, um limiar único e médias sobre dez bases, sem resultado separado para o MIT-BIH. O artigo também não diz qual variante de SHAP foi usada.

5. Relação com o TCC

O artigo fundamenta a avaliação por perturbação em séries temporais e dois cuidados que o TCC adota: comparar sempre com uma referência sem informação e escolher com cuidado o valor de substituição. As diferenças são grandes: o artigo trabalha com séries univariadas, perturba pontos isolados ou janelas de tamanho fixo e mede a acurácia do conjunto; o TCC trabalha com 12 derivações, perturba regiões fisiológicas do batimento e mede a fidelidade de cada mapa. O resultado favorável ao SHAP apoia a escolha do GradientSHAP só de forma indireta, porque o modelo, os dados e a variante de SHAP são outros.

6. Como citar no TCC

Sugestão
Schlegel et al. (2019) avaliaram atribuições em séries temporais alterando os pontos mais relevantes e comparando a queda da acurácia com a de pontos sorteados, e propuseram testes que alteram subsequências inteiras; nos experimentos preliminares, com séries univariadas, o SHAP foi o método mais estável entre as arquiteturas testadas.