Fichamento: InterpretTime revisado e acionabilidade

SERRAMAZZA, D. I.; LE NGUYEN, T.; IFRIM, G. *Improving the Evaluation and Actionability of Explanation Methods for Multivariate Time Series Classification.* arXiv:2406.12507v2, 2024

Tema: avaliação por perturbação (InterpretTime) com várias máscaras e agrupamento em trechos; seleção de canais guiada pela explicação

Aluno: Arthur Santos de Oliveira (RA: 156297)

Atualizado em: 28/10/2026

Link: https://arxiv.org/abs/2406.12507

Leitura: íntegra (arXiv v2, 12/08/2024, 25 páginas com apêndice)

Repositório: https://github.com/Arthur-so/shap-ecg-arrhythmia

---

Como ler. `[p. N]` indica a página do PDF lido (arXiv v2). As citações estão no original em inglês, cada uma seguida de uma tradução livre e de uma explicação.

Resumo

- **Objetivo:** examinar o InterpretTime (Turbé et al., 2023), método de avaliação de atribuições em séries multivariadas, apontar suas fraquezas e propor melhorias; mostrar um uso prático das explicações (seleção de canais).
- **Dados e modelos:** base sintética do InterpretTime (8 canais, 500 instantes), CMJ (3 canais), Military Press (8 ou 50 canais) e uma base de ECG de 12 derivações para BRD (comprimento 450); classificadores ResNet, dResNet, MiniRocket e ConvTran.
- **Métodos de explicação:** SHAP (amostragem de Shapley), KernelSHAP, Feature Ablation, Feature Permutation, Integrated Gradients, DeepLift, DeepLiftSHAP, GradientSHAP, Saliency (Captum) e dCAM; mapa aleatório como referência.
- **Avaliação:** métrica $AUC\tilde{S}_{top}$ do InterpretTime (queda da saída ao substituir os pontos mais importantes), calculada com seis máscaras em vez de só $N(0,1)$, descartando as máscaras que não superam o aleatório em 15%; agrupamento de pontos consecutivos por canal (5 a 20 trechos); verdade conhecida (AP, ROC) na base sintética.
- **Conclusão principal:** a máscara escolhida pode mudar o vencedor; agrupar em trechos melhora as métricas e reduz o tempo; métodos por perturbação (SHAP, Feature Ablation) superam os de gradiente, e o GradientSHAP fica entre os piores na base sintética.

1. O que o trabalho faz

O InterpretTime avalia uma atribuição substituindo, por valores de $N(0,1)$, a fração k dos pontos de maior atribuição e medindo a variação relativa da saída do modelo; supõe treino com ruído gaussiano, uma única máscara e só atribuições positivas [p. 7]. Sem esse treino aumentado, os autores não reproduzem os resultados originais: a ordenação fica "plana", perto do aleatório, porque os modelos passam a prever a mesma classe para toda série corrompida [p. 11–12, 23]. Propõem então (i) várias máscaras: zeros, média e gaussiana locais (por instante e canal) e globais, além de $N(0,1)$; (ii) o agrupamento (*chunking*) de pontos consecutivos de cada canal em trechos, cada um com um único valor de atribuição [p. 8–9]. Por fim, usam a média da atribuição por canal para selecionar canais [p. 9–10].

2. Como avalia as explicações

- **Normalização**: mapas reescalados para $[0,1]$ [p. 6]; na comparação com a verdade, só os valores positivos ($\max(0,W)$), como no InterpretTime [p. 9].
- **Máscaras**: só entram na média as máscaras em que a $AUC\tilde{S}_{top}$ do método supera a do mapa aleatório em pelo menos 15% (limiar empírico) [p. 9].

- **Granularidade**: ponto a ponto ou em 5, 10, 15 e 20 trechos iguais por canal, com média dos quatro; agrupar todos os canais juntos deu resultados ruins [p. 8].
- **Repetições**: cada classificador foi treinado 5 vezes e usado o mais preciso [p. 10].

3. Resultados e conclusões

Na base sintética, as métricas contra a verdade são baixas para todos; o GradientSHAP é o penúltimo nos dois modelos em que foi testado (AP 0,10 no ConvTran e 0,074 no ResNet; aleatório 0,052) [p. 11]. Com trechos, AP e ROC sobem e o tempo cai; o SHAP é o que mais ganha [p. 12–13]. No Military Press com ConvTran, três máscaras dão três vencedores diferentes [p. 14–15, 21]. Na base de ECG (Tabela 9, p. 20), ponto a ponto:

Modelo	SHAP	Int. Gradients	GradientSHAP	F. Ablation	Aleatório
ConvTran	0,472	0,566	0,519	0,436	0,077
ResNet	0,482	0,416	0,306	0,356	0,173

Os autores, porém, consideram essa base fácil demais para comparar métodos, porque um classificador tabular chega perto dos melhores (0,949 contra 0,967 do ConvTran) [p. 10, 13]. Na seleção de canais do Military Press, 8 canais escolhidos pelo SHAP e pelo Feature Ablation dão acurácia comparável à da escolha do especialista e, em geral, maior que a dos 50 canais [p. 15].

4. Citações

p. 9 §4.3 Melhorando o InterpretTime

"We then discard the masks where $AUC\tilde{S}_{top}$ of that attribution method is not greater than the $AUC\tilde{S}_{top}$ of the random attribution by at least 15% (we empirically found this threshold to separate between meaningless and meaningful)."
Tradução: "Descartamos então as máscaras em que a $AUC\tilde{S}_{top}$ do método de atribuição não supera em pelo menos 15% a do mapa aleatório (verificamos empiricamente que esse limiar separa o que não tem significado do que tem)."

EXPLICAÇÃO
A ideia é só confiar numa perturbação quando ela distingue uma explicação real de uma aleatória. O TCC usa o mesmo princípio com outra referência: as distâncias (sensibilidade, Random Logit, eMPRT) são lidas contra o piso do GradientSHAP, e não em valor absoluto.

p. 11 §5.1 Validação do InterpretTime

"Different from the original work, we also found that SHAP has some of the poorest metrics using ConvTran, moreover GradientShap which is a competitive method in the original work, in our study is the second to last in both tested cases."
Tradução: "Diferentemente do trabalho original, também observamos que o SHAP tem algumas das piores métricas com o ConvTran; além disso, o GradientShap, competitivo no trabalho original, foi o penúltimo nos dois casos testados."

EXPLICAÇÃO
O desempenho do GradientSHAP muda de um estudo para outro conforme o treino do modelo e a base. Para o TCC, é mais um motivo para não tomar a qualidade do método como dada e medi-la no próprio modelo.

p. 15 §5.3 Dados reais

"This suggests again that the distribution used to perturb time-series can have a huge impact on results and our strategy of averaging up to 6 different masks, unlike using only $N(0,1)$, can mitigate this problem."
Tradução: "Isso sugere novamente que a distribuição usada para perturbar as séries pode ter enorme impacto nos resultados, e que a estratégia de fazer a média de até 6 máscaras, em vez de usar só $N(0,1)$, pode mitigar o problema."

EXPLICAÇÃO
É a mesma conclusão do AMEE, agora no caso multivariado. Na Faithfulness Correlation e na Faithfulness Estimate do TCC, o valor de substituição das regiões é uma escolha que afeta o resultado e deve ser declarada; o artigo sugere checar mais de uma.

p. 16 §6 Conclusão

"We also improved the AUC scores of attribution methods, while reducing running time, by using chunking, i.e., grouping consecutive features in each channel. This is possible only for perturbation-based models as they can mask features together."
TRADUÇÃO: "Também melhoramos os escores AUC dos métodos de atribuição, reduzindo o tempo de execução, com o agrupamento em trechos, isto é, juntando atributos consecutivos em cada canal. Isso só é possível para os métodos por perturbação, que podem mascarar atributos em conjunto."

EXPLICAÇÃO
No artigo, o trecho é a unidade do próprio cálculo da atribuição. No TCC, o GradientSHAP é calculado ponto a ponto e só depois somado nas 36 regiões; as métricas, porém, perturbam regiões inteiras. O artigo apoia a granularidade por trechos dentro de cada canal (e não juntando canais), que é a forma das regiões do TCC.

5. Relação com o TCC

É o trabalho mais próximo do desenho de avaliação do TCC entre os de séries multivariadas: perturba regiões dentro de cada canal, compara com uma explicação aleatória e mostra que a máscara muda a ordenação. Inclui uma base de ECG de 12 derivações para BRD, mas com comprimento 450, tarefa binária e acurácia alta até para um classificador tabular, o que os próprios autores consideram fácil demais. O resultado ruim do GradientSHAP na base sintética e intermediário no ECG não contradiz o uso do método no TCC, mas obriga a justificá-lo (custo, compatibilidade com o modelo) e a mostrar que, no CPSC2018, os mapas superam as referências, como fazem o Random Logit e as distâncias do eMPRT. Duas diferenças: o artigo ordena **métodos**, o TCC compara **classes** com um método só; e o artigo agrupa trechos de tamanho igual, o TCC usa trechos fisiológicos (pré-QRS, QRS, ST-T).

6. Como citar no TCC

- "Serramazza, Le Nguyen e Ifrim (2024) mostram que, em séries temporais multivariadas, a distribuição usada para mascarar os pontos pode mudar o método vencedor e que agrupar pontos consecutivos de cada canal em trechos melhora a avaliação e reduz o custo."