Fichamento: XAI para auditoria de modelos de ECG

WAGNER, P.; MEHARI, T.; HAVERKAMP, W.; STRODTHOFF, N. *Explaining deep learning for ECG analysis: Building blocks for auditing and knowledge discovery.* Computers in Biology and Medicine, v. 176, 108525, 2024 (arXiv:2305.17043v2)

Tema: testes de sanidade por regressão de amplitudes, atribuições agregadas por batimento e segmento ("glocal"), TCAV e descoberta de subgrupos

Aluno: Arthur Santos de Oliveira (RA: 156297)

Atualizado em: 28/10/2026

Link: https://doi.org/10.1016/j.compbiomed.2024.108525 (https://arxiv.org/abs/2305.17043)

Leitura: íntegra do texto principal (arXiv v2, 25 páginas); apêndices (segmentação, TCAV técnico, figuras suplementares) apenas percorridos

Repositório: https://github.com/Arthur-so/shap-ecg-arrhythmia

---

Como ler. `[p. N]` indica a página do PDF lido (arXiv v2, 25 páginas, incluindo apêndices). As citações estão no original em inglês, cada uma seguida de uma tradução livre e de uma explicação.

Resumo

- **Objetivo:** propor "blocos" de XAI para auditar modelos de ECG antes do uso clínico e para descobrir conhecimento, indo além de exemplos escolhidos a dedo.
- **Dados e modelos:** PTB-XL (23 rótulos subdiagnósticos; 100 Hz; janelas de 2,5 s; multirrótulo com sigmoide e entropia cruzada binária); LeNet rasa e xresnet1d50.
- **Métodos de explicação:** Grad-CAM, *saliency* (norma do gradiente), Integrated Gradients (IG) e LRP; depois, só *saliency*; TCAV (vetores de ativação de conceitos) na análise global.
- **Avaliação:** teste de sanidade com modelos de regressão das amplitudes de P, R e T em cada derivação: mede-se a especificidade espacial (fração da atribuição na derivação-alvo) e temporal (perfil médio sobre os batimentos).
- **Conclusão:** só a *saliency* passa; Grad-CAM, IG e LRP concentram relevância no QRS mesmo quando a tarefa é a onda P ou T. Mapas agregados por segmento concordam com critérios clínicos (LVH, BRE completo, infarto).

1. O que o trabalho faz

O artigo tem quatro partes. (1) **Testes de sanidade**: treinam-se modelos que regridem, a partir do ECG, a amplitude da onda P, do pico R ou da onda T em cada derivação (12 saídas, valores do programa de Glasgow no PTB-XL+). Um método sensato deveria atribuir à derivação e ao segmento correspondentes. (2) **XAI "glocal"**: as atribuições locais são alinhadas por batimento (300 ms antes e 500 ms depois do pico R) ou ponderadas por uma segmentação probabilística em 24 segmentos (U-Net 2D própria) e agregadas sobre as 100 maiores predições de cada classe, dando mapas por derivação × segmento. (3) **XAI global**: TCAV testa se conceitos clínicos (QRS largo para BRE, índice de Sokolow-Lyon para LVH, ondas Q para infarto, idade, sexo) são usados pelo modelo, com 10 CAVs × 10 modelos. (4) **Descoberta**: agrupam-se atribuições alinhadas para separar subclasses de infarto.

2. Como avalia as explicações

A avaliação quantitativa dos métodos está só no teste de sanidade. A especificidade espacial s_l é a razão entre a norma temporal da atribuição na derivação-alvo e a soma das normas nas 12 derivações (1 = toda a atribuição na derivação certa). A especificidade temporal recorta cada batimento (80 amostras), tira a norma entre derivações e faz a média entre batimentos; espera-se um pico no segmento regredido. Não há perturbação, valor de referência nem métrica de fidelidade do tipo deleção: o critério é uma "verdade de referência" construída pela própria tarefa de regressão. Na parte glocal, a concordância

com critérios clínicos é qualitativa (os sete segmentos de maior relevância por classe).

3. Resultados e conclusões

- **Sanidade:** LRP e IG são os mais específicos nas precordiais; a *saliency*, nas derivações dos membros, com menor variância. No eixo temporal, IG, LRP e Grad-CAM põem a maior relevância no pico R mesmo para P e T; só a *saliency* tem o maior valor no segmento correto nos seis experimentos.
- **Glocal:** LVH concentra relevância nos picos R de V5, V1 e V6; BRE completo em V1; infarto anterior em V1–V2 (QRS) e inferior em II, III, aVF e aVL (ondas Q).
- **Global:** os três conceitos clínicos são usados de forma consistente pelos dois modelos para as classes correspondentes.
- **Descoberta:** separar AMI de IMI agrupando atribuições dá acurácia de 90%, contra 75% com os batimentos de entrada e 61% com as ativações internas.
- **Limitações declaradas:** só o PTB-XL; uma única atribuição (*saliency*) nas análises seguintes; a análise glocal só capta padrões iguais em todos os batimentos (não capta variação de RR).

4. Citações

p. 8 §3.1 Testes de sanidade

"In terms of temporal specificity, IG and LRP attribute the largest fraction of relevance to the R-peak even if the R-peak is not directly relevant for the given task (e.g., for predicting the P-wave or T-wave amplitude). Interestingly, a similar effect is observed for GradCAM."
Tradução: "Em termos de especificidade temporal, IG e LRP atribuem a maior fração da relevância ao pico R mesmo quando ele não é diretamente relevante para a tarefa (por exemplo, prever a amplitude da onda P ou T). Curiosamente, efeito semelhante é observado no Grad-CAM."

EXPLICAÇÃO
É evidência direta, em ECG, do viés de amplitude: métodos do tipo gradiente × entrada concentram relevância no QRS. O GradientSHAP do TCC pertence a essa família (multiplica o gradiente por ECG − referência), e o achado do eMPRT (o mapa do modelo de pesos sorteados também se concentra no QRS) é coerente com isso.

p. 14 §4 Discussão

"Surprisingly, three out of the four considered attribution methods do not show a sensible degree of temporal or spatial specificity and show a strong bias toward attributing relevance to the QRS-complex, which typically contains the highest signal amplitudes."
Tradução: "Surpreendentemente, três dos quatro métodos de atribuição considerados não mostram grau razoável de especificidade temporal ou espacial e têm forte viés de atribuir relevância ao complexo QRS, que costuma conter as maiores amplitudes do sinal."

EXPLICAÇÃO
Dá nome ao risco que o TCC precisa controlar: um mapa que destaca o QRS pode refletir a amplitude, e não a decisão. Por isso o TCC compara as distâncias com um piso e com um modelo aleatório, em vez de ler a concentração no QRS como sinal de qualidade.

p. 14 §4 Discussão

"Gradient noise, a major drawback of saliency methods, can be very effectively reduced by aggregating attributions across beats and samples."
Tradução: "O ruído do gradiente, grande desvantagem dos métodos de *saliency*, pode ser reduzido de forma muito eficaz agregando as atribuições entre batimentos e amostras."

EXPLICAÇÃO
Apoia a agregação usada no TCC: somar a atribuição dentro de regiões (pré-QRS, QRS, ST-T por derivação) reduz a variação ponto a ponto, que no GradientSHAP é inflada pelo sorteio de

referências e ruído (o “piso”).

p. 8 §3.2 XAI glocal

“It is worth stressing, that while local attributions can potentially aid human decision-making, they are not directly applicable for auditing, which focuses on model behavior across entire patient groups.”
Tradução: “Vale ressaltar que, embora as atribuições locais possam ajudar a decisão humana, elas não se aplicam diretamente à auditoria, que se ocupa do comportamento do modelo em grupos inteiros de pacientes.”

EXPLICAÇÃO
Justifica resumir as métricas por classe no TCC: a pergunta é sobre o comportamento do modelo em grupos (as 9 classes), não sobre exames isolados.

p. 15 §4 Limitações

“While we identified saliency as the most reliable attribution method through a defined sanity check, comparing it against integrated gradients, LRP, and Grad-CAM, we acknowledge the limitations inherent in relying on a single attribution method for the proposed experiments.”
Tradução: “Embora tenhamos identificado a *saliency* como o método de atribuição mais confiável por meio de um teste de sanidade definido, comparando-a com integrated gradients, LRP e Grad-CAM, reconhecemos as limitações de depender de um único método nos experimentos propostos.”

EXPLICAÇÃO
O TCC também usa um só método (GradientSHAP). A ressalva vale igualmente: as conclusões por classe são sobre o par modelo + GradientSHAP, não sobre “a explicação” em geral.

5. Relação com o TCC

É o trabalho mais próximo do TCC na agregação: atribuições somadas por derivação × segmento do batimento, que é a mesma ideia das 36 regiões (12 derivações × pré-QRS / QRS / ST-T), com segmentação mais fina (24 segmentos). Também oferece evidência de que métodos do tipo gradiente × entrada tendem a concentrar relevância no QRS, o que ajuda a interpretar a concentração do mapa aleatório no QRS observada no eMPRT. Por outro lado, o teste de sanidade do artigo exige treinar modelos de regressão com alvo conhecido, o que o TCC não faz; e o artigo não usa métricas de fidelidade nem compara a qualidade das explicações com o desempenho por classe. A concordância glocal com critérios clínicos é qualitativa e restrita a quatro patologias do PTB-XL.

6. Como citar no TCC

- Wagner et al. (2024) mostraram, com modelos treinados para regredir amplitudes de ondas do ECG, que IG, LRP e Grad-CAM concentram a relevância no complexo QRS mesmo quando a tarefa depende da onda P ou T, o que evidencia um viés dos métodos de atribuição para as regiões de maior amplitude.
- A agregação das atribuições por derivação e segmento do batimento segue a proposta de análise “glocal” de Wagner et al. (2024).