Guia de leitura da revisão da literatura

Resumo dos fichamentos completos, ordem de leitura, conexões com o TCC e glossário

Aluno: Arthur Santos de Oliveira (RA: 156297)

Atualizado em: 04/11/2026

Repositório: https://github.com/Arthur-so/shap-ecg-arrhythmia

Como usar. Este guia organiza os **12 fichamentos completos** da pasta `fichamentos/revisao-literatura/completos/`. A seção 1 sugere uma ordem de leitura; a seção 2 resume cada artigo em poucas linhas; a seção 3 mostra os temas que ligam os artigos entre si e ao TCC; a seção 4 indica em que parte do texto do TCC cada um entra; a seção 5 reúne os precedentes para dividir o ECG em regiões a partir do pico R; a seção 6 explica os termos técnicos que aparecem nos artigos. O relatório completo da revisão está em `fichamentos/revisao-literatura/relatorio/main.pdf`, e os 27 fichamentos curtos, em `curtos/`, ficam como consulta.

Os 12 fichamentos completos

Pasta	Artigo	Tema
`ismail-2020-benchmark-series`	Ismail et al. (2020), NeurIPS	*Benchmark* de saliência em séries
`mercier-2022-benchmark-atribuicao`	Mercier et al. (2022), ICAART	*Benchmark* com Sensitivity e Infidelity
`hollig-2023-xtsc-bench`	Höllig et al. (2023), ICMLA	XTSC-Bench (Quantus em séries)
`turbe-2023-avaliacao-series`	Turbé et al. (2023), *Nat. Mach. Intell.*	Avaliação no CPSC (BRD)
`suh-2024-atribuicao-ecg`	Suh et al. (2024), *Comput. Biol. Med.*	Faithfulness Correlation em ECG
`storas-2025-mapas-calor-ecg`	Storås et al. (2025), JAMIA	Especialistas × perturbação
`arends-2026-atribuicao-ecg`	Arends et al. (2026), *EHJ Digital Health*	ResNet-1D, 9 classes, GradientSHAP
`gumpfer-2026-avaliacao-diretrizes-ecg`	Gumpfer et al. (2026), *preprint*	Regiões das diretrizes e amplitude
`wagner-2024-auditoria-ecg`	Wagner et al. (2024), *Comput. Biol. Med.*	Atribuições por derivação × segmento
`baer-2025-efeitos-dependentes-classe`	Baer et al. (2025a), xAI	Efeitos dependentes da classe
`baer-2025-dados-sinteticos-classe`	Baer et al. (2025b), *preprint*	As causas, em dados sintéticos
`ravindran-2023-eeg-verdade-simulada`	Sujatha Ravindran e Contreras-Vidal (2023), *Sci. Rep.*	Randomização em EEG simulado

> Os fichamentos das métricas do TCC (Bhatt, Alvarez-Melis, Yeh, Dasgupta, Sixt e Hedström) continuam nas pastas próprias em `fichamentos/`.

1. Ordem de leitura sugerida

A ordem vai do geral (como se avalia explicação em séries temporais) para o específico (ECG, classes, randomização). Cada bloco responde a uma pergunta que o TCC também faz.

1. **Bloco 1 — Como se avalia uma explicação em séries temporais?**
   (a) **Ismail et al. (2020).** O ponto de partida da área: mostra que os métodos acham *quando* o sinal importa, mas não *em qual canal*, e que retirar partes da entrada tira o exemplo da distribuição de treino.
   (b) **Mercier et al. (2022).** Primeiro contato com a Sensitivity (família da Max/Avg-Sensitivity do TCC) em séries, com o GradientShap e um conjunto de ECG.
   (c) **Höllig et al. (2023), XTSC-Bench.** O antecedente mais próximo do **conjunto de métricas** do TCC (Faithfulness Correlation, Max/Avg-Sensitivity, Complexity, via Quantus).
2. **Bloco 2 — E no ECG?**
   (a) **Turbé et al. (2023).** Mesma base do TCC (CPSC), GradientSHAP com 50 referências e o problema do deslocamento de distribuição.
   (b) **Suh et al. (2024).** O precedente da Faithfulness Correlation em ECG real; localização e perturbação discordam.
   (c) **Storås et al. (2025).** Especialistas e perturbação discordam; o GradientSHAP é o caso extremo.
   (d) **Arends et al. (2026).** O trabalho mais parecido com o TCC: ResNet-1D, nove classes, GradientSHAP, estabilidade, randomização e perturbação.
   (e) **Gumpfer et al. (2026).** Por que o GradientSHAP vai bem nos bloqueios de ramo e mal no segmento ST: a relevância segue a amplitude.
   (f) **Wagner et al. (2024).** O precedente das regiões: atribuições recortadas em janela fixa em torno do pico R e agregadas por derivação × segmento; mostra também o viés de amplitude de IG e LRP.
3. **Bloco 3 — Por que as classes diferem nas métricas?**
   (a) **Baer et al. (2025a).** Métricas de perturbação variam por classe por motivos que não são a qualidade da explicação.
   (b) **Baer et al. (2025b).** A causa, em dados sintéticos: diferenças de amplitude e duração entre as classes bastam.
4. **Bloco 4 — O mapa depende do modelo?**
   (a) **Sujatha Ravindran e Contreras-Vidal (2023).** Testes de randomização em sinal fisiológico (EEG simulado). Ler em seguida o fichamento do eMPRT (`fichamentos/hedstrom-2023-emprt`) e o do Random Logit (`fichamentos/sixt-2020-random-logit`).

Quem tiver pouco tempo pode ler só **Arends, Suh, Gumpfer e Baer (2025a)**: juntos, eles cobrem o desenho mais próximo, o precedente da métrica, o efeito da amplitude e a ressalva sobre as classes.

2. Resumo de cada artigo

2.1. Ismail et al. (2020) — *benchmark* de saliência em séries

O que fizeram. Criaram séries multivariadas sintéticas em que se sabe quais instantes e quais variáveis carregam a informação, treinaram várias arquiteturas e compararam métodos de saliência,

entre eles o GradientSHAP. **Achado.** Os métodos identificam os instantes relevantes, mas não as variáveis dentro deles; a arquitetura pesa mais que o método. Retirar atributos para medir fidelidade pode tirar a entrada da distribuição de treino. **Para o TCC.** Justifica olhar a importância **por derivação** (e não só por segmento) e a ressalva sobre o deslocamento de distribuição na Faithfulness Correlation e na Faithfulness Estimate.

2.2. Mercier et al. (2022) — *benchmark* com Sensitivity e Infidelity

O que fizeram. Compararam 12 métodos em seis conjuntos de séries (entre eles o ECG5000) pelas métricas de Yeh et al. (2019), Sensitivity e Infidelity, além de testes de dependência do modelo e dos rótulos. **Achado.** Nenhum método vence em todos os critérios; os métodos por perturbação foram mais robustos e os baseados no gradiente, mais rápidos. O GradientShap teve a maior Sensitivity entre os métodos de gradiente em todos os conjuntos. **Para o TCC.** Apoia a leitura de que a variação própria do GradientSHAP (o piso) domina a sensibilidade, e a agregação em grupos de pontos (regiões).

2.3. Höllig et al. (2023) — XTSC-Bench

O que fizeram. Uma ferramenta de avaliação de explicações para classificação de séries temporais sobre o Quantus, com Faithfulness Correlation, Max/Avg-Sensitivity, Complexity e localização, incluindo o GradientSHAP. **Achado.** Nenhum explicador supera os demais em todas as propriedades; substituir trechos por zero ou média pode introduzir informação em séries; só avaliam classificadores com acurácia acima de 90%. **Para o TCC.** É o precedente do conjunto de métricas; o TCC difere ao calcular por regiões e ao estudar justamente o que acontece em classes de desempenho mais baixo.

2.4. Turbé et al. (2023) — avaliação no CPSC

O que fizeram. Na mesma base do TCC (CPSC), numa tarefa binária (BRD sim/não), compararam seis métodos (DeepLift, GradShap, IG, KernelShap, DeepLiftShap e Shapley Value Sampling) em três arquiteturas, com métricas de retirada (AUC $\tilde{S}_{top}$, F1$\tilde{S}$). Para evitar o deslocamento de distribuição, treinaram o modelo já com trechos trocados por ruído $\mathcal{N}(0, 1)$. O GradShap usa 50 ECGs sorteados do teste como referência; o ECG é reduzido a um batimento médio por derivação. **Achado.** Na CNN com ECG, DeepLiftShap 0,465, GradShap 0,357, Shapley 0,341, IG 0,313 e KernelShap 0,025, contra 0,047 do aleatório. A relevância funciona mais como **ordem** do que como contribuição proporcional; o modelo de BRD depende quase só de uma derivação. **Para o TCC.** Justifica a referência como distribuição de ECGs e explica por que correlações moderadas na Faithfulness Correlation são esperadas.

2.5. Suh et al. (2024) — Faithfulness Correlation em ECG

O que fizeram. Avaliaram 11 métodos (incluindo DeepSHAP e KernelSHAP; sem GradientSHAP) em cinco bases de ECG com uma ResNet-18 1D, com quatro métricas de localização e três de perturbação, entre elas a **Faithfulness Correlation**: 10% dos pontos substituídos por zero, 100 sorteios, Pearson com a queda do logit, só predições com probabilidade acima de 0,9. **Achado.** O DeepSHAP teve a maior Faithfulness Correlation nas quatro bases (0,41 a 0,63); os métodos melhores na localização não são os melhores na perturbação; os autores recomendam localização quando há anotação, por causa do deslocamento de distribuição. **Para o TCC.** É o precedente a citar: a métrica **não é inédita em ECG**. O que é próprio do TCC é o cálculo por regiões, o piso e a comparação por classe.

2.6. Storås et al. (2025) — especialistas × perturbação

O que fizeram. Nove métodos de gradiente, entre eles o Gradient SHAP com referência zero, em modelos que medem intervalos e amplitudes do ECG (regressão, ECGs sintéticos). Avaliação por três especialistas e por perturbação ordenada (um ponto por vez, ruído). **Achado.** O Gradient SHAP foi dos melhores na perturbação e quase não foi escolhido pelos especialistas; nenhum método venceu sempre. A perturbação por ruído afeta pouco os trechos de grande amplitude. **Para o TCC.** Mostra que "fiel ao modelo" e "convincente para o médico" são critérios diferentes e que a amplitude do sinal interfere nas métricas de retirada.

2.7. Arends et al. (2026) — o desenho mais próximo

O que fizeram. ResNet-1D treinadas em ECG de 12 derivações para nove classes, 12 métodos (GradientSHAP incluído, pelo Captum), com três testes: concordância entre modelos treinados com sementes diferentes, randomização progressiva dos pesos e perturbação no estilo ROAD. Fixaram o número de sorteios dos métodos estocásticos para que dois mapas do mesmo ECG tivessem correlação de pelo menos 0,98. **Achado.** Autoconsistência apenas moderada entre modelos (cerca de 0,55 para o GradientSHAP) e correlação perto de zero após randomizar os pesos; comportamento semelhante em classes de AUPRC alta e baixa, sem análise formal. **Para o TCC.** É o comparador principal; o TCC mede explicitamente a variação do método (piso) e faz a comparação por classe que eles deixaram em aberto.

2.8. Gumpfer et al. (2026) — regiões das diretrizes e amplitude

O que fizeram. Treze métodos no PTB-XL, comparados com regiões definidas por diretrizes clínicas (PR, QRS, ST) em quatro doenças. **Achado.** Métodos que multiplicam o gradiente pela entrada ou subtraem uma referência, entre eles o GradientSHAP, concentram a relevância em componentes de alta amplitude (pico R, onda T). O GradientSHAP cobre bem o QRS nos bloqueios de ramo e fica abaixo do acaso no ST da isquemia ($-5{,}5\%$). **Para o TCC.** Explica o eMPRT (o modelo aleatório concentra o mapa no QRS) e o padrão por classe: classes definidas pela forma do QRS (BRD, BRE, CVP) saem melhor nas métricas; classes de ST e de ritmo, pior. É também o precedente mais forte, entre os completos, para as regiões do batimento (seção 5).

2.9. Wagner et al. (2024) — atribuições por derivação e segmento

O que fizeram. No PTB-XL (100 Hz), com LeNet e XResNet, propuseram testes de sanidade (modelos que preveem amplitudes das ondas P, R e T, com resposta conhecida) e a XAI "glocal": atribuições recortadas de 300 ms antes a 500 ms depois de cada pico R, ou ponderadas por uma segmentação em 24 segmentos, e agregadas por derivação × segmento nas 100 maiores predições de cada classe. **Achado.** Só a saliency passa no teste de sanidade; IG, LRP (equivalente a gradiente × entrada) e Grad-CAM põem a relevância no pico R mesmo em tarefas de onda P ou T. Os mapas agregados concordam com as regras clínicas (LVH, bloqueio de ramo esquerdo, infarto), e agregar entre batimentos reduz o ruído do gradiente. **Para o TCC.** É o precedente mais próximo das 36 regiões e mais uma evidência do viés de amplitude da família do GradientSHAP. Ressalvas: o artigo usa a média por segmento (o TCC, a soma) e não usa as regiões como unidade de métricas; a agregação apaga variações entre batimentos (ritmo).

2.10. Baer et al. (2025a) — efeitos dependentes da classe

O que fizeram. Em séries temporais (UCR), analisaram métricas de perturbação por classe predita, com vários valores de perturbação e métodos (GradientSHAP incluído). **Achado.** A eficácia das métricas varia muito entre classes; as estratégias de melhor média são as mais dependentes da classe; a causa provável são vieses do classificador em relação ao valor usado para "retirar" um trecho. **Para o TCC.** A ressalva central: diferença de fidelidade entre classes não é, por si, diferença de qualidade. Recomendam reportar por classe.

2.11. Baer et al. (2025b) — as causas em dados sintéticos

O que fizeram. Repetiram a análise em dados sintéticos com evidência conhecida. **Achado.** Diferenças simples de **amplitude** ou de **duração** do padrão entre as classes bastam para gerar os efeitos; a métrica de perturbação chega a ordenar as classes ao contrário da verdade conhecida. **Para o TCC.** As classes do ECG diferem exatamente nisso (QRS largo, desvios pequenos de ST, PR longo); a ordem das classes na fidelidade deve ser discutida à luz dessas propriedades.

2.12. Sujatha Ravindran e Contreras-Vidal (2023) — randomização em EEG

O que fizeram. EEG simulado com evidência conhecida (canal, instante, frequência); 12 métodos; testes de randomização de pesos e de rótulos (Adebayo et al., 2018). **Achado.** A saliência (gradiente

puro) não foi específica do modelo nem da classe; DeepLift, LRP e Input × Gradient foram precisos e sensíveis à randomização. O GradientSHAP não foi avaliado, mas pertence a essa última família. **Para o TCC.** Reforça a necessidade dos testes de randomização (eMPRT, Random Logit) além das métricas de fidelidade.

3. Conexões entre os artigos e com o TCC

Tema	O que os artigos dizem	Decisão ou achado do TCC
Retirar trechos tira o ECG da distribuição	Ismail, Turbé, Suh e XTSC-Bench apontam o problema; Turbé treina com ruído para evitá-lo. Os quatro perturbam **pontos** ou trechos curtos, não regiões fisiológicas: servem para a limitação, não para justificar as regiões (seção 5)	Duas referências (zero e média, com resultados praticamente iguais); limitação declarada. Que regiões contíguas atenuam o problema é argumento do TCC, com apoio indireto de Cui (2023, curto)
A amplitude domina o mapa	Gumpfer (atribuição segue o pico R e a onda T), Wagner (IG e LRP no pico R mesmo em tarefas de onda P ou T), Storås (ruído afeta pouco o pico R), Adebayo (entrada × gradiente "devolve a entrada")	eMPRT: mapa do modelo aleatório no QRS; classes de QRS (BRD, BRE, CVP) no topo da fidelidade
O GradientSHAP é estocástico	Mercier (maior Sensitivity entre os de gradiente), Arends (fixa sorteios para correlação $\geq 0{,}98$)	Piso medido (0,18) e usado como régua; 200 sorteios
Métricas variam por classe	Baer (a, b), Gumpfer (por doença), Arends (AUPRC por classe)	Resultados por classe; comparação descritiva com o F1
Métricas discordam entre si	Suh (localização × perturbação), Storås (especialistas × perturbação), Mercier, XTSC-Bench	Sete métricas, lidas em conjunto, sem um "vencedor" único
O mapa depende do modelo?	Arends (randomização progressiva), Ravindran (pesos e rótulos), Mercier	eMPRT e Random Logit: distâncias muito acima do piso
Agregar pontos em regiões do batimento	Wagner (derivação × segmento, janela fixa no pico R), Gumpfer (máscaras PR/QRS/ST e teste de deslocamento), Turbé (recorte fixo no pico R), Hicks (retirada de ondas inteiras; curto), Mercier (falta de grupos em séries)	36 regiões = 12 derivações × pré-QRS/QRS/ST-T; limites variados sem mudar a ordem das classes (seção 5)
Desempenho do modelo e explicação	XTSC-Bench só usa modelos $> 90\%$; Arends sem relação clara com AUPRC	A pergunta do TCC; nenhum trabalho a responde diretamente

4. Como usar no texto do TCC

Parte do TCC	Artigos e o que sustentam
Introdução e justificativa	Arends e Gumpfer (avaliar atribuições em ECG é necessário e pouco feito); Suh (falta de avaliação sistemática em ECG); Storås (especialistas e métricas discordam)
Fundamentação: avaliação de explicações	Ismail, Mercier, XTSC-Bench (como se avalia em séries); Baer (limites das métricas de perturbação); Ravindran (testes de randomização)
Trabalhos relacionados	Turbé (mesma base), Suh (mesma métrica), Arends (mesmo desenho), Gumpfer (regiões e amplitude)
Metodologia: referência do GradientSHAP	Turbé (distribuição de 50 ECGs), Arends (controle da variação de sorteio)
Metodologia: regiões	Wagner e Gumpfer (precedentes diretos), Turbé e Hicks (recorte no pico R, retirada de ondas), Mercier, Serramazza e Šimić (agrupar pontos); ver a seção 5
Metodologia: valor de substituição	XTSC-Bench (zero pode carregar informação), Suh (zero), Turbé (ruído)
Metodologia: comparação descritiva com o F1	Baer (efeitos de classe), Gumpfer (diferenças por doença), Arends (análise só descritiva)
Discussão dos resultados	Gumpfer e Baer (por que BRD/BRE/CVP saem melhor e ST/ritmo pior); Mercier (sensibilidade e piso); Ravindran e Adebayo (eMPRT)
Limitações	Ismail, Turbé e Suh (deslocamento de distribuição); Gumpfer e Wagner (regiões fixas × delineação das ondas); Storås (plausibilidade não avaliada); Arends (um único modelo treinado)

Ao citar
Os fichamentos trazem, no fim, sugestões de frases ("Como citar no TCC"). Gumpfer et al. (2026) e Baer et al. (2025b) são *preprints*: citar como tal. Escrever "não se encontrou" (e não "não existe") ao afirmar a originalidade do TCC.

5. Precedentes para as regiões do batimento

O TCC soma o mapa em 36 regiões (12 derivações × pré-QRS, QRS e ST-T), delimitadas por janelas fixas a partir do pico R (QRS de $R-80$ ms a $R+100$ ms; ST-T até $0{,}45 \cdot RR$). A banca pode perguntar duas coisas: **por que regiões, e não pontos**, e **por que esses milissegundos**. Esta seção reúne o que os fichamentos oferecem para responder.

O que a linha do deslocamento de distribuição não sustenta
Ismail, Turbé, Suh e XTSC-Bench aparecem na tabela de conexões porque mostram que retirar trechos tira o ECG da distribuição de treino. Nenhum deles usa regiões fisiológicas: Ismail e XTSC-Bench perturbam pontos ou instantes; Turbé, uma fração dos pontos do batimento médio; Suh, 10% dos pontos sorteados na Faithfulness Correlation e trechos fixos de cerca de 0,06 s, sem relação com as ondas, em outra métrica. Eles sustentam a **limitação**, não a escolha das regiões.

5.1. Trabalhos que agrupam o ECG por regiões do batimento

Trabalho	O que fazem	Fichamento
Wagner et al. (2024), *Comput. Biol. Med.*	Alinham as atribuições de cada batimento numa janela fixa em torno do pico R (**300 ms antes e 500 ms depois**) ou as ponderam por uma segmentação em 24 segmentos, e agregam em mapas **derivação** × **segmento** por classe. Observam que agregar entre batimentos reduz o ruído dos métodos de gradiente. É o precedente mais próximo do TCC.	completo
Gumpfer et al. (2026), *preprint*	Detectam os picos R (NeuroKit2, derivação I), recortam batimentos e avaliam as explicações com máscaras **fixas** de PR, QRS e ST definidas por cardiologistas. Testam a robustez deslocando as máscaras: a ordem se mantém até 10 pontos (num batimento de 500); com 20, a máscara engole o QRS.	completo
Turbé et al. (2023), *Nat. Mach. Intell.*	Recortam cada batimento por uma janela fixa em torno do pico R (**0,35 s antes e 0,55 s depois**) para formar o batimento médio de entrada do modelo.	completo
Hicks et al. (2021), *Sci. Rep.*	Retiram **ondas inteiras** (P, QRS ou T) do batimento mediano, por interpolação entre as bordas, e medem a piora da predição: perturbação por região fisiológica.	curto

5.2. Trabalhos que agrupam pontos em trechos (sem relação com as ondas)

- **Mercier et al. (2022)** (completo): apontam a falta de agrupamento de pontos como um problema dos métodos em séries temporais.
- **Arends et al. (2026)** (completo): o Shapley sampling usa 240 segmentos (30 por derivação).
- **Serramazza et al. (2024)** (curto): agrupar pontos consecutivos de cada canal em trechos melhora as métricas de perturbação.
- **Šimić et al. (2025)** (curto): avaliam a retirada de regiões de 2,5% a 10% do comprimento da série.
- **Cui et al. (2023)** (curto, EEG): perturbam janelas contíguas em vez de pontos sorteados, para introduzir menos ruído de alta frequência; é o único apoio, indireto, para a ideia de que retirar regiões atenua o deslocamento de distribuição.

5.3. Como defender os milissegundos

1. **Janelas fixas a partir do pico R são prática usada:** Wagner (300/500 ms) e Turbé (0,35/0,55 s) fazem o mesmo, e Gumpfer usa máscaras fixas no batimento.
2. **Justificativa clínica:** a janela do QRS (180 ms) cobre o QRS normal (até cerca de 120 ms) e o alargado dos bloqueios de ramo (120 ms ou mais). O limite de $0{,}45 \cdot RR$ aproxima o fim da onda T (pela fórmula de Bazett, o QT ocupa cerca de 0,44 do RR com 60 bpm); em frequências altas, o fim da T pode cair no pré-QRS.
3. **Teste de robustez, como o de Gumpfer:** a Consistency e a complexidade foram recalculadas com o QRS de 140, 180 e 220 ms e o fim do ST-T em 0,40, 0,45 e 0,50 do RR (9 combinações, mapas da versão 2). Na Consistency ($k = 2$), BRD ficou em 1.º e CAP e STE nas duas últimas posições em todas; na complexidade, BRD, AF e IAVB foram sempre as três mais concentradas e STD a mais espalhada. As métricas que exigem rodar o modelo não foram recalculadas. Dados em `results/modeloB_v2/regioes_robustez.json`; texto na seção de regiões de `texto-tcc/metodologia-resultados/main.pdf`.
4. **Limitação e alternativa:** delinear o início e o fim de cada onda batimento a batimento (NeuroKit2, ou a segmentação de Wagner) seria mais fiel na teoria, mas menos confiável justamente nos ECGs patológicos; fica como trabalho futuro.

Leitura complementar
Wagner et al. (2024) tem fichamento completo (`completos/wagner-2024-auditoria-ecg`), com as duas frases a citar na Metodologia (p. 5 e p. 14) e a diferença entre a média por segmento do artigo e a soma por região do TCC, que a banca pode perguntar. Hicks et al. (2021) só tem fichamento curto (`curtos/hicks-2021-ecgradcam-descoberta`).

6. Glossário

Termos agrupados por assunto. Cada definição é a forma mais simples que basta para ler os artigos.

6.1. Medidas de desempenho do classificador

Precisão e revocação. Precisão: das vezes em que o modelo disse "classe X", quantas estavam certas. Revocação (*recall*, sensibilidade): dos casos que eram X, quantos o modelo encontrou.

F1. Média harmônica de precisão e revocação; só é alto se as duas forem altas. **F1-macro**: média simples do F1 das classes (cada classe pesa igual, rara ou comum).

Limiar. Valor a partir do qual a probabilidade vira "sim". No TCC, cada classe tem o seu limiar, escolhido para maximizar o F1 na validação.

Curva ROC e AUC (AUROC). A curva ROC mostra, para todos os limiares possíveis, a taxa de verdadeiros positivos contra a de falsos positivos. A **AUC** (*area under the curve*) é a área sob essa curva: 0,5 é o acaso e 1 é perfeito. Pode ser lida como a probabilidade de o modelo dar escore maior a um positivo sorteado do que a um negativo sorteado. Não depende de limiar.

AUPRC. Área sob a curva precisão–revocação. Parecida com a AUC, mas mais informativa para classes raras: o valor do acaso é a prevalência da classe (por exemplo, 0,03 se a classe aparece em 3% dos exames), e não 0,5.

AUC em métricas de explicação. Vários artigos usam "AUC" para a área sob uma **curva de retirada** (quanto a saída cai à medida que se retiram os trechos mais importantes), não para a curva ROC. É o caso da AUC $\tilde{S}_{top}$ de Turbé e da área sob a curva de erro de Storås. Sempre conferir qual curva é.

Logit, sigmoide, softmax. Logit: a saída "crua" do modelo antes de virar probabilidade. A sigmoide transforma cada logit numa probabilidade independente (multirrótulo, como no TCC); a softmax transforma o vetor de logits em probabilidades que somam 1 (uma classe só).

BCE. Entropia cruzada binária, a função de perda do treino multirrótulo; "ponderada" quando os positivos de classes raras pesam mais.

6.2. Métodos de explicação

Mapa de atribuição (saliência, *heatmap*). Um número por ponto (ou região) do sinal dizendo quanto ele contribuiu para a saída de uma classe.

Saliency. O gradiente puro da saída em relação à entrada.

Input × Gradient (G×I). Gradiente multiplicado pela própria entrada.

Integrated Gradients (IG). Média dos gradientes ao longo de um caminho reto entre uma referência e a entrada, multiplicada pela diferença entre as duas.

Valor de Shapley. Divisão "justa" da saída entre os atributos, pela média da contribuição de cada atributo em todas as combinações possíveis dos demais.

KernelSHAP, Shapley Value Sampling. Aproximações do valor de Shapley por amostragem de combinações (perturbando a entrada e rodando o modelo muitas vezes).

DeepLIFT, DeepSHAP (DeepLiftShap). Propagam para trás a diferença entre a ativação na entrada e numa referência; o DeepSHAP faz a média sobre várias referências.

GradientSHAP. Média de gradiente × (entrada − referência) em pontos sorteados entre a entrada e referências sorteadas, com ruído; é estocástico. É o método do TCC.

SmoothGrad. Média de mapas de saliência de cópias da entrada com ruído.

LRP. *Layer-wise Relevance Propagation*: redistribui a saída para trás, camada a camada, por regras próprias.

Grad-CAM, Guided Backprop, Guided Grad-CAM. Grad-CAM usa os mapas de ativação de uma camada convolucional pesados pelo gradiente (mapa de baixa resolução); Guided Backprop deixa passar só gradientes positivos; Guided Grad-CAM combina os dois.

LIME. Ajusta um modelo linear simples em torno do exemplo, com versões perturbadas da entrada.

Referência (*baseline*). O "sinal ausente" contra o qual se mede a contribuição (zero, média ou uma distribuição de exemplos). No TCC: 36 ECGs do treino, 4 por classe.

6.3. Avaliação de explicações

Fidelidade × plausibilidade. Fidelidade: o mapa reflete o que o **modelo** usa. Plausibilidade: o mapa coincide com o que um **especialista** olharia. São coisas diferentes; o TCC mede fidelidade.

Deleção/inserção, MoRF/LeRF, AOPC. Retirar (ou inserir) trechos na ordem do mapa e medir a saída. MoRF: retira primeiro os mais relevantes (a saída deve cair rápido); LeRF: os menos relevantes (deve cair devagar). AOPC: área média da queda ao longo das retiradas.

Valor de perturbação. O que se põe no lugar do trecho retirado (zero, média, ruído, interpolação). Muda os resultados (Baer, XTSC-Bench).

Deslocamento de distribuição (OOD). Entrada perturbada diferente de tudo o que o modelo viu no treino; a queda da saída pode vir da estranheza, e não da informação retirada.

ROAR, ROAD. ROAR: retira os trechos e **retreina** o modelo para evitar o OOD. ROAD: retira trechos com interpolação ruidosa, sem retreinar.

Localização: IoU, *pointing game*, *relevance rank/mass accuracy*. Comparam o mapa com uma região anotada: sobreposição (IoU), se o ponto máximo cai na região (*pointing game*), fração dos pontos mais relevantes ou da relevância total dentro dela.

Testes de sanidade, randomização em cascata. Sortear de novo os pesos do modelo (de uma vez ou camada a camada) ou os rótulos e verificar se o mapa muda (MPRT, eMPRT).

Autoconsistência. Concordância entre mapas do mesmo exemplo gerados por modelos treinados com sementes diferentes (Arends).

Verdade simulada (*ground truth*). Dados sintéticos em que se sabe onde está a evidência.

Meta-avaliação. Avaliar as próprias métricas de avaliação (por exemplo, MetaQuantus).

Quantus, Captum. Bibliotecas em Python: Quantus implementa métricas de avaliação; Captum, métodos de explicação (o GradientSHAP do TCC vem do Captum).

6.4. Estatística e concordância

Pearson e Spearman. Pearson: correlação linear entre valores. Spearman: correlação entre as **posições** (postos), insensível a escala. A Faithfulness Correlation usa Pearson dentro de cada mapa.

κ de Cohen. Concordância entre avaliadores descontando o acaso (0 = acaso, 1 = perfeita).

ICC. Coeficiente de correlação intraclasse: concordância entre avaliadores para notas numéricas.

SSIM. Índice de semelhança estrutural entre imagens, usado em testes de randomização em imagens.

Entropia, Gini. Medidas de espalhamento: entropia alta e Gini baixo indicam importância distribuída em muitas regiões.

***Bootstrap*.** Reamostrar os dados com reposição para obter intervalos de confiança.

6.5. Dados e treino

CPSC2018, PTB-XL, MIT-BIH, Icentia11K, ECG5000. Bases de ECG: CPSC2018 (12 derivações, 9 classes, base do TCC); PTB-XL (12 derivações, cerca de 21 mil exames); MIT-BIH e Icentia11K (Holter, batimentos); ECG5000 (batimentos de uma derivação, do arquivo UCR).

UCR/UEA. Repositórios de séries temporais usados como *benchmark* (univariadas e multivariadas).

Multirrótulo. Um exame pode ter mais de uma classe ao mesmo tempo (no CPSC2018, por exemplo, AF e BRD).

Ablação. Experimento que muda um único componente para medir o seu efeito (no TCC, BCE ponderada × simples).

***Early stopping*, z-score, *padding*.** Parar o treino quando a validação deixa de melhorar; normalizar cada derivação para média 0 e desvio 1; completar o sinal com zeros até o comprimento fixo.

***Preprint*.** Artigo publicado antes da revisão por pares (arXiv, medRxiv).