Fichamento: Random Logit

SIXT, L.; GRANZ, M.; LANDGRAF, T. *When Explanations Lie: Why Many Modified BP Attributions Fail*. ICML, 2020 (arXiv:1912.09818v7)

Métrica no Quantus: `quantus.RandomLogit`

Aluno: Arthur Santos de Oliveira (RA: 156297)

Atualizado em: 26/10/2026

Repositório: https://github.com/Arthur-so/shap-ecg-arrhythmia

---

Como ler. `[p. N]` indica a página do PDF do artigo (20 páginas, incluindo o apêndice). As citações estão no original em inglês, cada uma seguida de uma tradução livre. A **Parte I** explica a métrica sem pressupor a leitura do artigo; a **Parte II** é o fichamento; a **Parte III** descreve a versão implementada no TCC, sua aderência ao artigo, o diagnóstico e os resultados; a versão do Quantus aparece resumida no final.

> **Por que esta métrica**
> O documento *Seleção de métricas* (22/10/2026) escolheu o Random Logit por responder a uma pergunta que nenhuma métrica do TCC alcança: **a explicação é específica da classe?** A fidelidade, a robustez, a Consistency e a complexidade olham sempre o mapa da classe explicada, sem compará-lo ao mapa de outra classe no mesmo ECG.

PARTE I · ENTENDENDO A MÉTRICA

1. O problema que a métrica resolve

Cada mapa SHAP do TCC explica a saída de **uma** classe para **um** ECG: por exemplo, por que o modelo deu um logit alto para BRD neste exame. O modelo, porém, tem 9 saídas, e o mesmo ECG pode ser explicado para qualquer uma delas. Se o mapa que explica BRD for praticamente igual ao mapa que explica AF no mesmo ECG, ele não está mostrando por que o modelo decidiu BRD; está mostrando algo comum a todas as saídas, como os trechos de maior amplitude do sinal. Uma explicação assim é **insensível à classe**.

2. A ideia em uma frase e um exemplo

> **Definição em uma frase**
> Explica-se o mesmo ECG para a classe de interesse e para outra classe, e compara-se os dois mapas: se forem quase iguais, a explicação não é específica da classe.

O nome vem do artigo: compara-se a explicação do logit verdadeiro com a de um **logit sorteado** (*random logit*) entre as outras classes.

Exemplo. Um ECG com bloqueio de ramo direito (BRD) é explicado duas vezes: para BRD, a classe presente, e para AF, uma classe ausente. A tabela mostra o que fariam dois métodos de explicação **imaginários**, inventados só para ilustrar: o método 1, que **falharia** no teste, e o método 2, que **passaria**. Os números também são inventados (4 regiões, importâncias já normalizadas):

	V1 QRS	II pré-QRS	V5 QRS	aVR ST-T	Leitura
BRD (classe explicada)	0,90	0,10	0,30	0,30	—
AF, método 1	0,88	0,12	0,32	0,29	quase igual *(insensível)*
AF, método 2	0,10	0,85	0,20	−0,48	diferente *(específico)*

- **Método 1 (insensível à classe):** o mapa de AF sai quase igual ao de BRD; os dois apontam V1 QRS. O mapa mostra onde o ECG tem um sinal marcante, mas não por que o modelo decidiu

cada classe: perguntar sobre BRD ou sobre AF dá a mesma resposta. É o comportamento que Sixt et al. encontraram em métodos como o LRP (seção 3).

- **Método 2 (específico da classe):** o mapa de AF destaca outra região, a pré-QRS, onde fica a onda P, que falta na fibrilação atrial; o de BRD destaca o QRS de V1, onde o bloqueio de ramo direito aparece. Cada pergunta recebe a sua resposta. É o que se espera de uma boa explicação.

O Random Logit mede de qual dos dois lados está o método usado no TCC, o GradientSHAP.

3. Por que medir, se a teoria diz que o GradientSHAP não falha

O artigo explica **por que** alguns métodos dão mapas insensíveis à classe e diz que os métodos baseados no gradiente, como o GradientSHAP, estão livres desse problema. Ainda assim, há três motivos para fazer o teste no TCC.

(1) A garantia do artigo cobre uma causa, e há outra. A causa estudada no artigo está nos métodos de **retropropagação modificada** (LRP, Deep Taylor, Guided BP e outros). Eles levam a importância da saída até a entrada camada por camada, com regras próprias, e essa cadeia de regras acaba sempre na mesma direção, qualquer que seja a classe de partida: tecnicamente, converge para uma matriz de **posto 1**. Na prática, a última camada, que é a que distingue as classes, deixa de influenciar o mapa. O gradiente não tem essa convergência, e é isso que o artigo garante.

Há, porém, uma segunda causa possível, que a teoria do artigo não cobre. Aproximadamente, o GradientSHAP calcula

$$\text{mapa}_c(x) \approx \mathbb{E}\big[(x - x') \odot \nabla_x f_c(\tilde{x})\big],$$

em que x é o ECG, x' uma baseline sorteada do treino, $\tilde{x}$ um ponto entre as duas e $\nabla_x f_c$ o gradiente da saída da classe c. O mapa é um produto de dois fatores, e só um deles depende da classe:

Fator	Depende da classe?	Onde é grande
$x - x'$ (ECG − baseline)	Não: é o mesmo para as 9 classes	Onde o ECG difere da referência, como no QRS, de maior amplitude
$\nabla_x f_c$ (gradiente)	Sim	Onde a saída da classe c é sensível ao sinal

Se o primeiro fator dominar o produto, os mapas de todas as classes destacam os mesmos trechos, e o GradientSHAP se comportaria como o método 1 da seção anterior, por outro motivo. Adebayo et al. (2018, §5.2) apontam esse efeito em métodos do tipo gradiente × entrada. O próprio Sixt et al. ressalvam que os métodos baseados no gradiente "ainda podem sofrer de outras limitações" (p. 8).

(2) O artigo não testou o caso do ECG. Os resultados do artigo são em imagens com um único objeto por imagem, e os autores reconhecem que esse tipo de base esconde a insensibilidade à classe (p. 6). O ECG multirrótulo, em que cada classe tem a sua evidência num trecho diferente do batimento, é justamente o caso em que ela apareceria (ver, na Parte II, a citação sobre a doença de Alzheimer, p. 6).

(3) O teste não é só "passa ou falha". Mesmo que o GradientSHAP passe, a métrica mede **quanto** o mapa de cada classe se diferencia dos das outras. Isso dá um valor por classe, que pode ser comparado com o F1, como as demais métricas do TCC.

> **Em resumo**
> A teoria do artigo indica que o GradientSHAP não deveria falhar, mas não garante isso no ECG: há outra causa possível (o fator ECG − baseline, comum a todas as classes), o caso multirrótulo não foi testado no artigo, e o grau de especificidade de cada classe é, por si, um resultado.

4. Passo a passo

Para cada mapa (ECG x, classe explicada c):

1. Gera-se o mapa de referência de c.
2. Para outra classe c', gera-se o mapa de c' no mesmo ECG.
3. Mede-se a distância (ou a semelhança) entre os dois mapas.
4. Repete-se para outros ECGs e resume-se por classe.

Distância alta indica explicação específica da classe; distância próxima de zero, explicação insensível.

5. Três cuidados de leitura

- **O mapa de c' explica uma saída baixa.** Se c' não está presente no ECG, o modelo dá a ela um logit negativo, e o mapa de c' explica **por que** essa classe não foi predita. Isso continua sendo uma explicação legítima da saída c'; o teste só pergunta se ela difere da explicação de c.
- **Classes presentes no mesmo ECG.** Um ECG pode ter mais de um diagnóstico (por exemplo, AF e BRD). Nesse caso, mapas parecidos podem ser legítimos, pois as duas classes podem usar a mesma evidência. O artigo não trata esse caso, porque as bases de imagens usadas têm um objeto por imagem.
- **Ruído do método.** O GradientSHAP sorteia baselines e ruído; dois mapas da **mesma** classe, com sementes diferentes, já diferem (o piso medido na sensibilidade). Uma distância entre classes só indica especificidade se for maior que essa variação.

6. Traduzindo para o ECG

Elemento	No artigo	No TCC
Entrada	Imagem (ImageNet, CIFAR-10)	ECG de 12 derivações
Classe explicada	Rótulo verdadeiro (um por imagem)	Classe do mapa, presente e predita corretamente
Outra classe	Logit sorteado entre as demais	Classes ausentes nos rótulos do ECG (as presentes à parte)
Atributos	Pixels	36 regiões do batimento
Comparação	SSIM	Distância ℓ_2 entre vetores de norma 1
Referência	Nenhuma	Piso do GradientSHAP (outra semente)

PARTE II · FICHAMENTO DO ARTIGO

7. Mapa de leitura

O artigo trata principalmente da teoria da convergência (§2) e de uma métrica própria, a *cosine similarity convergence* (CSC). O Random Logit aparece como um dos três testes da avaliação (§3), ao lado do teste de randomização de parâmetros de Adebayo et al. (2018). As citações abaixo cobrem a motivação (p. 1–2), o alcance da teoria (p. 2–3), o teste (p. 5), os resultados (p. 6) e a discussão (p. 6 e 8).

p. 1 Figura 1

"(b-e) Class insensitivity of LRPα1β0 on VGG-16. Explanation for (c) Persian cat (283) and (d) King Charles Spaniel (156). (e) Difference (c) - (d), both normalized to [0, 1]. L1-norm of (e) = 0.000371."
Tradução: "(b-e) Insensibilidade à classe do LRPα1β0 na VGG-16. Explicação para (c) gato persa (283) e (d) King Charles Spaniel (156). (e) Diferença (c) − (d), ambas normalizadas para [0, 1]. Norma L1 de (e) = 0,000371."

EXPLICAÇÃO
É o exemplo que motiva o teste: a mesma imagem explicada para duas classes diferentes dá mapas praticamente idênticos (a diferença é da ordem de 10^{-4}). A explicação mostra a imagem, e não a decisão.

p. 2 §1 Introdução

"The paper focuses on modified BP methods, as other attribution methods do not suffer from the converges problem. They either rely on the gradient directly [...], which does not converge or consider the model as a black-box (Ribeiro et al., 2016; Lundberg & Lee, 2017)."
TRADUÇÃO: "O artigo se concentra nos métodos de retropropagação modificada, pois os outros métodos de atribuição não sofrem do problema da convergência. Eles ou se baseiam diretamente no gradiente [...], que não converge, ou tratam o modelo como caixa-preta (Ribeiro et al., 2016; Lundberg & Lee, 2017)."

EXPLICAÇÃO

O GradientSHAP (Lundberg & Lee, 2017) combina as duas coisas: usa o gradiente e vem da família SHAP. Pela teoria do artigo, ele não deveria ser insensível à classe. O teste, no TCC, verifica isso na prática e procura o outro motivo possível (o fator $x - x'$, seção 3).

p. 2 §1 Introdução

"Our findings show that many modified BP methods are prone to class-insensitive explanations and provide saliency maps that rather highlight low-level features."
TRADUÇÃO: "Nossos resultados mostram que muitos métodos de retropropagação modificada tendem a dar explicações insensíveis à classe e produzem mapas que destacam sobretudo características de baixo nível."

EXPLICAÇÃO

"Características de baixo nível" são bordas e contornos na imagem. No ECG, o equivalente seriam os trechos de maior amplitude, como o QRS. Um mapa que sempre destaca o QRS, seja qual for a classe, estaria nessa situação.

p. 3 §2.2 LRP_z

"LRPz can be considered a gradient-based and not a modified BP method. The gradient is not converging to a rank-1 matrix and therefore gradient⊙input is also not converging."
TRADUÇÃO: "O LRP_z pode ser considerado um método baseado no gradiente, e não de retropropagação modificada. O gradiente não converge para uma matriz de posto 1 e, portanto, o gradiente⊙entrada também não converge."

EXPLICAÇÃO

O GradientSHAP é uma média de gradiente $\odot$ (entrada $-$ baseline). O artigo garante que esse tipo de método não sofre a convergência para o posto 1, mas não diz que ele seja específico da classe por outros motivos. Essa é a lacuna que o teste no TCC cobre.

p. 5 §3 Avaliação

"Random Logit: We display the difference of saliency maps explaining the ground-truth and a random logit in Figure 4a. As the logit value is responsible for the predicted class, the saliency maps should change. We use the SSIM metric (Wang et al., 2004) as in (Adebayo et al., 2018)."
TRADUÇÃO: "Random Logit: mostramos a diferença entre os mapas que explicam o logit verdadeiro e um logit sorteado na Figura 4a. Como o logit é o responsável pela classe predita, os mapas deveriam mudar. Usamos a medida SSIM (Wang et al., 2004), como em Adebayo et al. (2018)."

EXPLICAÇÃO

É a definição completa do teste no artigo: um parágrafo, sem fórmula própria. Os elementos são o logit verdadeiro, um logit sorteado entre os demais e uma medida de semelhança entre os dois mapas. A SSIM (*structural similarity*) é uma medida de semelhança de imagens, que compara janelas vizinhas de pixels; vai até 1 (imagens iguais).

p. 5 §3 Avaliação, configuração

"All results were computed on 200 images from the validation set. To justify the sample size, we show bootstrap confidence intervals in Figure 4b."
TRADUÇÃO: "Todos os resultados foram calculados em 200 imagens do conjunto de validação. Para justificar o tamanho da amostra, mostramos intervalos de confiança por *bootstrap* na Figura 4b."

EXPLICAÇÃO

O artigo usa um logit sorteado por imagem e 200 imagens no total. No TCC, com 622 mapas e só 9 classes, é viável comparar cada mapa com **todas** as outras classes, o que dispensa o sorteio.

p. 6 §4 Resultados e Figura 4

"Our random logit analysis reveals that converging methods produce almost identical saliency maps, independently of the output logit (SSIM very close to 1). The rest of the field (SSIM between 0.4 and 0.8) produces saliency maps different from the ground-truth logit's map (see Figure 4a)."
Tradução: "Nossa análise com logits sorteados revela que os métodos que convergem produzem mapas quase idênticos, independentemente do logit de saída (SSIM muito próxima de 1). O restante (SSIM entre 0,4 e 0,8) produz mapas diferentes do mapa do logit verdadeiro (ver Figura 4a)."

EXPLICAÇÃO

O resultado é uma separação em dois grupos, e não uma escala fina: mapas que não mudam com a classe (SSIM perto de 1) e mapas que mudam (0,4 a 0,8). O artigo não compara a SSIM com nenhuma referência de ruído do método, nem fixa um valor a partir do qual o mapa é "específico".

p. 6 §5 Discussão

"First, it is easy to blame the network for unreasonable explanations – no ground truth exists. Second, MNIST, CIFAR, and ImageNet contain only a single object class per image – not revealing the class insensitivity."
Tradução: "Primeiro, é fácil culpar a rede por explicações sem sentido, pois não existe uma verdade de referência. Segundo, MNIST, CIFAR e ImageNet têm uma única classe de objeto por imagem, o que não revela a insensibilidade à classe."

EXPLICAÇÃO

O ECG multirrótulo é exatamente o caso que o artigo diz faltar: um mesmo exame pode conter evidências de classes diferentes em lugares diferentes (onda P, QRS, segmento ST). Se a explicação for insensível à classe, isso aparece aqui com mais facilidade do que nas bases de imagens.

p. 6 §5 Discussão

"[...] it might not be too problematic for some applications if the saliency maps are independent of the later network's layers. For example, to explain Alzheimer's disease [...], local low-level features are sufficient as they are predictive for the disease and the data lacks conflicting evidences (i.e. the whole brain is affected)."
Tradução: "[...] pode não ser tão problemático em algumas aplicações que os mapas independam das camadas finais da rede. Por exemplo, para explicar a doença de Alzheimer [...], características locais de baixo nível bastam, pois são preditivas da doença e os dados não têm evidências conflitantes (isto é, o cérebro inteiro é afetado)."

EXPLICAÇÃO

Os autores dizem que um mapa insensível à classe nem sempre atrapalha. No Alzheimer, a doença afeta o cérebro inteiro: qualquer região que o mapa destaque é evidência da doença, então um mapa que destaca sempre as mesmas regiões, seja qual for a pergunta, ainda é útil. Não há "evidências conflitantes", isto é, regiões que indiquem uma resposta e regiões que indiquem outra. O ECG é o caso oposto: cada classe tem a sua evidência num trecho diferente do batimento.

Classes	**Onde está a evidência**
AF, SNR (ritmo)	Onda P e intervalos entre batimentos (região pré-QRS)
BRD, BRE (bloqueios de ramo)	Forma do QRS
STD, STE (desnivelamento de ST)	Segmento ST (região ST-T)

Se o mapa fosse o mesmo para todas as classes, destacaria o mesmo trecho para todas e estaria errado para a maioria delas: um mapa que aponta o QRS serve para BRD, mas não para AF nem para STD. Por isso, no ECG, a insensibilidade à classe seria um problema real, e o teste faz sentido no TCC.

p. 8 §5 Métodos que não convergem

"All here mentioned attribution methods do not converge, as they either rely on the gradient or treat the model as black-box. Only when the BP algorithm is modified, the convergence problem can occur. The here mentioned algorithms might still suffer from other limitations."
TRADUÇÃO: "Nenhum dos métodos aqui mencionados converge, pois eles ou se baseiam no gradiente ou tratam o modelo como caixa-preta. O problema da convergência só pode ocorrer quando o algoritmo de retropropagação é modificado. Os algoritmos aqui mencionados ainda podem sofrer de outras limitações."

EXPLICAÇÃO
A lista inclui SHAP. A última frase é a que importa para o TCC: o GradientSHAP escapa da convergência, mas "pode sofrer de outras limitações". A dependência do fator $x - x'$ (seção 3) é uma delas, e o Random Logit é a forma de medi-la.

PARTE III · APLICAÇÃO AO TCC

8. Versão implementada no TCC

Código: `src/random_logit.py` (commit `3a81dec`). Para cada um dos 622 mapas do modelo B (ECG × classe explicada c, predições corretas do teste):

1. **Mapa de referência de c.** O GradientSHAP é refeito com a configuração dos mapas do TCC (`src/gshap.py`: referência balanceada de 36 ECGs, 200 sorteios, desvio do ruído 0,09; na versão 1, 32 ECGs sorteados do treino e 50 sorteios) e com a semente fixa daquele mapa, a mesma da sensibilidade. O mapa de referência é, portanto, o mesmo usado na Max/Avg-Sensitivity.
2. **Mapas das outras 8 classes.** O mesmo ECG é explicado para cada uma das outras classes c', com a **mesma semente**: os sorteios internos do GradientSHAP (baselines, ponto no caminho e ruído) são idênticos, e a diferença entre os mapas vem só da classe explicada.
3. **Distância** ℓ_2 entre os dois mapas normalizados para norma 1, nas **36 regiões do batimento** (principal) e ponto a ponto (referência), como na sensibilidade. Vai de 0 (mapas iguais) a 2 (mapas opostos). A distância se relaciona com o cosseno entre os mapas por $\cos = 1 - d^2/2$: $d = \sqrt{2} \approx 1{,}41$ corresponde a mapas sem relação (cosseno 0), e $d > 1{,}41$, a mapas que tendem a ter sinais opostos nas mesmas regiões.
4. **Classes ausentes e presentes.** O resultado principal usa as classes c' **ausentes** nos rótulos do ECG (4 886 pares). As **presentes** (90 pares, de ECGs com mais de um diagnóstico) são analisadas à parte.
5. **Piso:** distância entre a referência e outro mapa de c com outra semente (variação própria do método). Uma distância entre classes só indica especificidade se passar do piso.
6. **Por mapa:** distância média às classes ausentes, menor distância (classe ausente mais parecida), razão entre a distância média e o piso e fração dos pares acima do piso. **Por classe:** média sobre os mapas. Como diagnóstico, uma matriz 9×9 com a distância média entre o mapa da classe explicada (linha) e o de cada outra classe (coluna).

São $1 + 1 + 8 = 10$ execuções do GradientSHAP por mapa (referência, piso e as 8 outras classes), $10 \times 622 = 6\,220$ no total.

9. Aderência ao artigo

Aspecto	Artigo	Versão do TCC	Aderente?
Ideia	Comparar o mapa do logit verdadeiro com o de outro logit (p. 5)	Igual	Sim
Outra classe	Um logit sorteado entre os demais (p. 5)	Todas as 8 outras; ausentes como resultado principal	Sim, ampliado
Medida	SSIM entre imagens (p. 5)	Distância ℓ_2 com norma 1 nas 36 regiões	Adaptado
Referência de ruído	Nenhuma	Piso do GradientSHAP	Acréscimo do TCC
Semente	Não discutida	A mesma nos dois mapas	Escolha do TCC
Amostra	200 imagens (p. 5)	622 mapas	Sim

Por que não SSIM. A SSIM compara janelas vizinhas de pixels de uma imagem. No ECG, "vizinhos" no arranjo $12 \times 15\,000$ incluem derivações diferentes, e o trecho de preenchimento entraria na comparação. A distância ℓ_2 com norma 1 nas 36 regiões é a mesma usada na sensibilidade, o que torna o piso diretamente comparável.

Por que todas as classes. O artigo sorteia um logit por imagem porque tem 1 000 classes. Com 9, comparar com todas custa pouco (cerca de 70 min na T4 com 50 sorteios; 4,4 h com 200) e elimina a variação do sorteio.

10. Diagnóstico

Antes da execução completa, um diagnóstico na CPU explicou 3 ECGs (2 de SNR e 1 de AF) para todas as classes. Ele foi interrompido nesse ponto, mas os 3 ECGs já mostraram o padrão: piso entre 0,33 e 0,45 e distância às outras classes entre 0,95 e 1,85, quase sempre entre 1,4 e 1,7, em todos os pares. Também mostraram que, ao comparar com um mapa de outra classe gerado com outra semente (o que o Quantus faria), o resultado praticamente não muda, porque a diferença entre classes é muito maior que o ruído do método. A mesma semente foi mantida por ser a forma correta de isolar o efeito da classe.

11. Resultados

Duas execuções. A primeira usou os mapas da versão 1: referência de 32 ECGs sorteados do treino e 50 sorteios (Kaggle, versão 20 do `shap-ecg-arrhythmia-runner`, 23/10/2026, 68 min; resultados em `results/modeloB_rlogit/`). Desde 26/10/2026 o TCC usa a versão 2 dos mapas, a opção D do documento `fichamentos/verificacao-referencia-gradientshap`: referência balanceada, com 4 ECGs de rótulo único de cada uma das 9 classes (36), e 200 sorteios por mapa. O Random Logit foi refeito com essa configuração (versão 23 do runner, 26/10/2026, 264 min, dataset `arthurso/shap-ecg-modelob-v2`; resultados em `results/modeloB_v2/rlogit/`). Nas duas execuções não houve erro nem valor indefinido. As tabelas abaixo são da versão 2; a versão 1 aparece só para comparação.

11.1. Por classe

Classes ordenadas da explicação mais específica (maior distância às classes ausentes) para a menos específica. "Cosseno" é o cosseno médio entre os mapas (0 = sem relação; negativo = sinais opostos). "Mín." é a distância média à classe ausente mais parecida. "Razão" é a distância dividida pelo piso do próprio mapa, em média. As duas últimas colunas são a distância e a posição da classe com os mapas da versão 1.

Classe	Mapas	Distância	Cosseno	Mín.	Piso	Razão	F1	Pos. F1	Dist. v1	Pos. v1
AF	108	1,687	−0,44	1,42	0,19	9,6	0,931	1.º	1,667	1.º
BRD	172	1,633	−0,35	1,35	0,13	13,2	0,927	2.º	1,586	4.º
CVP	59	1,627	−0,35	1,26	0,17	11,0	0,837	5.º	1,620	2.º
BRE	20	1,622	−0,33	1,33	0,13	12,8	0,870	4.º	1,617	3.º
IAVB	61	1,607	−0,32	1,31	0,18	9,8	0,884	3.º	1,585	5.º
CAP	45	1,578	−0,26	1,27	0,25	6,7	0,750	8.º	1,578	6.º
STD	65	1,483	−0,13	1,16	0,23	7,0	0,778	7.º	1,485	7.º
SNR	78	1,479	−0,12	1,18	0,23	6,8	0,796	6.º	1,472	8.º
STE	14	1,427	−0,05	1,02	0,18	8,6	0,596	9.º	1,397	9.º
Global	622	1,595	−0,30	1,29	0,18	10,0	0,819	—	1,574	—

Resultado principal
As explicações do GradientSHAP são específicas da classe. Em todas as classes, a distância entre o mapa da classe explicada e o de uma classe ausente fica entre 6,7 e 13,2 vezes o piso, e **todos** os 4 886 pares ausentes estão acima do piso do próprio mapa. Mesmo a classe ausente mais parecida fica, em média, a 1,29, cerca de 7 vezes o piso. O GradientSHAP não sofre a insensibilidade à classe descrita por Sixt et al., como a teoria do artigo previa para métodos baseados no gradiente, e o fator (ECG − baseline), comum a todas as classes, não domina os mapas.

O que mudou em relação à versão 1. As distâncias entre classes quase não mudaram (média global de 1,574 para 1,595; nenhuma classe mudou mais de 0,05). O piso caiu pela metade (0,36 → 0,18), como esperado com quatro vezes mais sorteios. Por isso a razão dobrou (5,0 → 10,0), e o único par que ficava abaixo do piso na versão 1 passou a ficar acima. A especificidade, portanto, é uma propriedade das explicações, e não do ruído do método: a distância entre classes é a mesma com pouco ou muito ruído.

Leitura descritiva frente ao F1. As pontas coincidem: AF, a classe de maior F1, tem as explicações mais específicas, e STE, a de menor F1, as menos específicas. STD e SNR, 7.º e 6.º no F1, estão entre as três menos específicas. Com os mapas da versão 2, a concordância no topo também ficou maior: BRD, 2.ª no F1, subiu da 4.ª para a 2.ª posição, e as cinco classes de maior F1 (AF, BRD, IAVB, BRE e CVP) ocupam as cinco primeiras posições, embora em outra ordem entre si. As diferenças entre os extremos (1,69 em AF contra 1,43 em STE) são várias vezes o desvio dentro de cada classe (0,06 a 0,11), então a separação das pontas é real. As do meio (1,58 a 1,63) não são: a troca de posições entre BRD, CVP, BRE e IAVB de uma versão para outra mostra que essa ordem não é estável. STE tem só 14 mapas e BRE, 20.

11.2. Verificação: a distância vem do sinal oposto dos mapas?

A distância média (1,60) é maior que $\sqrt{2}$, e o cosseno médio é negativo (−0,30): o mapa da classe ausente tende a ter sinal oposto ao da classe explicada nas mesmas regiões. Há uma razão mecânica para isso. A soma de um mapa do GradientSHAP acompanha a saída do modelo para o ECG menos a saída média para as baselines. Para a classe explicada, presente no ECG, essa diferença é positiva; para uma classe ausente, costuma ser negativa (o ECG tem menos daquela classe que a média das baselines). Mapas com somas de sinais opostos tendem a ter cosseno negativo sem que isso diga algo sobre *onde* eles olham. Uma inversão completa do mapa (mesmas regiões, sinal trocado) contaria como distância máxima, embora destaque as mesmas regiões.

Para separar os dois efeitos, a soma esperada de cada mapa de classe ausente foi calculada com a saída do modelo no ECG e a saída média nos 36 ECGs da referência (diagnóstico):

Pares de classes ausentes	Pares	Cosseno médio	Distância média
Soma esperada de c' negativa (sinal oposto)	3 824 (78%)	−0,34	1,63
Soma esperada de c' positiva (mesmo sinal)	1 062 (22%)	−0,12	1,48

- **O sinal oposto explica parte do cosseno negativo**, mas não a especificidade: mesmo quando

os dois mapas têm somas do mesmo sinal, a distância é 1,48, cerca de 8 vezes o piso, e o cosseno fica perto de 0. Os mapas apontam para **regiões diferentes**, e não apenas para as mesmas regiões com sinal trocado.

- **Inversões completas e mapas muito parecidos são raros:** só 2,6% dos pares têm cosseno abaixo de −0,8, e 1,1% acima de 0,5.
- **As pontas da ordem se mantêm** nos pares de mesmo sinal: AF (−0,24) e BRD (−0,21) continuam as mais específicas, e STD (−0,02) e STE (+0,03), as menos.
- A fração de pares com sinal oposto muda com a referência (71% na versão 1, 78% na versão 2), porque a soma esperada depende da saída média do modelo nos ECGs da referência. Por exemplo, a saída média de BRD cai de −3,4 para −9,6, já que a referência antiga tinha 14 ECGs de BRD e a nova tem 4. A conclusão do teste é a mesma nas duas versões.

Uma verificação direta, com a distância entre os valores absolutos dos mapas, exigiria guardar os vetores das 36 regiões de cada par, o que as execuções não fizeram. A verificação equivalente foi feita no eMPRT (`fichamentos/hedstrom-2023-emprt/main.pdf`), comparando o mapa do modelo treinado com o de um modelo de pesos sorteados: só nas magnitudes, os dois ficam a 5,8 vezes o piso, e a fração de mapas com as 2 regiões principais no QRS varia por classe com o modelo treinado (95% em BRE, 2% em IAVB) e fica entre 76% e 92% em todas as classes com o modelo aleatório. O fator (ECG − referência) concentra o mapa no QRS quando o modelo não aprendeu nada, mas não domina os mapas do modelo treinado.

11.3. Classes presentes no mesmo ECG

Nos 90 pares em que c' também está nos rótulos do ECG, a distância média é 1,36, menor que nos pares ausentes (1,60), como esperado: duas classes presentes podem usar parte da mesma evidência. As distâncias mais baixas aparecem quando a classe explicada é STE (1,11) ou STD (1,19). Com tão poucos pares por combinação (de 5 a 29 por classe explicada), esses números servem só como indicação.

11.4. Quais classes têm explicações parecidas (matriz)

A classe ausente mais parecida com cada classe explicada (fração dos mapas):

Classe explicada	Classe ausente mais parecida (versão 2)	Versão 1
AF	STD (27%), BRD (26%), CVP (22%)	STD (39%), CAP (19%), CVP (15%)
BRD	STE (31%), AF (27%), BRE (15%)	STE (31%), AF (19%), BRE (19%)
BRE	CVP (35%), IAVB (20%), STE (20%)	CVP (35%), STE (20%), CAP (15%)
CAP	AF (36%), CVP (31%), SNR (11%)	AF (42%), SNR (13%), CVP (13%)
CVP	BRE (58%), BRD (20%), STD (10%)	BRE (69%), STD (10%), AF (8%)
IAVB	BRE (61%), STE (15%), BRD (13%)	BRE (64%), STE (15%), STD (11%)
SNR	STE (28%), BRE (22%), CVP (17%)	BRE (28%), STE (26%), CAP (14%)
STD	BRE (37%), IAVB (25%), BRD (14%)	BRE (58%), IAVB (15%), CVP (8%)
STE	BRD (57%), BRE (21%), CVP (7%)	BRE (50%), CVP (21%), BRD (21%)

O par mais próximo da matriz é agora STE com BRD (distância média 1,05), seguido de STE com BRE (1,23) e STD com BRE (1,26). Duas observações:

(i) **BRE perdeu parte do papel de "classe mais parecida".** Na versão 1, o mapa de BRE era o mais parecido para cinco das nove classes (30% de todos os mapas), e uma das hipóteses era a ausência de BRE na referência (BRE é rara no treino, 3,4%, e não estava entre as 32 baselines sorteadas). Com 4 ECGs de BRE na referência, BRE continua a mais parecida para três classes (CVP, IAVB e STD), mas para 23% dos mapas, e com frações menores em cada classe. A composição da referência explica, portanto, parte do efeito, mas não todo: CVP e IAVB continuam com mais da metade dos mapas mais próximos de BRE.

(ii) **STE se aproxima dos bloqueios de ramo** (BRD e BRE) nas duas versões, agora mais de BRD. Isso é coerente com o fato clínico de que bloqueios de ramo alteram o segmento ST, mas essa leitura não é avaliada no TCC.

11.5. Relação com as outras métricas (diagnóstico)

Mapa a mapa, a distância às classes ausentes tem correlação de postos de $-0{,}46$ com o número efetivo de regiões (mapas mais concentrados são mais específicos), $-0{,}47$ com o piso (mapas com mais erro de estimativa são menos específicos) e 0,44 com o logit da classe explicada (predições mais confiantes, explicações mais específicas). Na versão 1, os valores eram $-0{,}38$, $-0{,}36$ e 0,41. São relações moderadas, usadas aqui só como diagnóstico: o Random Logit não repete nenhuma das outras métricas, mas conversa com a complexidade e com o piso. STD e SNR, duas das três classes menos específicas, são também das explicações mais espalhadas e têm piso alto; STE, a menos específica, tem complexidade intermediária.

11.6. O que se conclui

1. O GradientSHAP produz explicações **específicas da classe** no modelo B: a pergunta da seleção de métricas ("o mapa de BRD é diferente do de outra classe no mesmo ECG?") tem resposta positiva para todas as classes, nas duas versões dos mapas.
2. A especificidade varia entre classes, e as pontas acompanham o F1 (AF mais específica, STE menos; STD e SNR também embaixo). No meio, a ordem não é estável entre as versões. A ordem não repete a de nenhuma métrica anterior: AF, por exemplo, tem uma das menores Faithfulness Estimate (7.ª de 9) e é a classe mais específica.
3. Trocar a referência e quadruplicar os sorteios mantém as distâncias entre classes e corta o piso pela metade. A conclusão principal fica mais forte, e não muda.

12. Versão do Quantus e por que não foi usada

A `quantus.RandomLogit` (Quantus 0.6.0) nunca entrou no pipeline do TCC. Ela sorteia, para cada exemplo, uma classe diferente da explicada (entre todas, sem olhar os rótulos do ECG), gera o mapa dessa classe com uma nova chamada da função de explicação e compara com o mapa salvo usando SSIM sobre o mapa achatado. No ECG, isso traria três problemas: (i) o mapa salvo e o mapa novo viriam de sorteios diferentes do GradientSHAP, e a diferença incluiria o piso inteiro (0,18 com os mapas da versão 2; 0,36 com os da versão 1); (ii) a SSIM sobre os 180 000 pontos, com o preenchimento, compara janelas que misturam derivações; (iii) a classe sorteada poderia estar presente no ECG. A versão própria resolve os três: mesma semente nos dois mapas, distância nas 36 regiões e classes ausentes separadas das presentes.