Verificação da referência do GradientSHAP

ECGs normais como baselines e 200 sorteios

Código: `src/baseline_check.py` **Resultados:** `results/modeloB_basecheck/`

Aluno: Arthur Santos de Oliveira (RA: 156297)

Atualizado em: 25/10/2026

Repositório: https://github.com/Arthur-so/shap-ecg-arrhythmia

---

Por que este documento. Ao estudar a complexidade e o Random Logit, surgiram duas dúvidas sobre a forma como os mapas SHAP do TCC são gerados: (1) os ECGs de referência usados pelo GradientSHAP (as **baselines**) são uma mistura de arritmias sorteada do treino, quando clinicamente a referência natural seria o ECG **normal**; (2) cada mapa é a média de só **50 sorteios**, e o erro dessa média (o **piso**) é grande. Este documento descreve um teste que mede o peso das duas escolhas e termina com as opções de decisão.

Como ler. A **Parte I** explica o que é a referência e por que ela importa; a **Parte II** descreve o teste; a **Parte III** traz os resultados; a **Parte IV**, as opções para a decisão. Todos os números são médias sobre os 622 mapas do modelo B (predições corretas do teste) e usam as 36 regiões do batimento (12 derivações × pré-QRS, QRS e ST-T), como as demais métricas do TCC.

Resumo

- **200 sorteios cortam o erro pela metade.** O piso (distância entre dois mapas que só diferem nos sorteios) cai de 0,33 para 0,17, como prevê a estatística de uma média.
- **A referência normal muda os mapas, mas moderadamente.** Fora SNR, o mapa com referência normal e 200 sorteios tem cosseno médio de 0,92 com o mapa atual. Trocar só o sorteio das 32 baselines por outro aleatório já muda o mapa quase tanto.
- **Com a referência normal, a classe SNR perde o sentido:** explicar um ECG normal em relação a ECGs normais deixa quase nada a explicar (soma média do mapa −1,5, contra 16,2 hoje).
- **Prévia com os mapas novos:** a Consistency sobe na maioria das classes (global 0,42 → 0,54); a complexidade praticamente não muda.
- **Nada foi trocado.** Os resultados oficiais continuam com os mapas atuais. A decisão de adotar a nova referência é do aluno com o orientador (Parte IV).

PARTE I · A REFERÊNCIA DO GRADIENTSHAP

1. O que é a referência

O GradientSHAP não explica a saída do modelo "em absoluto". Ele explica a **diferença** entre a saída para o ECG e a saída média para um conjunto de ECGs de referência, as **baselines**. A soma de todas as importâncias do mapa é, aproximadamente,

$$\text{soma do mapa} \approx f_c(\text{ECG}) - \text{média de } f_c(\text{baselines}),$$

em que f_c é o logit da classe explicada c. Cada importância vem de termos do tipo gradiente × (ECG − baseline). Por isso, uma região do ECG que é **parecida** com a mesma região das baselines recebe pouca importância, mesmo que o modelo a use: o fator (ECG − baseline) é pequeno ali.

Consequência
O mapa responde à pergunta: *o que neste ECG difere da referência e leva o modelo à classe c?* Trocar a referência troca a pergunta.

2. As 32 baselines atuais

Em `src/explain.py`, a referência são 32 ECGs sorteados do conjunto de treino (4 812 ECGs), sempre com a semente 42 do projeto. O número 32 é o padrão do código, sem justificativa formal registrada. O sorteio ficou desbalanceado por acaso:

	SNR	**AF**	**IAVB**	**BRE**	**BRD**	**CAP**	**CVP**	**STD**	**STE**
% no treino	13,3	17,8	10,5	3,4	27,1	9,0	10,2	12,7	3,2
Esperado em 32	4,3	5,7	3,3	1,1	8,7	2,9	3,3	4,0	1,0
Nas 32 atuais	2	4	5	**0**	**14**	2	5	1	**0**

Nenhuma baseline é individualmente extrema (duração de 10 a 30 s, amplitude máxima abaixo do percentil 99 do treino), mas BRD está super-representado e BRE e STE estão ausentes.

3. Por que o ECG normal

Referência	**Pergunta que o mapa responde**
Atual: mistura de ECGs do treino	O que neste ECG faz o modelo dar à classe uma saída diferente da que ele dá, em média, aos ECGs do treino (a maioria com alguma arritmia)?
ECGs normais (SNR)	O que neste ECG, em relação a um coração saudável, levou o modelo à classe?

A primeira é o padrão do SHAP (uma amostra dos dados como referência) e não está errada, mas compara a arritmia com outras arritmias. A segunda é mais próxima do raciocínio clínico: uma arritmia se define pelo que a afasta do ritmo normal. A escolha da referência é uma questão conhecida na literatura de explicabilidade (ver, por exemplo, Sturmfels, Lundberg e Lee, 2020, *Visualizing the Impact of Feature Attribution Baselines*, Distill; não fichado).

Um efeito colateral previsto. Com a referência normal, a classe SNR perde o sentido: explicar um ECG normal em relação a ECGs normais deixa a soma do mapa perto de zero, e o mapa vira quase só ruído.

4. Os 50 sorteios e o piso

O GradientSHAP estima o mapa como a média de `n_samples` = 50 termos sorteados (qual baseline, um ponto no caminho entre ela e o ECG e um pequeno ruído). Com outros 50 sorteios, sai um mapa um pouco diferente. O **piso** é a distância entre dois mapas do mesmo ECG e da mesma classe que só diferem nos sorteios; na sensibilidade, foi 0,355. O erro de uma média cai aproximadamente com $1/\sqrt{n}$: com 200 sorteios (4 vezes mais), o piso deveria cair pela metade. A explicação detalhada está na seção 6.2 do fichamento da complexidade (`fichamentos/bhatt-2020-complexity`).

PARTE II · O TESTE

5. Desenho

Para cada um dos 622 mapas (ECG × classe explicada), o GradientSHAP foi refeito em sete versões, todas com a **mesma semente** de sorteios internos, para que as diferenças venham só da referência ou do número de sorteios:

Mapa	Referência (32 ECGs do treino)	Sorteios
atual	a de `explain.py` (semente 42)	50, semente s
atual′	a de `explain.py`	50, semente $s+1$
normal	32 ECGs com rótulo único SNR (semente 42)	50, semente s
normal′	a mesma normal	50, semente $s+1$
aleatória	outro sorteio do treino (semente 43): SNR 6, AF 2, IAVB 6, BRE 1, BRD 7, CAP 3, CVP 2, STD 5, STE 1	50, semente s
normal200	a mesma normal; 4 blocos de 50, o 1.º é o mapa normal	200
normal200′	a mesma normal; 4 blocos a partir de normal′	200

Os 200 sorteios são feitos como média de 4 execuções de 50 com sementes diferentes, o que equivale estatisticamente a uma média de 200 e cabe na memória da GPU. As 32 normais são ECGs do **treino** (nenhum do teste) com rótulo único de SNR; todos os 642 SNR do treino têm rótulo único.

Comparações. Distância ℓ_2 entre os mapas normalizados para norma 1, nas 36 regiões (0 = iguais; 2 = opostos; o cosseno entre os mapas é $1 - d^2/2$):

Comparação	O que mede
atual × atual′	Piso atual (50 sorteios)
atual × aleatória	Quanto muda o mapa só por trocar o sorteio das 32 baselines (controle)
atual × normal	Efeito da referência normal, com 50 sorteios
atual × normal200	Efeito da referência normal, com o mapa normal mais preciso
normal × normal′	Piso com a referência normal, 50 sorteios
normal200 × normal200′	Piso com a referência normal, 200 sorteios

Também foram registradas a soma de cada mapa e a região mais importante. Os mapas normal200 foram salvos para recalcular as métricas sem gerar os mapas de novo.

Execução. Kaggle (GPU T4), versão 21 do runner, 23/10/2026, 72 min (11 execuções de 50 sorteios por mapa, cerca de 6 800 no total). Nenhum erro.

6. Como ler o resultado

- **atual × normal perto do piso:** a referência pesa pouco; basta justificar a escolha no texto.
- **atual × normal bem acima do piso e acima de atual × aleatória:** a referência normal muda a explicação de fato.
- **atual × normal ≈ atual × aleatória, ambos acima do piso:** os mapas dependem de qual conjunto se usa, mas não especificamente de ele ser normal.

PARTE III · RESULTADOS

7. Os sorteios: 200 cortam o piso pela metade

	SNR	AF	IAVB	BRE	BRD	CAP	CVP	STD	STE	Global
Piso atual (50)	0,41	0,35	0,36	0,23	0,32	0,46	0,32	0,40	0,35	0,355
Piso normal (50)	0,51	0,31	0,30	0,30	0,25	0,41	0,29	0,39	0,36	0,331
Piso normal (200)	0,26	0,17	0,15	0,15	0,12	0,21	0,15	0,20	0,15	**0,167**

Com a mesma referência normal, passar de 50 para 200 sorteios reduz o piso de 0,331 para 0,167, quase exatamente a metade prevista ($1/\sqrt{4}$), e em todas as classes. A ordem dos pisos entre as classes se mantém (CAP e STD mais altos; BRD mais baixo), o que confirma que o piso depende de como o modelo responde a cada classe, e não só do número de sorteios.

8. A referência: muda os mapas, mas moderadamente

Classe	Piso atual	Atual × aleatória	Atual × normal (50)	Atual × normal (200)	Cosseno (200)	Acima do piso
SNR	0,41	0,52	0,99	1,01	0,47	99%
AF	0,35	0,37	0,41	0,37	0,92	54%
IAVB	0,36	0,36	0,40	0,37	0,92	56%
BRE	0,23	0,30	0,37	0,32	0,95	75%
BRD	0,32	0,36	0,41	0,39	0,92	81%
CAP	0,46	0,52	0,54	0,49	0,87	67%
CVP	0,32	0,36	0,37	0,34	0,94	64%
STD	0,40	0,46	0,50	0,46	0,89	72%
STE	0,35	0,41	0,44	0,42	0,91	86%
Sem SNR	0,35	0,39	0,43	0,39	0,92	69%

"× normal (200)" é a distância entre o mapa atual e o mapa com referência normal e 200 sorteios; "Acima do piso" é a fração dos mapas em que essa distância passa do piso atual do próprio mapa.

- **A referência normal muda os mapas além do ruído**, em 69% dos mapas (fora SNR). Mas a mudança é moderada: o cosseno médio entre o mapa atual e o novo é 0,92 (1 seria igual). As regiões que importam continuam, em grande parte, as mesmas.
- **Trocar só o sorteio das 32 baselines já muda o mapa quase tanto** (0,39 contra 0,39 com a referência normal e 200 sorteios, fora SNR). Ou seja, os mapas atuais dependem de qual conjunto de referência foi sorteado; a referência normal não muda os mapas muito mais do que outro sorteio qualquer.
- **Parte da distância é ruído do próprio mapa atual.** Mesmo um mapa normal perfeito ficaria a cerca de 0,25 do mapa atual só pelo erro dos 50 sorteios do mapa atual (piso $\div\sqrt{2}$). O efeito da referência em si é, portanto, menor do que os 0,39 sugerem.

8.1. Região mais importante

Fração dos mapas em que a região mais importante é a mesma no mapa atual e no mapa normal (200): 66% no global; 92% em BRD, 76% em CVP, 65 a 67% em AF, IAVB e BRE, 57% em STE, 45 a 47% em STD e CAP, e 29% em SNR. Alguns deslocamentos:

Classe	Referência atual	Referência normal (200)
BRD	V1 QRS (85%)	V1 QRS (91%)
IAVB	aVR pré-QRS (62%), II pré-QRS (13%)	aVR pré-QRS (52%), II pré-QRS (33%)
STD	aVR ST-T (37%), II ST-T (11%)	II ST-T (26%), aVR ST-T (17%)
STE	aVR pré-QRS (57%), V1 QRS (21%)	aVR pré-QRS (29%), V2 pré-QRS (21%)

Esses deslocamentos são registrados como observação; a plausibilidade clínica das regiões não é avaliada no TCC.

8.2. Soma dos mapas

	SNR	AF	IAVB	BRE	BRD	CAP	CVP	STD	STE
Atual	16,2	15,9	16,9	21,4	11,2	12,9	13,5	13,3	12,9
Normal (200)	−1,5	16,5	17,6	20,3	**18,6**	11,9	15,8	14,3	12,3

- **SNR:** a soma vai a −1,5, ou seja, quase nada a explicar, como previsto. Com a referência normal, os mapas de SNR não são interpretáveis (a distância ao mapa atual, perto de 1, e a baixa coincidência da região principal confirmam isso).

- **BRD:** a soma sobe de 11,2 para 18,6. É o efeito esperado do desbalanceamento: 14 das 32 baselines atuais têm BRD, então a saída média de BRD na referência atual é alta e sobra menos diferença para explicar. Com a referência normal, a explicação de BRD passa a cobrir toda a evidência de BRD.
- Nas demais classes, a soma muda pouco.

9. Prévia das métricas com os mapas novos

Os mapas normal200 permitem recalcular, sem GPU, as métricas que não chamam o modelo. Nesta prévia mudam **duas coisas ao mesmo tempo** (referência e número de sorteios), então os efeitos não podem ser separados.

	SNR	**AF**	**IAVB**	**BRE**	**BRD**	**CAP**	**CVP**	**STD**	**STE**	**Global**
Consistency atual	0,21	0,42	0,45	0,25	0,64	0,14	0,26	0,51	0,03	0,42
Consistency nova	(0,58)	0,47	0,59	0,35	0,76	0,16	0,50	0,45	0,03	0,54
Complexidade atual	26,9	22,8	23,3	25,8	22,4	25,7	24,7	26,9	25,5	24,2
Complexidade nova	(25,7)	22,8	22,6	26,2	23,1	25,7	24,8	27,4	25,6	24,3

Consistency com $k = 2$ (valor observado); complexidade em número efetivo de regiões (de 36). Os valores de SNR estão entre parênteses porque, com a referência normal, não são interpretáveis.

- **Consistency:** sobe na maioria das classes (CVP 0,26 → 0,50; IAVB 0,45 → 0,59; BRD 0,64 → 0,76), cai em STD (0,51 → 0,45) e não muda em CAP e STE, que continuam as menos consistentes. É coerente com o que se esperava: com menos ruído, o par das 2 regiões principais se repete mais entre ECGs da mesma classe.
- **Complexidade:** praticamente igual (24,2 → 24,3 no global); as classes mais concentradas continuam AF, BRD e IAVB, e a mais espalhada, STD.
- As métricas que chamam o modelo (Faithfulness Correlation e Estimate, Max/Avg-Sensitivity, Random Logit) não foram recalculadas.

10. Limitações do teste

- Só uma referência normal (um sorteio de 32 SNR) foi testada; outro sorteio de normais também mudaria os mapas, como mostrou o controle aleatório.
- Não foi gerado o mapa com a referência **atual** e 200 sorteios, que separaria o efeito dos sorteios do efeito da referência nas métricas.
- A hipótese levantada no Random Logit (o mapa de BRE parece com o de muitas classes porque BRE não está nas baselines) não pode ser testada sem refazer o Random Logit com a nova referência.

PARTE IV · DECISÃO

11. Opções

	A. Manter	**B. Referência normal + 200 sorteios**	**C. Referência atual + 200 sorteios**
O que muda	Nada	Referência e sorteios	Só os sorteios
Pergunta do mapa	Diferença em relação à média do treino (mistura de arritmias)	Diferença em relação a um coração saudável	Igual à atual
Ruído (piso)	0,355	cerca de 0,17	cerca de 0,17 (esperado)
SNR	Normal	Sem sentido; precisa de tratamento à parte	Normal
Custo	Nenhum	Mapas já gerados; refazer FaithCorr e FaithEst (cerca de 30 min cada), sensibilidade (cerca de 5,5 h) e Random Logit (cerca de 4,5 h) e revisar os textos	Gerar os mapas (cerca de 30 min) e refazer as mesmas métricas, com o mesmo custo
Defesa no texto	Justificar a mistura como padrão do SHAP e citar o teste	Mais natural clinicamente; citar o teste	Reduz o ruído sem mudar a pergunta

Tratamento de SNR na opção B. Duas saídas possíveis: (i) explicar SNR com a referência atual e as demais classes com a normal, o que mistura duas perguntas na mesma tabela; ou (ii) tirar SNR das métricas de explicação e explicar no texto por quê (a classe é a própria referência). A comparação com o F1 passaria a ter 8 classes.

> **Leitura do teste para a decisão**
> Os resultados indicam que as conclusões principais do TCC tendem a se manter com qualquer das opções: os mapas mudam moderadamente (cosseno de 0,92), a complexidade não muda e a Consistency sobe sem trocar as classes das pontas (BRD no topo; CAP e STE na base). O que a opção B oferece é uma pergunta mais natural (o que afasta o ECG do normal) e metade do ruído; o que ela custa é o tratamento de SNR e refazer as métricas que chamam o modelo. A opção C reduz o ruído sem mudar a pergunta nem afetar SNR. Em B e C, o custo maior vem da sensibilidade e do Random Logit, que refazem o GradientSHAP e, com 200 sorteios, ficam cerca de 4 vezes mais lentos (cerca de 10 h de Kaggle no total, em execuções separadas); reduzir o número de perturbações da sensibilidade ou de classes do Random Logit diminuiria esse custo.

Para levar ao orientador: qual referência usar (A, B ou C); se B, como tratar SNR; e se o número de sorteios passa a 200 (B ou C), sabendo que as métricas que dependem do piso (Consistency, sensibilidade, Random Logit) ficam mais precisas.

Arquivos: `src/baseline_check.py` (commit `c3e5420`); `results/modeloB_basecheck/` (`baseline_check.csv` por classe, `baseline_check_mapas.csv` por mapa, `previa_normal200/` com a Consistency e a complexidade recalculadas); mapas normal200 fora do git, em `output/modeloB_normal200/`.