

Relatório de Status do TCC

Avaliação das Explicações SHAP em Redes Neurais Profundas para Classificação de Arritmias Cardíacas em ECG

Aluno: Arthur Santos de Oliveira (RA: 156297)

Orientador: Prof. Dr. Luis Augusto Martins Pereira

Período: 30/09/2026 a 09/10/2026

Repositório: <https://github.com/Arthur-so/shap-ecg-arrhythmia>

1. Resumo do período

- Leitura do artigo que define as métricas *Consistency* e *Sufficiency* (Dasgupta, Frost e Moshkovitz, 2022) e análise do que se aplica a explicações SHAP de ECG.
- *Sufficiency* retirada da análise, por não ter definição no artigo para métodos de importância de atributos.
- Identificação de um defeito na *Consistency* do Quantus e implementação própria da métrica, fiel ao artigo e adaptada ao ECG.
- Correção de uma falha de rotulagem que deixava a classe CVP sem nenhuma amostra.
- Alinhamento do treino ao protocolo do artigo base (Zhang et al., 2021): F1-macro no teste passou de 0,641 para **0,819** (artigo: 0,813).
- Geração das explicações SHAP do novo modelo, cálculo da *Consistency* e primeiras conclusões.

2. Leitura de Dasgupta et al. (2022): o que se aplica ao trabalho

O artigo define a fidelidade de uma explicação ao modelo por meio de duas propriedades complementares:

- **Consistency:** instâncias que recebem a *mesma explicação* devem receber a mesma predição.
- **Sufficiency:** se a propriedade apontada pela explicação de x também está presente em outra instância x' , então x' deve receber a mesma predição, mesmo que a explicação de x' seja outra.

O que se aplica. A *Consistency* se aplica a mapas SHAP desde que eles sejam *discretizados*: mapas contínuos de 12×15000 valores nunca se repetem, e o artigo propõe reduzi-los a uma representação simplificada (por exemplo, o sinal dos atributos de maior importância) antes de comparar (p. 11 e Apêndice D.5).

Por que a *Sufficiency* foi retirada. Os próprios autores afirmam que, para métodos de importância de atributos (SHAP, LIME, gradiente), não está claro quando uma explicação “se aplica” a outra instância, e por isso analisam apenas a *Consistency* nesses métodos (p. 8). A versão do Quantus contorna isso comparando mapa com mapa por distância, o que na prática é uma *Consistency* relaxada, e não a *Sufficiency* do artigo. Por não ter base na definição original, a métrica foi deixada de fora.

3. Consistency: defeito no Quantus e implementação própria

Defeito encontrado. A discretização padrão da `quantus.Consistency` (v0.6.0) toma o sinal dos 5 *primeiros* valores do mapa, e não dos 5 mais importantes, depois de aplicar valor absoluto. Nos mapas do projeto, isso produziu **a mesma explicação para todos os ECGs**, em todas as classes (verificado nos mapas). A métrica passava a medir só a homogeneidade das predições dentro de cada classe, e por isso acompanhava o F1 de forma mecânica.

Implementação própria (`src/consistency.py`), seguindo a definição e o estimador do artigo:

1. **Regiões do batimento:** o ECG tem 12 derivações, registradas ao mesmo tempo, e o mapa SHAP tem um valor para cada derivação e cada instante. Os picos R (o pico do complexo QRS

de cada batimento) são localizados em uma das derivações, a derivação II, com a biblioteca NeuroKit2. Como as 12 derivações são simultâneas, os mesmos instantes valem para todas elas. Cada batimento (o trecho entre dois picos R consecutivos) é então dividido em três regiões (Figura 1): **QRS** (de 80 ms antes a 100 ms depois do R), **ST-T** (do fim do QRS até 45% do intervalo RR) e **pré-QRS** (o restante, que contém a onda P e o intervalo PR). O trecho de preenchimento (*padding*) é excluído. A localização exata de P, QRS e T foi testada e descartada, porque falhou justamente nas classes de interesse (“onda P” detectada na fibrilação atrial e QRS largo não detectado nos bloqueios de ramo).

2. **Resumo do mapa:** a atribuição SHAP é somada por derivação $\times$ região, o que dá 36 valores por mapa.
3. **Discretização:** dos 36 valores, mantêm-se apenas as k regiões de maior importância em valor absoluto, junto com o sinal de cada uma (+ quando a região contribui a favor da classe explicada, – quando contribui contra). O parâmetro k é, portanto, **quantas regiões compõem a explicação**. Com $k = 2$, a explicação de um ECG é o par das duas regiões mais importantes, por exemplo “V1 · QRS (+) e V2 · QRS (+)”; dois ECGs têm a mesma explicação quando coincidem essas duas regiões e seus sinais. É o análogo ao *Sign-of-top-5* do artigo, que usa os 5 atributos mais importantes. A escolha de k é um compromisso: k pequeno gera explicações pobres, que se repetem entre classes diferentes; k grande gera explicações tão específicas que muitos mapas ficam sem nenhum outro igual e não podem ser avaliados (o estimador do artigo lhes atribui 0). Foi usado $k = 2$ e, para comparação, $k = 1$ e $k = 3$ (seção 5).
4. **Estimador:** todos os mapas, de todas as classes, são agrupados pela explicação discretizada. Para cada mapa, calcula-se a fração dos *outros* mapas do seu grupo que explicam a mesma classe que ele. Por exemplo, se um mapa de BRD tem a explicação “V1 · QRS (+) e V2 · QRS (+)” e outros 10 mapas têm essa mesma explicação, dos quais 8 são de BRD, o valor desse mapa é $8/10 = 0,8$. Um mapa é **sem par** quando nenhum outro mapa tem a mesma explicação que ele, ou seja, quando está sozinho no seu grupo. Nesse caso não há com o que comparar, e o estimador do artigo lhe atribui 0 (a fidelidade não pode ser verificada). A *Consistency* de uma classe é a média dos valores dos seus mapas.




Figura 1: Trecho de cerca de 1,5 s da derivação II de um ECG normal (SNR), com três picos R marcados (triângulos) e as regiões de cada batimento: QRS (vermelho), ST-T (verde) e pré-QRS (azul). A derivação II é usada apenas para localizar os picos R; as mesmas regiões são aplicadas às 12 derivações.

Conferência do código. Para garantir que a implementação calcula o que deveria, foram feitas duas checagens: (i) antes de escrever o módulo definitivo, a métrica foi calculada com um script provisório; os dois, rodados sobre os mesmos mapas, deram resultados idênticos; (ii) o valor esperado ao acaso, apresentado na seção 5, é obtido por uma fórmula; para conferi-la, as classes foram embaralhadas entre os mapas 3000 vezes, a *Consistency* foi recalculada em cada embaralhamento, e a média coincidiu com a fórmula.

4. Correções e melhoria do classificador

Classe CVP sem amostras. Os registros de extrassístole ventricular usam o código SNOMED 164884008, que não estava no mapeamento de rótulos. Com isso, 607 registros ficavam sem rótulo e entravam no treino como “nenhuma classe”. O código foi adicionado, e todos os 6877 registros passaram a ter rótulo.

F1 abaixo do artigo base. O código foi comparado com o artigo e com a implementação pública dos autores, e foram corrigidos: taxa de aprendizado ($1e-3 \rightarrow 1e-4$), kernel dos blocos residuais ($3 \rightarrow 7$), *pooling* final (média $\rightarrow$ média + máximo), aumento de dados (escala e deslocamento de linha de base) e **limiar de decisão por classe** otimizado no F1 da validação.

Ablação da função de perda. A BCE ponderada por classe (prevista na proposta) foi comparada com a BCE simples (usada pelos autores), em 60 épocas. Os resultados foram equivalentes (Tabela 1), e adotou-se a **BCE simples**, por ser mais fiel à referência, gerar probabilidades mais bem calibradas e convergir mais rápido. *Esta é uma mudança em relação à seção 4.2 da proposta.*

Tabela 1: Evolução do F1-macro no conjunto de teste.

Versão	O que mudou	F1 teste
Run 1	Classe CVP sem rótulo; lr $1e-3$, kernel 3, limiar 0,5	0,590
Run 2	CVP corrigida	0,641
Run 3	Treino alinhado ao artigo, BCE ponderada, 40 épocas	0,803
A	Run 3 com 60 épocas, BCE ponderada	0,816
B (escolhido)	Run 3 com 60 épocas, BCE simples	0,819
Zhang et al. (2021)	Média de 10 <i>folds</i>	0,813

5. Resultados da Consistency (modelo B)

Foram geradas explicações GradientSHAP para as 622 predições corretas do teste. A *Consistency* global foi **0,42**, contra 0,13 esperado ao acaso. A Tabela 2 mostra os valores por classe, e a Figura 2, a comparação com o F1.

Valor esperado ao acaso. É a *Consistency* que se obteria se as explicações não tivessem nenhuma relação com a classe, como se as classes fossem sorteadas entre os mapas. Ele serve só como referência para saber se um valor é alto ou baixo; nada é descontado. Não é zero porque, mesmo com explicações sorteadas, dois mapas com a mesma explicação às vezes seriam da mesma classe por coincidência, e isso acontece mais nas classes grandes. Por exemplo, 172 dos 622 mapas (28%) são de BRD, e o acaso dessa classe é 0,23; já o STE tem 14 mapas, e o acaso dele é 0,02. Assim, o BRD, com 0,64, está bem acima do acaso, enquanto o STE, com 0,03, está praticamente nele.

Tabela 2: F1 e *Consistency* ($k = 2$) por classe, modelo B, ordenados pela *Consistency*.

Classe	Mapas	F1	Consistency	Acaso	Explicação mais comum
BRD	172	0,927	0,64	0,23	$V1 \cdot QRS + V2 \cdot QRS$
STD	65	0,778	0,51	0,09	$II \cdot ST-T + aVR \cdot ST-T$
IABV	61	0,884	0,45	0,08	$II \cdot \text{pré-QRS} + aVR \cdot \text{pré-QRS}$
AF	108	0,931	0,42	0,14	$V4 \cdot QRS + V5 \cdot QRS$
CVP	59	0,837	0,26	0,08	$aVR \cdot QRS + V5/aVF \cdot QRS$
BRE	20	0,870	0,25	0,03	$V1 \cdot QRS + V2 \cdot QRS$
SNR	78	0,796	0,21	0,10	$aVR \cdot \text{pré-QRS} + V1 \cdot QRS$
CAP	45	0,750	0,14	0,06	dispersa
STE	14	0,596	0,03	0,02	pré-QRS (esperado: ST-T)




Figura 2: $F1 \times Consistency$ por classe (modelo B). Os círculos vazios indicam o valor esperado ao acaso, e a haste, o quanto cada classe fica acima dele.

Sensibilidade. O método foi recalculado com 9 combinações de regiões (janela do QRS de 140, 180 ou 220 ms e fim do ST-T em 40, 45 ou 50% do RR) e com $k \in \{1, 2, 3\}$. Com $k = 2$, o BRD fica em 1º e CAP e STE nas duas últimas posições em todas as combinações. Com $k = 3$, cerca de 47% dos mapas ficam sem par (explicação não verificável), e por isso essa opção foi descartada.

6. Conclusões parciais (apenas F1 e Consistency)

A comparação com o F1 foi feita de forma **descritiva** (ordenação e comparação por classe, conforme a seção 4.5 da proposta), sem coeficientes de correlação: as nove classes não são observações independentes (registros multirrótulo, mesmo modelo e mesmo conjunto de teste) nem uma amostra de uma população maior de classes.

1. O classificador reproduz o desempenho do artigo base (0,819 contra 0,813). As classes mais difíceis são as mesmas: STE e CAP.
2. As explicações carregam informação sobre a classe de forma moderada: *Consistency* global de 0,42, cerca de 3 vezes o esperado ao acaso.
3. A *Consistency* é alta onde o diagnóstico depende de um marcador morfológico localizado (BRD, STD, IAVB), e as regiões destacadas coincidem com os critérios clínicos (QRS em V1 no BRD, ST-T no STD, intervalo PR no IAVB). Isso indica plausibilidade, ainda sem validação por especialista.
4. Desempenho e consistência coincidem nas pontas: as classes de melhor F1 (BRD, IAVB, AF) estão entre as mais consistentes, e as de pior F1 (CAP, STE) são as menos consistentes. Há exceções no meio (STD com explicações consistentes e F1 intermediário; BRE com bom F1 e explicações pouco consistentes), o que mostra que as duas dimensões não se confundem.
5. A discretização determina o resultado da métrica: a versão padrão do Quantus gerava uma coincidência artificial com o F1.

Limitações: um único modelo e uma única divisão dos dados; apenas as predições corretas foram explicadas; classes pequenas têm valores pouco estáveis (STE tem 14 mapas); e a *Consistency* mede coerência interna das explicações, e não a sua correção clínica.

7. Próximos passos

- Ler os artigos das próximas métricas do Quantus, de fidelidade (*Faithfulness Correlation*, *Faithfulness Estimate*, *Sensitivity-N*, *Selectivity*, *Infidelity*) e de robustez (*Local Lipschitz Estimate*, *Max/Avg-Sensitivity*, *Continuity*, RIS e ROS).

- Para cada uma, verificar se a implementação do Quantus é aderente à definição original e ao caso de ECG (formato 12 derivações $\times$ 15000 amostras, preenchimento e multirrótulo), como foi feito para a *Consistency*.
- Rodar as métricas aderentes sobre o modelo B, resolvendo as pendências de memória já conhecidas (GPU nas métricas de robustez e RAM na *Selectivity*).

Pontos para discutir com o orientador: (i) a troca para BCE simples, que difere da proposta; (ii) a análise descritiva sem coeficientes de correlação, que difere do “calculando a correlação” da proposta; (iii) a escolha de k ($k = 1$ é mais verificável, com cerca de 2% dos mapas sem par; $k = 2$ é mais informativo, com cerca de 18%).