Relatório de Status do TCC

Avaliação das Explicações SHAP em Redes Neurais Profundas para Classificação de Arritmias Cardíacas em ECG

Aluno: Arthur Santos de Oliveira (RA: 156297)

Orientador: Prof. Dr. Luis Augusto Martins Pereira

Data: 14/10/2026

Repositório: https://github.com/Arthur-so/shap-ecg-arrhythmia

---

1. Resumo

- O classificador está no nível do artigo base: F1-macro de **0,819** no teste, contra 0,813 de Zhang et al. (2021).
- Duas métricas de qualidade das explicações já estão calculadas e documentadas: **Consistency** e **Faithfulness Correlation**. As duas foram **reimplementadas** a partir dos artigos originais, porque as versões do Quantus não eram adequadas ao ECG.
- A **Sufficiency** foi retirada da análise.
- As demais métricas estão sendo **revisadas uma a uma**: leitura do artigo original e verificação de se a implementação do Quantus atende à definição e ao caso do ECG.

2. Modelo avaliado

ResNet34 1D treinada no CPSC2018 (9 classes), com o protocolo de Zhang et al. (2021). Em relação à proposta, duas mudanças: (i) foi corrigido o rótulo da classe CVP, que estava sem nenhuma amostra por falha no mapeamento de códigos; (ii) a perda passou de BCE ponderada para BCE simples, como no código dos autores, porque uma ablação mostrou resultados equivalentes (0,816 com ponderação e 0,819 sem). As explicações GradientSHAP foram geradas para as 622 predições corretas do conjunto de teste.

3. Métricas: o que foi decidido e por quê

3.1. Base comum: regiões do batimento

Um mapa SHAP tem 180 000 valores (12 derivações × 15 000 instantes), e um ponto isolado do ECG não tem significado clínico. Por isso, as duas métricas reimplementadas usam os mesmos **atributos**: cada batimento é dividido, a partir do pico R, em três partes (pré-QRS, QRS e ST-T), em cada uma das 12 derivações, o que dá **36 regiões** por ECG (Figura 1). A importância de uma região é a soma do mapa SHAP nela.

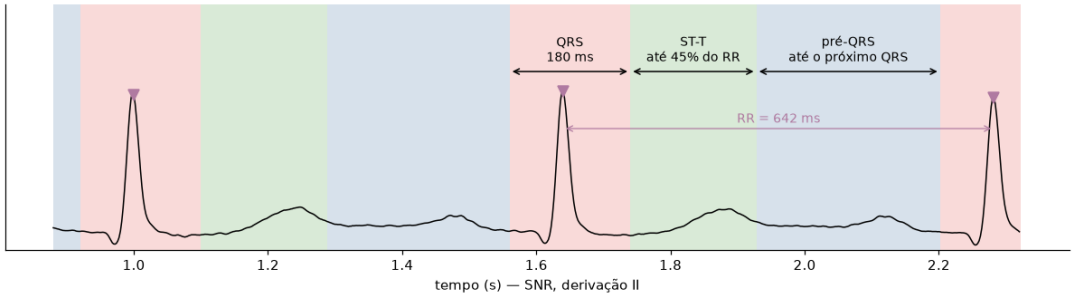


Figura 1: Trecho de cerca de 1,5 s da derivação II de um ECG normal, com três picos R (triângulos) e as regiões de cada batimento: QRS (vermelho), ST-T (verde) e pré-QRS (azul). As mesmas regiões são aplicadas às 12 derivações.

3.2. Sufficiency: retirada

O artigo que a define (Dasgupta et al., 2022) afirma que, para métodos de importância de atributos como o SHAP, não é possível saber quando uma explicação "se aplica" a outro exemplo, e por isso não define a métrica para esses métodos. A versão do Quantus compara mapas por distância, o que na prática é uma segunda Consistency, sem base na definição original.

3.3. Consistency: reimplementada

O problema. A discretização padrão do Quantus usa o sinal dos 5 *primeiros* valores do mapa (e não dos 5 mais importantes), depois de aplicar valor absoluto. Nos mapas do projeto, isso deu **a mesma explicação para todos os ECGs**, e a métrica passava a medir só a homogeneidade das predições.

A versão atual. Segue a definição e o estimador de Dasgupta et al. (2022): a explicação de cada mapa é o par das 2 regiões mais importantes, com o sinal; para cada mapa, calcula-se a fração dos outros mapas com a mesma explicação que explicam a mesma classe. O valor esperado ao acaso é reportado como referência.

3.4. Faithfulness Correlation: reimplementada

O problema. O Quantus retira 224 pontos isolados (0,12% do sinal) e os substitui pelo valor mínimo do próprio ECG. Num diagnóstico com 36 ECGs, essa perturbação mudou bastante a saída do modelo, mas **sem relação com as atribuições** (correlação média de $-0{,}02$): a queda refletia os picos artificiais criados pelo valor mínimo, e não a retirada de informação.

A versão atual. Segue o protocolo de Bhatt et al. (2020): para cada ECG, sorteiam-se 50 grupos de regiões; para cada grupo, compara-se a soma das atribuições com a queda do *logit* da classe ao substituir as regiões pela baseline. O valor do ECG é a correlação de Pearson entre essas duas listas. Como no artigo, foram usadas as baselines zero e média do treino (que deram resultados praticamente iguais) e vários tamanhos de grupo (4, 9 e 18 regiões). No mesmo diagnóstico, a correlação média passou de $-0{,}02$ para 0,57.

As duas implementações foram conferidas em casos sintéticos com resultado conhecido, e cada métrica tem um fichamento do artigo original com a comparação artigo × Quantus × versão atual.

4. Resultados (modelo B)

Tabela 1: F1, Consistency e Faithfulness Correlation por classe. Entre parênteses, a posição da classe em cada medida (1° = maior valor).

Classe	Mapas	F1		Consistency (acaso)		Faithfulness Corr.	
BRD	172	0,927	(2°)	0,64 (0,23)	(1°)	0,74	(1°)
IAVB	61	0,884	(3°)	0,45 (0,08)	(3°)	0,64	(3°)
AF	108	0,931	(1°)	0,42 (0,14)	(4°)	0,54	(6°)
CVP	59	0,837	(5°)	0,26 (0,08)	(5°)	0,61	(4°)
BRE	20	0,870	(4°)	0,25 (0,03)	(6°)	0,65	(2°)
STD	65	0,778	(7°)	0,51 (0,09)	(2°)	0,52	(7°)
SNR	78	0,796	(6°)	0,21 (0,10)	(7°)	0,46	(9°)
CAP	45	0,750	(8°)	0,14 (0,06)	(8°)	0,52	(8°)
STE	14	0,596	(9°)	0,03 (0,02)	(9°)	0,60	(5°)
Global	622	**0,819**		**0,42 (0,13)**		**0,61**	

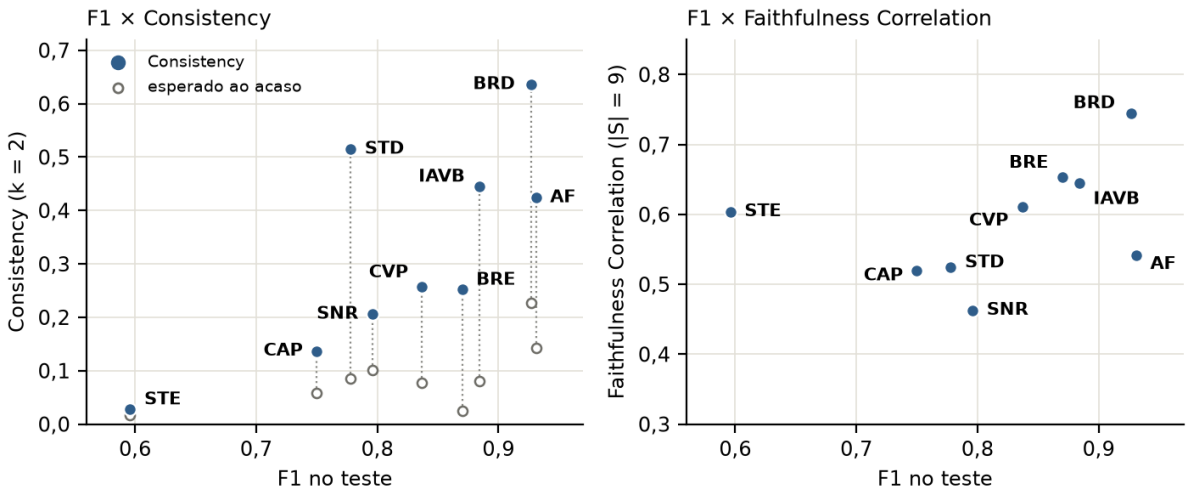


Figura 2: F1 por classe contra a Consistency (esquerda; círculos vazios: valor esperado ao acaso) e contra a Faithfulness Correlation com grupos de 9 regiões (direita).

5. Conclusões até agora

As comparações com o F1 são **descritivas** (ordenação das classes), sem coeficientes de correlação: as nove classes não são observações independentes (registros multirrótulo, mesmo modelo e mesmo conjunto de teste) nem uma amostra de uma população maior de classes.

1. **As explicações SHAP carregam informação real sobre o modelo.** A Consistency global (0,42) é cerca de três vezes o esperado ao acaso (0,13), e a Faithfulness Correlation (0,61) é positiva em todas as classes: quando o SHAP aponta um grupo de regiões como mais importante, retirá-lo derruba mais a saída do modelo. Os valores são moderados, e não perfeitos.
2. **BRD tem as explicações de melhor qualidade** nas duas métricas (1º em ambas) e está entre as classes de maior F1. As regiões que o SHAP destaca coincidem com o critério clínico (QRS em V1/V2).
3. **CAP fica na base nas três medidas** (8º no F1, na Consistency e na Faithfulness Correlation), e **IAVB** fica em 3º nas três.
4. **Desempenho e qualidade das explicações coincidem nas pontas, mas não de forma estrita.** Há discordâncias: AF tem o melhor F1 e qualidade intermediária; STE tem o pior F1, Consistency quase nula e Faithfulness Correlation intermediária (com só 14 mapas); STD tem explicações muito consistentes, mas fidelidade intermediária.
5. **As duas métricas medem propriedades diferentes** e nem sempre concordam entre si (por exemplo, STD e BRE), o que reforça a importância de avaliar a qualidade das explicações por mais de uma dimensão.
6. **A configuração padrão do Quantus não pode ser usada sem revisão** no caso do ECG: nas duas métricas revisadas, ela produzia resultados que não refletiam as explicações.

Limitações: um único modelo e uma única divisão dos dados; apenas as predições corretas foram explicadas; classes pequenas (STE, BRE) têm valores menos estáveis; as métricas medem a coerência das explicações com o modelo, e não a sua correção clínica.

6. Revisão das demais métricas

As métricas restantes estão sendo revisadas com o mesmo procedimento usado para a Consistency e a Faithfulness Correlation: (1) leitura do artigo original; (2) comparação da implementação e da

configuração do Quantus com a definição; (3) se houver dúvida, um diagnóstico com dados; (4) se necessário, reimplementação adaptada ao ECG; (5) fichamento documentando as decisões.

Tabela 2: Situação das métricas.

Métrica	**Artigo de referência**	**Situação**
Fidelidade		
Consistency	Dasgupta, Frost e Moshkovitz (2022)	Reimplementada e calculada
Faithfulness Correlation	Bhatt, Weller e Moura (2020)	Reimplementada e calculada
Sufficiency	Dasgupta, Frost e Moshkovitz (2022)	Retirada
Faithfulness Estimate	Alvarez-Melis e Jaakkola (2018)	Próxima a revisar (artigo já baixado)
Sensitivity-N	Ancona et al. (2018)	A revisar (artigo já baixado)
Selectivity	Montavon, Samek e Müller (2018)	A revisar; estourava a memória (RAM)
Infidelity	Yeh et al. (2019)	A revisar; a mais cara de calcular
Robustez		
Local Lipschitz Estimate	Alvarez-Melis e Jaakkola (2018)	A revisar; estourava a memória da GPU
Max- e Avg-Sensitivity	Yeh et al. (2019)	A revisar; estouravam a memória da GPU
Continuity	Montavon, Samek e Müller (2018)	A revisar; estourava a memória da GPU
RIS e ROS	Agarwal et al. (2022)	A revisar; estouravam a memória da GPU

7. Próximos passos

- Revisar a Faithfulness Estimate e a Sensitivity-N, cujos artigos já foram baixados, seguidas das demais métricas de fidelidade.
- Revisar as métricas de robustez, resolvendo também os problemas de memória da GPU.
- Calcular cada métrica revisada sobre o modelo B, reaproveitando o modelo e os mapas já gerados, e acrescentá-la à comparação descritiva com o F1.