Relatório de Status do TCC

Avaliação das Explicações SHAP em Redes Neurais Profundas para Classificação de Arritmias Cardíacas em ECG

Aluno: Arthur Santos de Oliveira (RA: 156297)

Orientador: Prof. Dr. Luis Augusto Martins Pereira

Data: 21/10/2026

Repositório: https://github.com/Arthur-so/shap-ecg-arrhythmia

1. Resumo

- **Novas métricas:** a **Faithfulness Estimate** e a **Max-/Avg-Sensitivity** foram revisadas a partir dos artigos originais, reimplementadas e calculadas. Nas duas, a configuração do Quantus usada antes não media o que a métrica pretende.
- **Análise conjunta:** as quatro métricas disponíveis se organizam em **dois blocos**. Fidelidade (Faithfulness Correlation e Estimate) e robustez (sensibilidade) ordenam as classes do mesmo jeito; a Consistency segue outra ordem.
- **Achado principal da sensibilidade:** as explicações são robustas, pois quase não mudam com perturbações pequenas do ECG. Como referência, trocar a semente do GradientSHAP no mesmo ECG muda o mapa mais do que essas perturbações (cerca de 5 vezes); a Seção 6.4 discute como isso entra na leitura das métricas.
- **Pergunta do TCC:** a qualidade das explicações acompanha o F1 só em parte. Fidelidade e robustez parecem depender mais do **tipo de classe** (forma do QRS ou ritmo) que do F1.

2. Contexto (resumo do que já estava feito)

Modelo B: ResNet34 1D no CPSC2018, 9 classes, F1-macro de 0,819 no teste (Zhang et al., 2021: 0,813). As explicações GradientSHAP foram geradas para as 622 predições corretas do teste. Todas as métricas usam as mesmas **36 regiões do batimento**: 12 derivações × 3 trechos (pré-QRS, QRS e ST-T), cada região reunindo o mesmo trecho em todos os batimentos do ECG (Figura 1). A **Consistency** e a **Faithfulness Correlation** já haviam sido reimplementadas; a **Sufficiency** foi retirada; a **complexidade** (Bhatt et al., 2020) foi analisada e aguarda decisão sobre inclusão.

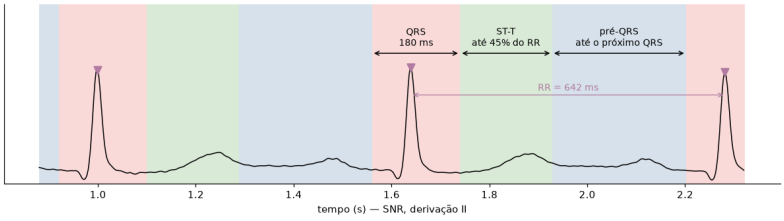


Figura 1: Regiões de cada batimento na derivação II: QRS (vermelho), ST-T (verde) e pré-QRS (azul).

3. Faithfulness Estimate

Pergunta. Retirando **uma região de cada vez**, a queda na saída do modelo acompanha a importância que o SHAP deu à região? (Alvarez-Melis e Jaakkola, 2018, §5.3.)

Por que foi reimplementada. A configuração usada trocava grupos de 500 pontos pelo valor mínimo do ECG. Num diagnóstico, retirar grupos de importância **negativa** derrubava a saída quase tanto quanto retirar os de importância positiva (3,06 contra 3,30): a métrica media o dano ao sinal, e não a retirada de informação.

Versão atual. Cada uma das 36 regiões é trocada por uma baseline, uma de cada vez; o valor do ECG é a correlação de Pearson entre as 36 importâncias e as 36 quedas do *logit*. Ela segue o artigo

com duas adaptações justificadas: regiões no lugar de atributos isolados (o próprio artigo recomenda unidades de nível mais alto para entradas grandes) e *logit* no lugar da probabilidade, que satura (84% das retiradas a mudam menos de 0,01). Com a probabilidade, a conclusão é a mesma.

Baseline. O artigo manda trocar o atributo por um "valor médio", sem dizer qual. Por isso foram calculadas duas versões: com **zero** e com a **média do treino** (média de cada ponto, derivação × instante, sobre os ECGs de treino). Os resultados coincidem até a terceira casa decimal (global 0,615 nas duas; diferença máxima por classe de 0,001), então os números abaixo valem para as duas. Uma explicação provável é que as duas baselines são quase o mesmo sinal: cada derivação está em z-score, com média zero, e na média do treino os batimentos, que caem em instantes diferentes em cada ECG, tendem a se cancelar.

Resultado. Global de **0,62**, positiva em todas as classes. Retirar uma região de importância positiva baixa o *logit* em 0,32, em média, e retirar uma de importância negativa o aumenta em 0,34, como se espera de uma explicação fiel.

4. Max-Sensitivity e Avg-Sensitivity

Pergunta. Se o ECG mudar um pouquinho, a explicação muda muito? A Max-Sensitivity (Yeh et al., 2019) é a maior mudança da explicação entre várias versões levemente perturbadas do ECG; a Avg-Sensitivity (Bhatt et al., 2020), a média. **Menor é melhor.**

Por que foi reimplementada. A configuração do Quantus comparava o mapa salvo (50 amostras do GradientSHAP) com mapas refeitos com 20 amostras e outra semente aleatória, somava ruído também ao preenchimento e não descartava perturbações que mudam a predição. Um diagnóstico com 18 ECGs mostrou que o valor obtido era praticamente o mesmo que se obtém **sem perturbação nenhuma**: a métrica media a aleatoriedade do GradientSHAP, e não a robustez da explicação.

Versão atual. Para cada mapa, 10 perturbações com ruído uniforme de ±0,1 (em escala z-score) somado só ao trecho real do ECG, o raio usado por Yeh et al. Cada ECG perturbado é explicado com a **mesma configuração e a mesma semente** da explicação original, de modo que a diferença entre os mapas reflete só a perturbação. Perturbações que mudam a predição são descartadas (só 1 de 6 220 mudou). A distância é a de Yeh et al. (entre mapas normalizados; vai de 0 a 2), calculada nas 36 regiões. Reporta-se também o **piso**: a distância entre duas execuções do GradientSHAP no mesmo ECG, sem perturbação, com sementes diferentes.

Tabela 1: Diagnóstico e resultado global (distância por regiões; "top-2 igual": os dois mapas têm o mesmo par de regiões principais, que é a explicação usada pela Consistency).

Comparação	**Distância**	**Top-2 igual**
Mesmo ECG, outra execução do GradientSHAP (piso)	0,36	67%
ECG perturbado (±0,1), mesma semente: Max-Sensitivity	0,07	97%
Configuração antiga do Quantus	0,43	56%

Resultado. As explicações são **robustas**: uma perturbação pequena muda o mapa em 0,07 (numa escala até 2) e mantém o par de regiões principais em 97% dos casos. Mas o **piso é cerca de 5 vezes maior**, e isso vale em todos os 622 mapas: duas execuções do GradientSHAP no mesmo ECG concordam no par de regiões principais em só 67% dos casos. A Max e a Avg ordenam as classes do mesmo jeito, então basta acompanhar uma delas.

5. Resultados por classe

Tabela 2: F1 e as métricas por classe. Entre parênteses, a posição da classe (1º = melhor; na sensibilidade e no piso, melhor = menor valor). Faithfulness Correlation com grupos de 9 regiões; sensibilidade e piso por regiões.

Classe	Mapas	F1		Consistency		Faith. Corr.		Faith. Est.		Max-Sens.		Piso
BRD	172	0,927	(2º)	0,64	(1º)	0,74	(1º)	0,78	(1º)	0,058	(2º)	0,32
BRE	20	0,870	(4º)	0,25	(6º)	0,65	(2º)	0,72	(2º)	0,047	(1º)	0,23
IAVB	61	0,884	(3º)	0,45	(3º)	0,64	(3º)	0,57	(5º)	0,064	(3º)	0,36
CVP	59	0,837	(5º)	0,26	(5º)	0,61	(4º)	0,66	(3º)	0,073	(5º)	0,32
STE	14	0,596	(9º)	0,03	(9º)	0,60	(5º)	0,57	(4º)	0,071	(4º)	0,35
AF	108	0,931	(1º)	0,42	(4º)	0,54	(6º)	0,51	(7º)	0,081	(7º)	0,35
STD	65	0,778	(7º)	0,51	(2º)	0,52	(7º)	0,51	(9º)	0,085	(8º)	0,40
SNR	78	0,796	(6º)	0,21	(7º)	0,46	(9º)	0,51	(8º)	0,077	(6º)	0,41
CAP	45	0,750	(8º)	0,14	(8º)	0,52	(8º)	0,55	(6º)	0,096	(9º)	0,46
Global	622	**0,819**		**0,42**		**0,61**		**0,62**		**0,072**		0,36

Valores esperados ao acaso na Consistency: global 0,13 (por classe, de 0,02 a 0,23).

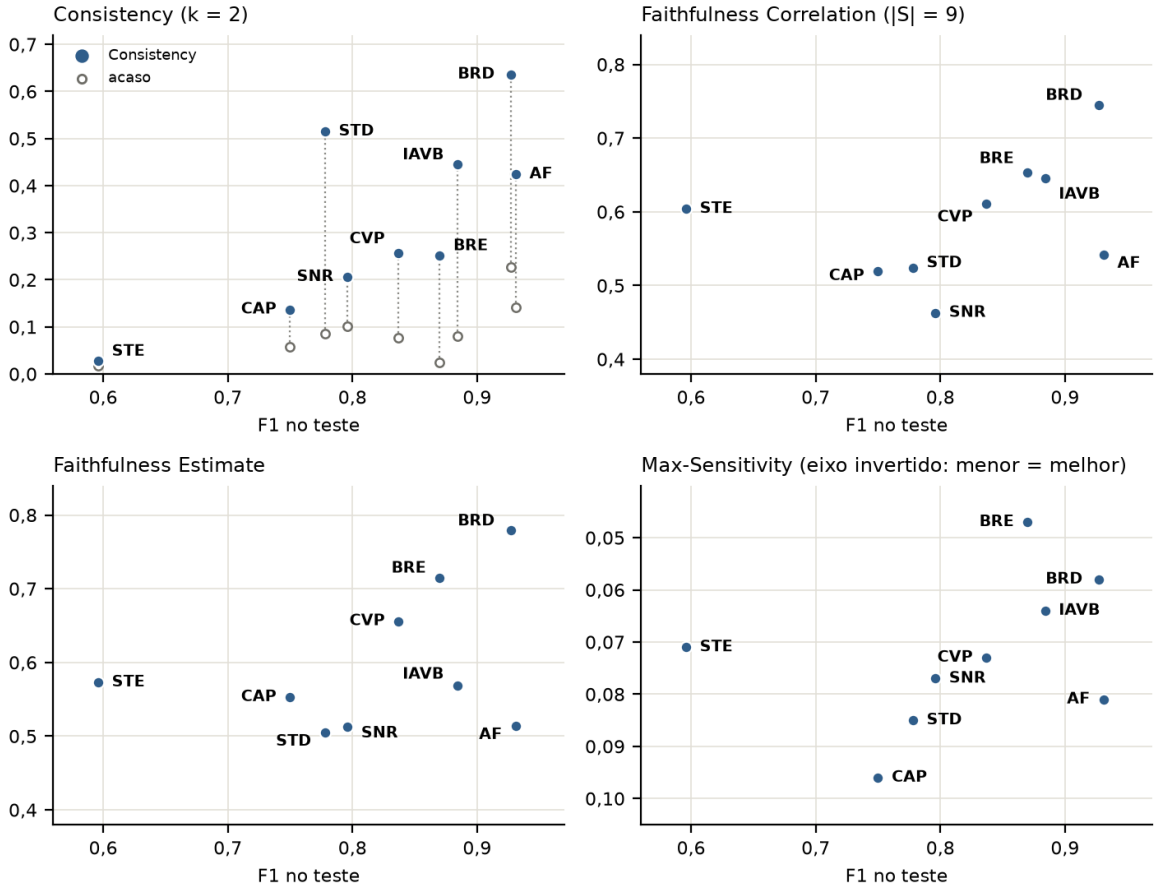


Figura 2: F1 por classe contra cada métrica. Na Max-Sensitivity, o eixo é invertido para que "melhor" fique para cima, como nos outros painéis.

6. Análise conjunta

As comparações com o F1 são **descritivas** (ordenação das classes), sem coeficientes de correlação: as nove classes não são observações independentes nem uma amostra de uma população de classes.

6.1. O que cada métrica pergunta

Dimensão	Pergunta	O que se compara
Fidelidade (Faith. Corr. e Estimate)	A explicação descreve o que o modelo faz?	A explicação com a **saída do modelo** ao retirar regiões
Consistência (Consistency)	ECGs diferentes da mesma classe recebem a mesma explicação?	Explicações de **ECGs diferentes**
Robustez (Max/Avg-Sensitivity)	A explicação se mantém se o ECG mudar um pouquinho?	Explicações de **versões quase idênticas do mesmo ECG**

6.2. Dois blocos: fidelidade e robustez de um lado, consistência de outro

Em princípio são três dimensões. Nos resultados, a robustez acompanha a fidelidade:

- As **4 classes menos robustas** (SNR, AF, STD e CAP) são exatamente as **4 menos fiéis** na Faithfulness Estimate, e BRE e BRD são as 2 primeiras nas duas. Mapa a mapa, a relação vai na mesma direção (diagnóstico: correlação de postos de $-0{,}44$ entre sensibilidade e Faithfulness Estimate).
- As duas Faithfulness concordam entre si (0,61 e 0,62 no global, ordens parecidas), como já se esperava.
- A **Consistency** segue outra ordem: STD é 2ª na Consistency e fica entre a 7ª e a 9ª posição na fidelidade e na robustez; BRE é 6ª na Consistency e 1ª–2ª nas outras.

Leitura: onde o SHAP descreve bem o modelo, ele também é estável; onde descreve pior, também é mais frágil. Já repetir a mesma razão entre ECGs é uma propriedade diferente.

6.3. Perfis das classes

Perfil	Classes	Leitura
Bom nos dois blocos	BRD, IAVB	Explicações fiéis, robustas e que se repetem entre ECGs. BRD é o caso ideal: QRS de V1 em 87% dos mapas, o critério clínico do bloqueio de ramo direito.
Fiel e robusto, pouco consistente	BRE, CVP, STE	Cada explicação descreve bem o modelo e é estável, mas a razão varia entre ECGs.
Consistente, menos fiel e robusto	STD, AF	A mesma razão se repete, mas a importância de cada região acompanha pior o modelo e é mais frágil.
Fraco nos dois blocos	SNR, CAP	Explicações menos fiéis, menos robustas e pouco repetidas.

6.4. A Consistency mistura duas causas

O GradientSHAP não calcula o mapa de forma exata: ele o estima com 50 sorteios (baselines e ruído), e outro conjunto de sorteios daria um mapa um pouco diferente. O piso mede esse erro de estimativa: em duas execuções no mesmo ECG, o par de regiões principais coincide em só 67% dos casos.

A Consistency **capta corretamente** essa variação: as explicações efetivamente geradas são menos consistentes por causa dela, e o valor medido é válido. O que muda é a leitura, porque uma Consistency baixa pode ter duas causas, que a métrica sozinha não separa:

	Origem	Relação com a pergunta do TCC
A	O modelo usa evidências diferentes em ECGs diferentes da mesma classe	Característica do modelo na classe; faz sentido comparar com o F1
B	Erro de estimativa do GradientSHAP (50 amostras por mapa)	Característica da configuração do estimador; diminui com mais amostras e não depende de quão bem o modelo classifica a classe

O mesmo erro afeta também a Faithfulness Correlation e a Estimate (importâncias com ruído reduzem a correlação), mas a Consistency tende a ser mais sensível, porque usa um rótulo discreto (o par top-2): um erro pequeno pode trocar o rótulo inteiro.

Como o piso varia entre as classes, ele dá uma indicação de qual causa pesa mais em cada uma:

- **CAP** tem o maior piso (0,46) e Consistency baixa (8ª): parte da inconsistência pode vir da causa B.
- **BRE** tem o menor piso (0,23) e Consistency baixa (6ª): a causa B é pequena, então a inconsistência deve vir principalmente da causa A; as explicações de BRE variam de fato entre ECGs (por exemplo, alternando entre o QRS de V1 e o de V2).
- **STD** tem piso alto (0,40) e mesmo assim Consistency alta (2ª): o padrão de STD se repete apesar da causa B.

Assim, a Consistency é mantida como resultado, com o piso ao lado como contexto. Para separar as duas causas, seria preciso gerar os mapas com mais amostras e recalcular a métrica: se a Consistency de uma classe subir, pesava a causa B; se ficar igual, a causa A. Isso tem custo maior de GPU e muda os mapas usados por todas as métricas.

6.5. O que isso diz sobre a pergunta do TCC

A qualidade das explicações acompanha o F1 **em parte**:

1. **Nas pontas há coincidência.** BRD está entre as melhores no F1 e é a melhor ou a segunda em todas as métricas; CAP está entre as piores em tudo.
2. **A Consistency é a que mais acompanha o F1.** Fora STD e AF, as posições na Consistency ficam próximas das do F1. Quando o modelo classifica bem uma classe, ele tende a usar uma razão estável entre ECGs.
3. **Fidelidade e robustez dependem mais do tipo de classe.** BRE e BRD, definidas pela forma do QRS, têm explicações fiéis e robustas; AF, SNR e CAP, ligadas ao ritmo ou ao batimento como um todo, têm explicações menos fiéis e menos robustas, mesmo com F1 alto no caso de AF. Como as regiões juntam todos os batimentos e não representam o intervalo entre eles, parte disso pode ser uma limitação da própria unidade de medida para classes de ritmo.
4. **O pior F1 não tem explicação comum.** STE tem Consistency próxima do acaso, mas fidelidade e robustez intermediárias: cada explicação descreve o modelo, mas o modelo não usa uma razão estável para essa classe (com a ressalva de que são só 14 mapas).

Limitações: um único modelo e uma divisão dos dados; só predições corretas; classes pequenas (STE, BRE) menos estáveis; regiões que favorecem classes de forma local; o ruído do GradientSHAP afeta todos os mapas; as métricas avaliam se o SHAP descreve o modelo, e não se o modelo usa o critério clínico correto.

7. Situação das métricas

Métrica	Artigo de referência	Situação
Fidelidade		
Consistency	Dasgupta, Frost e Moshkovitz (2022)	Reimplementada e calculada
Faithfulness Correlation	Bhatt, Weller e Moura (2020)	Reimplementada e calculada
Faithfulness Estimate	Alvarez-Melis e Jaakkola (2018)	**Reimplementada e calculada (nova)**
Sufficiency	Dasgupta, Frost e Moshkovitz (2022)	Retirada
Sensitivity-N	Ancona et al. (2018)	Próxima a revisar
Selectivity	Montavon, Samek e Müller (2018)	A revisar
Infidelity	Yeh et al. (2019)	A revisar
Robustez		
Max- e Avg-Sensitivity	Yeh et al. (2019); Bhatt et al. (2020)	**Reimplementadas e calculadas (novas)**
Local Lipschitz Estimate	Alvarez-Melis e Jaakkola (2018)	A revisar
Continuity	Montavon, Samek e Müller (2018)	A revisar
RIS e ROS	Agarwal et al. (2022)	A revisar
Complexidade		
Complexity	Bhatt, Weller e Moura (2020)	Analisada; inclusão a decidir

8. Próximos passos

- Revisar a Sensitivity-N e, depois, as demais métricas de fidelidade e de robustez.
- Decidir se os mapas devem ser regerados com mais amostras do GradientSHAP, para reduzir o ruído do estimador.
- Decidir a inclusão da complexidade por regiões.
- Acrescentar cada nova métrica à análise conjunta, verificando se os dois blocos e os perfis das classes se mantêm.