Relatório de Status do TCC

Avaliação das Explicações SHAP em Redes Neurais Profundas para Classificação de Arritmias Cardíacas em ECG

Aluno: Arthur Santos de Oliveira (RA: 156297) **Orientador:** Prof. Dr. Luis Augusto Martins Pereira

Data: 11/11/2026 **Repositório:** https://github.com/Arthur-so/shap-ecg-arrhythmia

1. Situação geral

Os experimentos estão **concluídos** e a redação começou: os capítulos de **Materiais e Métodos** e de **Resultados e Discussão** já têm uma versão completa (24 páginas, 14 figuras), no formato de TCC do curso. Faltam a Introdução, a Fundamentação Teórica, os Trabalhos Relacionados e a Conclusão. A pergunta do trabalho é se a qualidade das explicações GradientSHAP, medida por métricas quantitativas, acompanha o desempenho (F1) do modelo em cada classe de arritmia.

2. O que está pronto

- **Modelo:** ResNet34-1D no CPSC2018 (9 classes, multirrótulo), F1-macro de **0,819** no teste, próximo de Zhang et al. (2021), 0,813, com F1 por classe também próximo (AF e BRD acima de 0,92; STE a pior, 0,596).
- **Explicações:** 622 mapas GradientSHAP (predições corretas do teste), com referência balanceada de 36 ECGs (4 por classe) e 200 sorteios por mapa.
- **Regiões do batimento:** cada mapa é resumido em 36 valores (figura na Seção 4) (12 derivações × pré-QRS, QRS e ST-T), a partir dos picos R. Os limites foram justificados clinicamente e por precedentes (Wagner et al., 2024; Gumpfer et al., 2026; Turbé et al., 2023) e testados em 9 combinações alternativas, sem mudar as pontas da ordem das classes.
- **Métricas:** sete métricas reimplementadas por regiões, com a implementação conferida contra o artigo original de cada uma: *Faithfulness Correlation*, *Faithfulness Estimate*, *Max/Avg-Sensitivity*, *Consistency*, *Complexity*, *Random Logit* e eMPRT. As comparações entre mapas são lidas em relação ao **piso**, a variação do próprio GradientSHAP entre sementes (0,18).
- **Revisão da literatura:** 12 fichamentos completos e 36 curtos (9 deles das referências de apoio da Metodologia), guia de leitura e relatório da revisão.

3. O que cada métrica avalia e resultados

Todas as métricas usam o mapa resumido nas 36 regiões. "Retirar" uma região é trocar todos os seus pontos por zero (a média da derivação) e ver quanto cai a saída (logit) da classe explicada. Quando uma métrica compara dois mapas, a distância é lida em relação ao **piso**: a distância entre dois mapas do mesmo ECG gerados com sementes diferentes (média de 0,18, numa escala de 0 a 2). Só uma distância acima do piso indica uma mudança maior que a variação do próprio GradientSHAP.

- ***Faithfulness Correlation*** (fidelidade; Bhatt et al., 2020). *Avalia* se as regiões que o mapa diz serem importantes são as que mais influenciam o modelo. *Como:* sorteiam-se 50 conjuntos de 9 regiões; para cada um, compara-se a soma das atribuições com a queda da saída ao retirá-lo, pela correlação de Pearson (1 = o mapa prevê perfeitamente a queda). *Resultado:* 0,60 global, comparável aos 0,41 a 0,63 da família SHAP em ECG (Suh et al., 2024). BRD (0,75) no topo; SNR (0,45) e STD (0,47) embaixo.
- ***Faithfulness Estimate*** (fidelidade; Alvarez-Melis e Jaakkola, 2018). *Avalia* o mesmo, região por região. *Como:* cada uma das 36 regiões é retirada sozinha, e a sua atribuição é correlacionada com a queda que ela causa. *Resultado:* 0,61 global, com a mesma ordem: BRD (0,78) e BRE (0,70) no alto, STD e SNR (0,49) embaixo.

- ***Max/Avg-Sensitivity*** (robustez; Yeh et al., 2019; Bhatt et al., 2020). *Avalia* se a explicação muda pouco quando o ECG muda pouco. *Como:* soma-se um ruído pequeno ao ECG (10 vezes), o mapa é refeito com a mesma semente, e mede-se a maior (Max) e a média (Avg) das distâncias ao mapa original. *Resultado:* 0,045 e 0,036, cerca de **4 vezes menores que o piso**: as explicações são robustas, e o que mais as faz variar é o sorteio do próprio método. A ordem das classes repete a da fidelidade.

- ***Consistency*** (Dasgupta et al., 2022). *Avalia* se ECGs que recebem a mesma explicação recebem a mesma predição. *Como:* cada mapa é resumido pelas suas 2 regiões principais (com o sinal); para cada mapa, calcula-se a fração dos outros mapas com o mesmo resumo que explicam a mesma classe, comparada com o valor esperado ao acaso. *Resultado:* 0,455 global, acima do acaso em todas as classes; é a métrica mais próxima do F1 (AF, BRD e IAVB no alto; CAP e STE embaixo).

- ***Complexity*** (Bhatt et al., 2020). *Avalia* se a importância está concentrada em poucas regiões, o que facilita a leitura. *Como:* calcula-se a entropia das frações de importância e a converte no número efetivo de regiões (de 1, tudo numa região, a 36, tudo igual). *Resultado:* 24 de 36 regiões: os mapas são espalhados. BRD, AF e IAVB são os mais concentrados; STD, o mais espalhado.

- ***Random Logit*** (randomização; Sixt et al., 2020). *Avalia* se o mapa muda quando se pergunta por outra classe. *Por quê:* um método de explicação pode simplesmente destacar o que chama atenção no ECG (por exemplo, os QRS, que são os picos mais altos), qualquer que seja a classe pedida. Nesse caso, o mapa que "explica o BRD" e o que "explica a STE" seriam iguais, e o mapa não diria nada sobre a decisão do modelo. *Como:* num ECG com BRD, por exemplo, gera-se o mapa da classe BRD e o mapa de uma classe que o ECG não tem (como STE), com a mesma semente, para que só a classe mude. Compara-se a distância entre os dois (0 = mapas iguais; 2 = opostos). Se a distância ficasse perto do piso, a explicação não dependeria da classe. *Resultado:* distância média de 1,60, cerca de 10 vezes o piso, e todos os 4 886 pares ficam acima do piso: os mapas são específicos da classe explicada. AF tem os mapas mais específicos e STE, os menos, o que acompanha o F1.

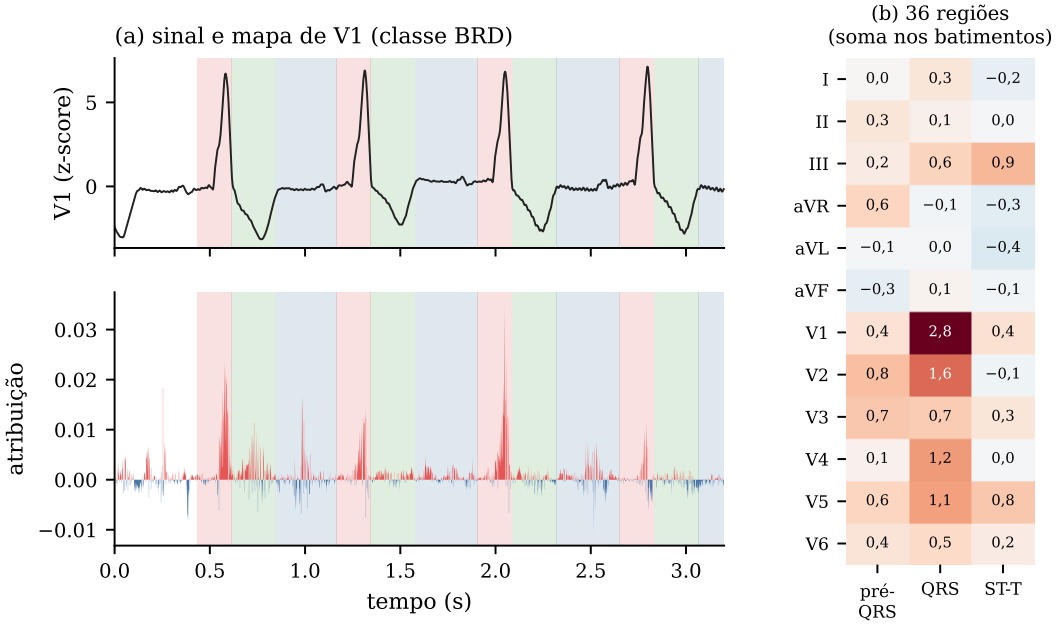
- **eMPRT** (randomização; Hedström et al., 2023). *Avalia* se o mapa depende do que o modelo aprendeu. *Por quê:* se um mapa sai praticamente igual de uma rede treinada e de uma rede que não aprendeu nada, ele não explica o modelo; descreve só o ECG. *Como:* sorteiam-se de novo todos os pesos da rede, o que apaga o aprendizado, e refaz-se o mapa do mesmo ECG com a mesma semente. O critério do artigo é que o mapa do modelo aleatório fique **mais espalhado** (maior entropia, $q > 0$), porque não haveria mais regiões que o modelo "usa". *Resultado:* o critério falha ($q = -0{,}015$): o mapa do modelo aleatório fica até mais concentrado, quase sempre nos QRS (as 2 regiões principais são de QRS em 88% dos mapas, contra 42% no modelo treinado). *Por que isso é esperado:* o mapa do GradientSHAP é o gradiente multiplicado por (ECG − referência). Num modelo aleatório, o gradiente não tem estrutura, mas o segundo fator continua lá, e ele é maior justamente onde o ECG tem os maiores valores, os picos do QRS. O mapa passa a reproduzir a forma do próprio ECG, como Adebayo et al. (2018) observaram para os métodos do tipo gradiente × entrada (a estrutura da entrada permanece; muda o sinal das atribuições). A entropia não detecta isso, mas as distâncias detectam: o mapa do modelo aleatório fica a 8,7 vezes o piso do mapa treinado, e a região principal coincide em só 5% dos casos. O mapa depende, portanto, do modelo; o eMPRT é usado como teste de sanidade, e não para comparar classes.

4. Principais resultados

Relação de cada grupo de métricas com o F1 por classe (comparação descritiva, por posição das classes).

Métricas	**Valor global**	**Relação com o F1**
Consistency, *Random Logit*	0,455; 1,60	Acompanham o F1 nas pontas: AF, BRD e IAVB no alto; CAP e STE embaixo.
Faithfulness Correlation e *Estimate*	0,60; 0,61	Não acompanham: seguem o tipo de evidência (QRS: BRD, BRE, CVP no alto; ritmo e ST: SNR, AF, CAP, STD embaixo).
Max/Avg-Sensitivity	0,045; 0,036	Mesma ordem da fidelidade; ambas 4 vezes menores que o piso.
Complexity	24 de 36 regiões	Parcial: as três mais concentradas são as três de maior F1.
eMPRT	$q = -0{,}015$	Falha no critério de entropia, mas o mapa depende do modelo (distância 8,7 vezes o piso); usado como teste de sanidade.

Conclusão parcial: a resposta **depende da propriedade medida**. As métricas que envolvem a decisão do modelo entre classes acompanham o F1; as de fidelidade e robustez acompanham a amplitude e o tipo da região diagnóstica de cada classe, o que concorda com Gumpfer et al. (2026) e Baer et al. (2025a, 2025b). Não se encontrou, na revisão, trabalho que relacione diretamente a qualidade das explicações com o F1 por classe.



Exemplo (ECG de BRD): o mapa de V1 e o vetor das 36 regiões; a região principal é o QRS de V1, onde o BRD é reconhecido clinicamente.